

Evaluación de cadenas de procesamiento en la creación de conjuntos de datos del habla

*Tesis final presentada para obtener el título de Ingeniero de Sonido de la
Universidad Nacional de Tres de Febrero (UNTREF)*

TESISTA: Matías Di Bernardo (42.229.438)

TUTOR/A: (Ing.) Guillermo Marzik

COTUTOR/A: (Lic.) Gala Lucía Gonzalez Barrios

AGRADECIMIENTOS

Se propone incluir este apartado, donde se debe agradecer primeramente a las autoridades de la Universidad, al coordinador de la carrera, al tutor y a los docentes implicados en el desarrollo de la investigación. Seguidamente agradecer a familiares o a aquellas personas que se quiera. También puede incluirse en la siguiente hoja una dedicatoria personal. A modo de ejemplo el contenido podría ser:

“En primer lugar dar gracias a la Universidad Nacional de Tres de Febrero (UNTREF), a su Rector Lic. Anibal Jozami, a todo su personal docente y no docente. Por promover un espacio ideal para el desarrollo de ideas y nuevos pensamientos y brindar a todos y cada uno de los alumnos, de esta casa de altos estudios, todos los recursos que esta institución dispone. Esta investigación no hubiera sido posible sin una formación académica acorde, por este motivo debo extender mi agradecimiento a los docentes de la carrera de Ingeniería de Sonido de la UNTREF, a su coordinador Ing. Alejandro Bibondo, que siendo la primera carrera de estas características del país, es muy importante contar con un cuerpo docente afín a las exigencias que este desafío propone, prestando su dedicación y vocación de enseñar. Un especial agradecimiento por la participación de esta tesis a la tutora Ing. Nombre Apellido, que supo transmitirme sus conocimientos y ayudarme a organizarme y fijarme un rumbo concreto y delineado, disponiendo desmedidamente de su tiempo. Por otra parte, quisiera hacer una mención especial al Ing. Hernan San Martin, que permitió el uso de las instalaciones de su laboratorio para poder trabajar y la disposición de todos sus recursos para que dicha investigación se realizara en tiempo y forma. Por último y no menos importante, quiero dar un afectuoso y cálido agradecimiento a mi familia...”

DEDICATORIA

Elige a quién o a qué quieres dedicárselo (completar).

Elegir el motivo de la dedicatoria (orientativo).

ÍNDICE DE CONTENIDOS

RESUMEN	XI
ABSTRACT	XII
1 INTRODUCCIÓN	1
1.1 FUNDAMENTACIÓN	1
1.2 OBJETIVOS	2
1.2.1 Objetivo general	2
1.2.2 Objetivos específicos	3
1.3 ESTRUCTURA DE LA INVESTIGACIÓN	3
2 MARCO TEÓRICO	5
2.1 DESCRIPTORES DE CALIDAD DE AUDIO	5
2.1.1 Métricas de degradación de la señal	5
2.1.2 Métricas de entorno	6
2.1.3 Métricas del habla	7
2.2 TEXT-TO-SPEECH (TTS)	8
2.3 REDES NEURONALES	9
2.4 INTELIGENCIA ARTIFICIAL GENERATIVA	9
2.5 MODELOS DE DIFUSIÓN	10
3 ESTADO DEL ARTE	12
3.1 MODELOS DE TTS	12
3.1.1 Modelos Autoregresivos	12
3.1.2 Modelos No Autoregresivos y Paralelos	13
3.1.3 Modelos basados en Difusión y Flow Matching	13
3.2 CADENAS DE PRE PROCESAMIENTO	14
3.3 CONJUNTOS DE DATOS DEL HABLA EN ESPAÑOL	15
4 DESARROLLO	16
4.1 RECOPIACIÓN DE BASES DE DATOS	16
4.1.1 Datos <i>in-the-wild</i>	16
4.1.2 Datos profesionales	17

4.2	DESARROLLO DE LA CADENA DE PRE PROCESAMIENTO	17
4.2.1	Diferentes configuraciones	18
4.3	EVALUACIÓN DE LOS CONJUNTOS DE DATOS	21
4.3.1	Reducción del corpus	21
4.3.2	Calidad de la grabación	22
4.3.3	Condiciones acústicas	23
4.3.4	Diferencias del habla	24
4.3.5	Métrica conjunta	24
4.4	ENTRENAMIENTO DEL MODELO DE ESTIMACIÓN DE DENSIDAD	25
4.4.1	Configuración del modelo e hiperparámetros	26
4.5	MODELO DE TTS ZERO-SHOT	27
5	RESULTADOS Y ANÁLISIS	30
5.1	RESULTADOS DE LAS DIFERENTES VARIANTES DE LA CADENA	30
5.1.1	Ejemplo de cálculo	30
5.1.2	Métricas separadas	31
5.1.3	Métricas compuestas	33
5.1.4	Optimización de la cadena	34
5.1.5	Análisis del peso de cada métrica	35
5.2	COMPARACIÓN ENTRE CONJUNTOS DE DATOS	36
5.2.1	Dataset profesional vs procesado	36
5.3	COMPARACIÓN POR ESTIMACIÓN DE DENSIDAD	39
5.4	COMPARACIÓN ENTRE MÉTRICAS OBJETIVAS Y ESTIMACIÓN DE DENSIDAD .	43
5.4.1	Conclusión del Análisis Cruzado	45
5.5	VALIDACIÓN MODELO DE TTS ZERO-SHOT	46
5.6	EVALUACIÓN EXPLORATORIA EN TAREAS DE SÍNTESIS ZERO-SHOT	46
5.6.1	Predicción basada en Métricas Objetivas (TOT)	47
5.6.2	Predicción basada en Estimación de Densidad (Log-Likelihood) . . .	48
5.6.3	Discusión Final	49
5.6.4	Sensibilidad Arquitectónica: Modelos Autoregresivos frente a Mode- los de Difusión	49
6	CONCLUSIONES	51

7	LÍNEAS FUTURAS DE INVESTIGACIÓN	52
	BIBLIOGRAFÍA	53

Índice de Figuras

Figura 1. Diagrama de flujo del proceso completo para generar el dataset.	19
Figura 2. Resultado de MOS por cantidad de segmentos del dataset original para los 2 modelos a comparar.	20
Figura 3. Variantes propuestas para evaluar diferentes configuración de la cadena de procesamientos.	20
Figura 4. Comparación entre PESQ y cantidad de horas de diferentes variantes con NISQA.	31
Figura 5. Comparación entre T30 y cantidad de horas de diferentes variantes con DNS MOS.	32
Figura 6. Comparación entre F0-std y PESQ para diferentes variantes con DNS MOS.	33
Figura 7. Comparación entre reducción de datos y calidad de señal para diferentes variantes con Nisqa.	34
Figura 8. Comparación entre calidad de señal y condiciones acústicas para diferentes variantes con DNSMOS.	34
Figura 9. Diferencias del valor de PESQ promedio según diferentes conjuntos de datos.	37
Figura 10. Diferencias del valor de T30 promedio según diferentes conjuntos de datos.	38
Figura 11. Diferencias del valor de F0 promedio según diferentes conjuntos de datos.	39
Figura 12. Función de pérdida en función de los audios evaluados durante el entrenamiento del modelo de difusión.	40
Figura 13. Distribución de la verosimilitud para diferentes algoritmos de denoising.	42
Figura 14. Ejemplo del mismo audio procesado con diferentes algoritmos de denoising.	44
Figura 15. Comparación de la predicción del modelo de difusión con las métricas de calidad de señal y condiciones acústicas.	45
Figura 16. Relación entre la métrica objetiva total (TOT) y la calidad subjetiva sintetizada (MOS).	47
Figura 17. Relación entre la estimación de densidad (Log-Likelihood) y la calidad subjetiva sintetizada (MOS).	48
Figura 18. Comparación entre PESQ y horas del dataset para diferentes variantes con DNSMOS.	60

Figura 19.Comparación entre SI-SDR y horas del dataset para diferentes variantes con DNSMOS.	60
Figura 20.Comparación entre SNR y horas del dataset para diferentes variantes con NISQA.	60
Figura 21.Comparación entre T30 y horas del dataset para diferentes variantes con NISQA.	61
Figura 22.Comparación entre C50 y horas del dataset para diferentes variantes con DNSMOS.	61
Figura 23.Comparación entre F0-std y PESQ del dataset para diferentes variantes con DNSMOS.	62
Figura 24.Comparación entre SI-SDR de los datasets ITW y Profesional.	62
Figura 25.Comparación entre SNR de los datasets ITW y Profesional.	62
Figura 26.Comparación entre C50 de los datasets ITW y Profesional.	63

Índice de Tablas

Tabla 1.	Comparación entre diferentes etapas en una cadena de pre procesamiento para TTS.	15
Tabla 2.	Resumen de conjuntos de datos en español.	16
Tabla 3.	Tiempo y métricas de control del entrenamiento del modelo de difusión.	27
Tabla 4.	Mejora SNR por métrica de calidad y algoritmo de denoising.	30
Tabla 5.	Métricas compuestas y total para todas las configuraciones.	35
Tabla 6.	Desvío estándar y máxima desviación para cada métrica compuesta respecto a las diferentes configuraciones de cadena bajo evaluación. . . .	36
Tabla 7.	Especificaciones técnicas e hiperparámetros del entrenamiento del modelo de difusión.	39
Tabla 8.	Comparación entre métricas de estimación de densidad (Likelihood) y la métrica objetiva total (TOT), ordenado por verosimilitud.	41

RESUMEN

Pendiente: Su contenido no debe superar una página. Se indicarán los objetivos del trabajo, los métodos y resultados principales. A dos espacios debajo del resumen, en la misma página, se colocarán hasta 5 palabras clave que identifican los contenidos del trabajo.

Palabras Clave:

ABSTRACT

Ídem que para castellano.

Keywords:

1. INTRODUCCIÓN

1.1. FUNDAMENTACIÓN

Los modelos de texto a habla (TTS, por sus siglas en inglés) experimentaron un avance tecnológico exponencial en los últimos años: mediante redes neuronales profundas se alcanzaron resultados de elevada calidad sonora e inteligibilidad (Tan et al., 2021). No obstante, la fuerte dependencia de estos sistemas respecto a los datos de entrenamiento dificulta la obtención de voces sintetizadas con naturalidad para la gran diversidad de hablantes. Esta dificultad es especialmente notable en regiones con escasez de conjuntos de datos extensos, como ocurre en distintas provincias de Argentina.

En este marco, se han desarrollado sistemas de TTS en español rioplatense (Ortega Riera et al., 2023) que alcanzan resultados aceptables, pero se enfrentan a la limitada cantidad de datos específicos de los diferentes dialectos de Argentina, lo cual impide lograr sistemas más robustos y naturales. Tradicionalmente, la generación de bases de datos para entrenar modelos de TTS se orienta a recopilar grandes volúmenes de grabaciones de alta calidad (realizadas en estudios profesionales) y a emplear hablantes con características específicas (por ejemplo, locutores), lo que da lugar a un corpus homogéneo en sus características acústicas y prosódicas. Este enfoque fue significativo para la convergencia de modelos basados en aprendizaje profundo, pero representa una barrera de entrada para numerosos idiomas y variedades dialectales que no disponen de recursos para producir dichos datasets.

La literatura denomina “idiomas de bajos recursos” (low-resource languages) a estos casos; dentro de ellos se incluyen dialectos específicos de una lengua, como sería el español rioplatense o las variantes propias de determinadas provincias argentinas. Para entrenar modelos de TTS en lenguajes de bajos recursos se ha explorado la utilización de datos recolectados en Internet (Cooper, 2019), conformando conjuntos heterogéneos procedentes de diversas fuentes y de calidad de audio variable. Estos corpus suelen denominarse datos salvajes (ITW, “in-the-wild” por sus siglas en inglés). Además, con el avance de la inteligencia artificial generativa, han surgido diferentes mejoras en la arquitecturas de los sistemas de TTS mas actuales (Xie et al., 2024), lo que hace que los conjuntos de datos ITW sean una fuente especialmente atractiva para capturar la gran diversidad del fenómeno del habla.

El principal problema de entrenar modelos de TTS con conjuntos ITW es la elevada variabilidad en la calidad de las grabaciones, lo que incide directamente en la capacidad de los modelos neuronales para aprender los patrones subyacentes y, en muchos casos, impide la convergencia hacia resultados satisfactorios. Para abordar esta limitación, recientemente se han propuesto cadenas de preprocesamiento que extraen, a partir de un gran conjunto de datos, subgrupos con mejor calidad de audio (J. Yu et al., 2024). Si bien existen distintas variantes de estas cadenas en la literatura, no se ha llevado a cabo una caracterización acústica exhaustiva de la variabilidad que generan los conjuntos resultantes tras su aplicación. La validación suele basarse en el entrenamiento de modelos TTS y en la evaluación de su convergencia; sin embargo, no se suele caracterizar toda la cadena mediante parámetros acústicos que permitan comparar diferentes implementaciones bajo criterios comunes, ni definir configuraciones óptimas según objetivos distintos (por ejemplo, maximizar la calidad del audio frente a maximizar la cantidad de horas del corpus). El impacto de la calidad de los datos en el entrenamiento de modelos de TTS ha sido profundamente estudiado (Ayllón et al., 2019), pero no se han analizado las diferencias entre los dataset ITW y los dataset profesionales mediante un análisis objetivo.

La investigación propuesta en esta tesis tiene como objetivo determinar la eficacia de estas cadenas de procesamiento mediante parámetros acústicos. Este tipo de análisis no solo facilita la iteración y la optimización de los procesos de filtrado de audios de habla, sino que también abre la posibilidad de desarrollar con mayor facilidad bases de datos para lenguajes de bajos recursos, contribuyendo así a disponer de sistemas TTS de mayor calidad para una amplia variedad de idiomas y acentos locales.

1.2. OBJETIVOS

1.2.1. Objetivo general

El objetivo de la investigación es evaluar con parámetros objetivos y subjetivos, el impacto de cadenas de procesamiento de conjuntos de datos *in-the-wild* para el entrenamiento de modelos de texto a voz basados en redes neuronales profundas.

1.2.2. Objetivos específicos

Los objetivos específicos son:

- Crear un dataset *in-the-wild* en español de Argentina. Recopilar datasets de voces profesionales en español (grabaciones de alta calidad realizadas por hablantes profesionales).
- Desarrollar una cadena automática de preprocesamiento modular para la generación de conjuntos de datos de habla, y procesar el conjunto de datos ITW con la cadena bajo diferentes configuraciones operativas.
- Evaluar métricas acústicas en los distintos conjuntos de datos generados y comparar dichos resultados con los obtenidos en datasets tradicionales y determinar, según criterios acústicos, cuál de los conjuntos generados puede considerarse óptimo (comparando media y desvío de los diferentes conjuntos).
- Entrenar un modelo de estimación de distribuciones y comparar la similitud entre los diferentes conjuntos en el espacio latente. Determinar el conjunto de datos óptimo según criterios de similitud basados en estimación de densidad.
- Comparar los resultados del análisis acústico con los derivados del análisis por estimación de densidad. Analizar de forma estadística la relevancia de las diferencias observadas en los distintos parámetros.
- Validar los resultados en el contexto de clonación de voz mediante modelos TTS zero-shot.

1.3. ESTRUCTURA DE LA INVESTIGACIÓN

Esta tesis corresponde a una investigación de carácter tecnológico orientada al desarrollo y evaluación de una herramienta de software para la selección automática de audios, destinada a la generación de conjuntos de datos de habla. El objetivo principal es crear un dataset en español con los diferentes acentos de Argentina, contribuyendo al avance de las tecnologías del habla en el país y, en consecuencia, a la soberanía tecnológica nacional. El desarrollo de esta tesis se enmarca en el proyecto Archivoz del grupo de investigación Intercambios Transorgánicos, radicado en el MUNTREF.

Organización del documento:

En el capítulo 2 se presenta el marco teórico: se exponen los fundamentos de la inteligencia artificial y se describen las arquitecturas aplicables a los modelos modernos de TTS, incluyendo tanto modelos secuenciales como modelos generativos. Además, se detallan las métricas acústicas seleccionadas para la caracterización de los datos.

El capítulo 3 ofrece una recapitulación de los modelos de TTS actuales y de las cadenas de procesamiento que han surgido en los últimos años.

En el capítulo 4 se describen con detalle las etapas del desarrollo: recopilación de datos, diseño y construcción del software, metodología de comparación propuesta y el entrenamiento de modelos mediante redes neuronales.

El capítulo 5 presenta los resultados y el análisis de los experimentos descritos en la sección anterior.

Finalmente, el capítulo 6 expone las conclusiones generales de la tesis, y el capítulo 7 propone líneas de investigación futuras y posibles aplicaciones no exploradas en el presente trabajo.

2. MARCO TEÓRICO

2.1. DESCRIPTORES DE CALIDAD DE AUDIO

2.1.1. Métricas de degradación de la señal

Las métricas de degradación de la señal cuantifican, a nivel objetivo, la diferencia entre una señal de referencia (habitualmente la señal limpia o de alta calidad) y una señal procesada o degradada (por ejemplo, una señal comprimida o con ruido de fondo). A continuación se describen las más empleadas en evaluación de voz y TTS.

PESQ es un índice objetivo diseñado para predecir la calidad percibida de la voz en telefonía y sistemas de comunicación. Compara la señal de referencia y la señal degradada mediante un modelo perceptual que incluye etapas de alineamiento temporal, modelado perceptual y mapeo a una escala MOS-LQO (Mean Opinion Score — Listening Quality Objective). PESQ fue normalizado originalmente como la recomendación ITU-T P.862 (ITU-T, 2001) y se utiliza ampliamente para evaluación de códecs y transmisiones telefónicas.

Esta métrica tiene la limitación del rango de frecuencia que evalúa (va entre 200 Hz a 3500 Hz), para un análisis mas completo surge la métrica denominada POLQA, que es la tercera generación de métricas ITU para evaluación de calidad de voz end-to-end ITU-T P.863 (ITU-T, 2018). Mejora y extiende PESQ en ancho de banda (incluye super-wideband y fullband), es más robusta frente a ciertas distorsiones modernas (ecualización, delays, codificación amplia banda) y proporciona predicciones MOS más fiables en escenarios actuales.

Desde un lado objetivo de la calidad de la señal se tienen métricas como el SNR y el SI-SDR. El SNR (relación señal a ruido por sus siglas en inglés) es la relación entre la potencia de la señal útil y la potencia del ruido de fondo, normalmente expresada en decibelios (Ecuación 1). Es una medida física simple, muy útil para caracterizar condiciones de captura o transmisión, pero su correlación con la percepción humana puede ser pobre cuando las distorsiones son no-gaussianas, no-aditivas o hay alteraciones de fase y tiempo; por ello suele utilizarse junto con métricas perceptuales.

$$\text{SNR}_{\text{dB}} = 10 \log_{10} \left(\frac{P_{\text{señal}}}{P_{\text{ruido}}} \right) \quad (1)$$

El SI-SDR (relación invariante de distorsión a señal por sus siglas en inglés) es una versión modificada y más robusta del SDR tradicional diseñada para evitar penalizaciones por escalado de amplitud entre referencia y estimado (Le Roux et al., 2019). En la práctica, SI-SDR proyecta la señal estimada sobre la referencia (elimina la diferencia de escala) y calcula la relación señal/residuo resultante; por su formulación, es ampliamente usada en separación de fuentes y evaluación de redes de denoising o separación en el dominio temporal. Su definición y discusión de ventajas frente a SDR clásico están recogidas en la literatura sobre evaluación objetiva de separación.

Por último, entre las métricas de calidad de señales del habla se puede incluir el STOI (inteligibilidad objetiva de tiempo corto por sus siglas en inglés), que estima inteligibilidad de habla en condiciones ruidosas mediante una medida de correlación entre segmentos de tiempo-frecuencia de la señal limpia y la señal degradada (Taal et al., 2011). Fue propuesta para predecir la inteligibilidad de señal procesada (p. ej. filtrado espectral, separación) y ha mostrado alta correlación con experimentos de inteligibilidad humana en muchos escenarios. No mide naturalidad, sino inteligibilidad.

Por su definición, para calcular todas estas métricas se necesita tener una referencia limpia (o la señal sin ruido para SNR). En la práctica no siempre se puede tener esta señal de referencia, por eso han surgido métodos de estimación ciega de todos estos parámetros, que permiten estimar la calidad de un audio sin tener la señal de referencia.

Hay que destacar, que ninguna métrica única captura todos los aspectos perceptuales (naturalidad, inteligibilidad, artefactos, coloración). En evaluación de TTS y sistemas de procesamiento de voz es habitual combinar métricas intrusivas (PESQ/POLQA, SI-SDR, MCD) con medidas de inteligibilidad (STOI) y, cuando es posible, pruebas subjetivas (MOS).

2.1.2. Métricas de entorno

Las métricas de entorno (o de acústica de salas) describen propiedades de la sala o del campo acústico que afectan la percepción de la voz y la música.

Uno de los parámetros principales, es el tiempo de reverberación (T), que se define clásicamente como el tiempo que tarda el nivel sonoro en decaer 60 dB tras cortar la fuente (Sabine). Por razones prácticas se calculan estimadores como (T_{30}) (pendiente del

decaimiento entre -5 dB y -35 dB extrapolada a -60 dB) o (T_{20}) (entre -5 y -25 dB). El (T_{30}) es de uso corriente en caracterización objetiva de salas y está normalizado por ISO 3382 («ISO 3382-2:2008 Acoustics – Measurement of room acoustic parameters – Part 2: Reverberation time in ordinary rooms», 2008). Los valores de (T) afectan inteligibilidad, claridad y sensación de espacialidad acústica.

Otro parámetros que se usa para evaluar la percepción de audios en auditorios es la claridad (C_{50}) (para voz) y (C_{80}) (para música), ya que miden la relación energía temprana/energía tardía. Este parámetro se define matemáticamente como:

$$C_{50} = 10 \log_{10} \frac{\int_0^{50,ms} p^2(t) dt}{\int_{50,ms}^{\infty} p^2(t) dt} \quad (2)$$

donde ($p(t)$) es la respuesta al impulso en la posición de escucha. Valores altos de (C_{50}) indican mayor proporción de energía temprana (mejor inteligibilidad para voz).

El D_{50} (a menudo expresado en porcentaje) es la fracción de energía que llega en los primeros 50 ms respecto a la energía total; es otra forma de cuantificar claridad/inteligibilidad para voz (relacionado con (C_{50})). Se calcula a partir de la respuesta al impulso y es relevante para evaluación de locales docentes, salas de conferencia y condiciones de grabación.

2.1.3. Métricas del habla

Las métricas del habla describen propiedades prosódicas y espectrales de la voz que influyen en la naturalidad y en la identificación del hablante. Dentro de esta categoría, una de las métricas principales es la frecuencia fundamental de la voz (F_0), cuyo valor representa la frecuencia de vibración principal de las cuerdas vocales de los diferentes hablantes (Bäckström et al., 2022) y constituye la base de la percepción del *pitch*. Se estima mediante algoritmos de detección de pitch (autocorrelación, cepstrum, algoritmos basados en modelos probabilísticos) y se usa para análisis prosódico, control de entonación en TTS y evaluación de naturalidad. La distribución estadística de F_0 , su variación temporal (contorno), y su relación con la energía son indicadores usados tanto en evaluación objetiva como perceptual.

Otra métrica muy utilizada en el análisis de sistemas de TTS es la distorsión media

cepstral (MCD por sus siglas en ingles). MCD (a veces llamado Mel-Cepstral Distance) cuantifica la distancia entre dos secuencias de coeficientes mel-cepstrales (por ejemplo, señal natural vs. señal sintetizada) y se expresa en dB (Kominek et al., 2008). La expresión de esta métrica es la siguiente:

Se calcula comúnmente como una raíz cuadrada de la suma de cuadrados normalizada entre vectores de coeficientes y es ampliamente utilizada para evaluar la calidad espectral en TTS y vocoders; sin embargo, su correlación con la calidad percibida no es perfecta y debe complementarse con pruebas perceptuales. La métrica fue propuesta en trabajos clásicos sobre evaluación objetiva de síntesis.

2.2. TEXT-TO-SPEECH (TTS)

Los sistemas de text-to-speech (TTS) convierten texto en señal de voz (Tan et al., 2021). Históricamente pueden agruparse en tres grandes enfoques:

- Enfoque concatenativo: Ensamblan fragmentos pre grabados de voz (unidades) para formar enunciados. Ofrecen alta naturalidad cuando el corpus es homogéneo y extenso, pero presentan baja flexibilidad y alto coste de recopilación (Hunt y Black, 1996).
- Enfoque paramétrico: Modelan parámetros acústicos (por ejemplo, mediante HMM) y luego sintetizan la señal a partir de los parámetros predichos. Tienen mayor flexibilidad y requieren un menor tamaño de corpus, aunque su calidad perceptual suele ser inferior a la voz grabada (Tokuda et al., 2013).
- Enfoque neuronal: Emplean redes neuronales para mapear texto a representaciones intermedias (p. ej. mel-espectrogramas) y vocoders neuronales para generar la forma de onda. Dentro de este grupo hay variantes auto regresivas (mayor fidelidad pero más lentas) y no-autoregresivas (más rápidas y escalables). Los sistemas actuales de mayor calidad combinan un modelo de predicción de espectrogramas, como pueden ser Tacotron2 (Shen, Pang, Weiss, Schuster, Jaitly, Yang, Chen, Zhang, Wang, Skerry-Ryan et al., 2018) o FastSpeech (Ren et al., 2021a), con un vocoder neural, como pueden ser WaveNet (van den Oord et al., 2016) o HiFi-GAN (J. Kong et al., 2020).

En el presente trabajo se explora las opciones de síntesis neuronal, que han demostrado un salto cualitativo en calidad y flexibilidad, aunque requieren grandes cantidades de

datos y potencia computacional para entrenamiento. La evolución de estos sistemas de desarrolla en la Sección 3.1.

2.3. REDES NEURONALES

Las redes neuronales son modelos parametrizados por capas de neuronas artificiales que aprenden funciones complejas a partir de datos (Goodfellow et al., 2016). En TTS y procesamiento de audio se emplean arquitecturas diversas: redes convolucionales (CNN) para extracción de características tiempo-frecuencia; redes recurrentes y Transformers (Vaswani et al., 2017) para modelado secuencial; y mecanismos de *attention* en tareas seq2seq.

Las redes permiten aprender mapeos directos (texto $\rightarrow$ espectrograma) y modelos generativos (vocoder, modelos de densidad). Su flexibilidad explica el salto cualitativo en TTS, pero también la fuerte dependencia de la cantidad y calidad de los datos de entrenamiento.

2.4. INTELIGENCIA ARTIFICIAL GENERATIVA

La inteligencia artificial generativa (IAG) comprende técnicas cuyo objetivo es modelar la distribución de datos para generar muestras nuevas que sean plausibles, ya sea para imágenes, texto, o audio. La generación de estos *samples* nuevos puede ser condicionadas o no por información adicional (*prompts*). Los principales paradigmas contemporáneos son:

- Modelos autoregresivos: modelan la probabilidad conjunta como producto de condicionales (p. ej. PixelRNN en imágenes (Van Den Oord et al., 2016) o WaveNet en audio (van den Oord et al., 2016)). Son conceptualmente simples y producen alta calidad pero pueden ser lentos en inferencia por su naturaleza secuencial.
- VAE (Variational Autoencoders): modelos latentes que optimizan una cota variacional de la verosimilitud. Buen control del espacio latente y entrenamiento estable, pero a ofrecen menor fidelidad en muestras crudas (Kingma y Welling, 2013).
- GANs (Generative Adversarial Networks): enfrenta dos redes neuronales, un generador vs un discriminador que compiten en un juego adverso, generan muestras de alta fidelidad rápida y eficientemente (Goodfellow et al., 2020). Aunque el entrenamiento

puede ser inestable, se han aplicado a vocoders y síntesis auditiva (ej. HiFi-GAN por J. Kong et al., 2020).

- Modelos basados en score / difusión: incluyen los modelos de difusión y score-matching (DDPM, score-based models) que adicionan ruido progresivamente a datos reales y aprenden a invertir ese proceso para muestrear (Ho et al., 2020). Actualmente han mostrado resultados competitivos o superiores en calidad de muestras y estabilidad de entrenamiento en imagen y audio (ej. DiffWave por Z. Kong et al., 2021).

En audio/TTS, cada paradigma tiene ventajas: los autoregresivos (WaveNet) alcanzan alta naturalidad; los GANs (HiFi-GAN) ofrecen inferencia rápida y alta fidelidad; y los modelos de difusión (DiffWave) combinan calidad con mayor estabilidad y flexibilidad condicional. La elección depende de trade-offs entre calidad, velocidad y control.

2.5. MODELOS DE DIFUSIÓN

Los modelos de difusión son una clase de generadores probabilísticos basados en procesos estocásticos de adición y eliminación de ruido. Su formulación moderna se fundamenta en dos ideas principales: (1) definir un proceso directo (forward) que corrompe los datos añadiendo ruido gaussiano progresivamente hasta obtener ruido casi puro; (2) aprender el proceso inverso (reverse) —un modelo condicional que predice pasos de denoising— para transformar ruido en datos sintéticos.

La definición matemática plantea una muestra de datos x_0 , donde el proceso directo añade ruido en (T) pasos:

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t), \quad (3)$$

con una escala de varianzas (β_t) . El proceso inverso se parametriza como:

$$p_\theta(x_{t-1} | x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t)), \quad (4)$$

y se entrena minimizando una variación de la evidencia (ELBO) o una pérdida de denoising equivalente. El trabajo de Ho et al., 2020 formaliza esta familia (DDPM) y conecta la

aproximación por denoising con score-matching (Song et al., 2021).

Los modelos de difusión proporcionan calidad competitiva sin entrenamiento adversario y permiten control condicional (por ejemplo, condicionamiento en mel-espectrogramas para vocoders). La principal limitación práctica es el coste de muestreo (múltiples pasos), aunque variantes (DDIM, sampling acelerado, distillation) reducen el número de pasos sin pérdida sustancial de calidad.

3. ESTADO DEL ARTE

3.1. MODELOS DE TTS

El desarrollo de sistemas de síntesis de voz basados en redes neuronales ha experimentado una rápida evolución, transitando desde modelos secuenciales complejos hacia arquitecturas generativas probabilísticas. A continuación, se describe la progresión tecnológica de estos sistemas, clasificados según su paradigma de generación.

3.1.1. Modelos Autoregresivos

La primera generación de modelos neuronales de alta fidelidad se basó en el paradigma autoregresivo, donde la generación de cada segmentos del espectrograma de mel depende del segmento generado anteriormente.

El modelo más representativo de esta etapa es Tacotron 2 (Shen, Pang, Weiss, Schuster, Jaitly, Yang, Chen, Zhang, Wang, Skerry-Ryan et al., 2018). Esta arquitectura combina una red recurrente (LSTM) con un mecanismo de atención para mapear la secuencia de caracteres a un espectrograma de Mel, el cual es posteriormente convertido a forma de onda mediante un vocoder (originalmente WaveNet). Si bien Tacotron 2 estableció un nuevo estándar de naturalidad, su mecanismo de atención es propenso a errores de alineación, resultando en problemas de robustez como la repetición o la omisión de palabras.

Para mitigar los fallos de robustez del mecanismo de atención, surgió DurIAN (Duration Informed Attention Network) (C. Yu et al., 2020). Este modelo reemplaza el mecanismo de atención tradicional por un modelo de alineación que utiliza la duración de los fonemas (predicha o extraída mediante alineamiento forzado). Aunque DurIAN sigue generando los cuadros acústicos de manera autoregresiva, la incorporación de información explícita de duración mejora significativamente la estabilidad de la síntesis, eliminando gran parte de los artefactos presentes en Tacotron 2.

3.1.2. Modelos No Autoregresivos y Paralelos

La principal limitación de los modelos autoregresivos es su lenta velocidad de inferencia, dado que la generación no puede paralelizarse. Para resolver esto, surgieron arquitecturas capaces de generar el espectrograma completo en un solo paso.

FastSpeech 2 (Ren et al., 2021b) marcó un hito en esta categoría al proponer una red totalmente "feed-forward" basada en bloques de transformador (transformers). A diferencia de sus predecesores, FastSpeech 2 entrena predictores de varianza explícitos (duración, energía y frecuencia fundamental F_0) directamente sobre la entrada de texto. Esto no solo permite una inferencia extremadamente rápida (paralela), sino que también otorga un mayor control sobre la prosodia y una mayor robustez frente a datos ruidosos.

Posteriormente, el modelo VITS (Variational Inference with adversarial learning for end-to-end Text-to-Speech) (J. Kim et al., 2021) propuso un enfoque unificado. VITS combina flujos de normalización (Normalizing Flows) y una arquitectura de Autoencoder Variacional (VAE) con entrenamiento adversario (GAN). A diferencia de los sistemas en dos etapas (modelo acústico + vocoder), VITS es un sistema "end-to-end" que genera directamente la forma de onda, logrando una calidad de estado del arte con una naturalidad superior a los modelos de dos etapas previos.

3.1.3. Modelos basados en Difusión y Flow Matching

Con el auge de la Inteligencia Artificial Generativa, los modelos basados en difusión probabilística (DDPM) y, más recientemente, el paradigma de *Flow Matching*, han demostrado capacidades superiores para modelar la compleja distribución de la voz humana, especialmente en tareas de adaptación de hablante y *zero-shot*.

Diff-TTS (Jeong et al., 2021) fue uno de los pioneros en aplicar modelos de difusión probabilística para la estimación de espectrogramas de Mel. Este modelo formula la síntesis como un proceso de refinamiento iterativo, transformando ruido gaussiano en una señal de voz condicionada por el texto. Si bien la calidad es alta, el costo computacional de los múltiples pasos de muestreo es elevado.

Para abordar la latencia inherente a la difusión, Grad-TTS (Popov et al., 2021) intro-

dujo un marco basado en ecuaciones diferenciales estocásticas (SDE) con un alineamiento monótono estricto, permitiendo un trade-off flexible entre velocidad y calidad. En la misma línea de optimización, ProDiff (Huang et al., 2022) emplea técnicas de destilación progresiva (progressive distillation) para reducir drásticamente el número de pasos de muestreo requeridos, permitiendo síntesis de alta calidad en tan solo 2 o 4 pasos de difusión.

Finalmente, el estado del arte actual ha convergido hacia el paradigma de *Flow Matching*, una generalización de los modelos de difusión que aprende campos vectoriales para transformar distribuciones simples en distribuciones de datos complejas mediante trayectorias más rectas y eficientes. El modelo F5-TTS (Chen et al., 2024) representa la culminación actual de esta tendencia. F5-TTS utiliza una arquitectura basada en *Diffusion Transformers* (DiT) con un esquema de entrenamiento *Flow Matching*. A diferencia de los modelos anteriores que requieren alineamientos complejos o predictores de duración explícitos, F5-TTS entrena con un sistema de máscaras binarias (bloquea segmentos aleatorios del audio y deja que el modelo aprenda a predecir ese segmento), permitiendo capacidades de clonación de voz *zero-shot* y control de emociones con una naturalidad sin precedentes y una velocidad de inferencia competitiva gracias a la eficiencia del Flow Matching.

3.2. CADENAS DE PRE PROCESAMIENTO

En los últimos años se han desarrollado numerosas cadenas de procesamiento, todas con diferentes configuraciones y particularidades. El objetivo de estas cadenas de preprocesamiento es mejorar, filtrar y estandarizar un conjunto de datos de audios grandes proveniente de diferentes fuentes (dataset ITW). Como el procesamiento implica diferentes etapas, y varía según las necesidades de los modelos a entrenar, han surgido muchas propuestas de implementación, todas con sus respectivas particularidades. Para ilustrar las diferencias en las diferentes etapas se conforma la Tabla 1, donde se comparan diferencias de modelos, configuraciones y criterios en el desarrollo de cadena de pre procesamiento automático para la creación de datasets.

Las diferencias entre las etapas planteadas en esta Tabla se explican en la Sección 4.2, donde se explica las particularidades de la implementación propia de la cadena de procesamiento. La gran discrepancia entre modelos de las diferentes implementaciones es una de las motivaciones para el desarrollo de esta tesis, con el objetivo que esclarecer el desarrollo

Tabla 1. Comparación entre diferentes etapas en una cadena de pre procesamiento para TTS.

Nombre del estudio	Algoritmo de Denoising	Voice Activity Detection	Estimador MOS y umbral	Sistema TTS evaluados
AutoPrep - (J. Yu et al., 2024)	BSRRN	TDNN	DNS MOS: 2.4	DurlAN TTS
Text-to-Speech in the wild - (Jung et al., 2025)	Demucs	Whisper X Pipeline	Nisqa: 3	GradTTS y VITS
WeNeetSpeech - (Ma et al., 2024)	MBTFNet	Rezamblyzer	DNS MOS: 3.6, 3.8, 4	VALL-E y NS2
SCEP - (Sabra et al., 2024)	U-Net	Casual DNN	Usan SNR y PESQ	No evalúa
Muyan TTS - (Li et al., 2024)	FRCRN y VoiceFixer	No usa	Nisqa: 3.8	FireRedTTS y CozyVoice2
Emilia - (He et al., 2024)	UVR-MDX-N et Inst	Silero VAD	DNS MOS: 3	VoiceBox

de este tipo de procesamientos en el desarrollo de conjuntos de datos.

3.3. CONJUNTOS DE DATOS DEL HABLA EN ESPAÑOL

Es relevante mencionar la falta de conjuntos de datos del habla en español, en principal de la variante español de Argentina. En la Tabla 2 se recopilaron diferentes conjuntos de datos de habla en español, especificando la cantidad de horas y hablante, la región que lingüística que representa y el tipo. Los diferentes tipos hacen referencia a la fuente de donde fueron recopilados los datos. Además de los conjuntos profesionales e *in-the-wild* que ya fueron discutidos, se presentan dataset de tipo conversacional (de entrevistas o llamadas telefónicas) y los dataset *crowdsourced*, donde se recopilan audios de voces de voluntarios a través de internet.

Este análisis de los dataset en el estado del arte pone en evidencia la necesidad de conformar un corpus del español de Argentina, donde es fundamental extender la representatividad cultural de nuestra región, y capturar los diferentes acentos de todas las regiones del país, ya que como se ve en la recopilación, casi todo el material disponible del dialecto de Argentina se centra en la región porteña. Los dataset calificados como dialecto diverso es porque en su confección no delimitaron entre los diferentes dialectos del español, y agruparon todo en una misma categoría, lo que incluya español de las diferentes regiones de latinoamerica y de españa.

Tabla 2. Resumen de conjuntos de datos en español.

Nombre dataset	Cantidad horas	Cantidad hablantes	Región dialecto	Tipo dataset
Google LREC - Guevara-Rukoz et al., 2020	8	44	Buenos Aires	Profesional
Emilia - Torres et al., 2019	4	1	Buenos Aires	Profesional
HaCASpa - Gabriel, 2011	10	50	Buenos Aires/Mendoza	Conversacional
CORdEBA - UNLP, 2014	6	25	Buenos Aires	Conversacional
Common Voice - Ardila et al., 2020	587	260	Diversas	Crowdsourced
YODAS - Li et al., 2023	50k	N/A	Diversas	In-the-wild
CML TTS - Oliveira et al., 2023	400	115	España	Profesional
MLS - Pratap et al., 2020	1.5k	120	España	Profesional
VoxPopuli - Wang et al., 2021	166	305	España	Conversacional
Tedx Spanish - Hernandez-Mena, 2019	24	N/A	México	Espontáneo

4. DESARROLLO

4.1. RECOPIACIÓN DE BASES DE DATOS

4.1.1. Datos *in-the-wild*

Para evaluar las cadenas de procesamiento sobre conjuntos de datos de habla se emplea el corpus en español de Argentina recopilado por el grupo de investigación Intercambios Transorgánicos. Este corpus consta de 24 horas de grabaciones realizadas en condiciones heterogéneas, tanto en calidad de audio como en diversidad de hablantes, y proviene mayoritariamente de fuentes públicas en internet. Por su variabilidad y carácter no controlado, este conjunto *in-the-wild* resulta idóneo para validar procedimientos de preprocesado de audio. En lo sucesivo, se hará referencia a esta colección como el conjunto de datos *original* (versión sin procesamientos).

Con el objetivo de captar diferencias dialectales relevantes para Argentina, la selección de hablantes sigue la clasificación regional propuesta por (de Weinberg y de Mirande, 2004). En concreto, el corpus incluye 32 hablantes con acento bonaerense y 27 con acento centro, para un total de 59 hablantes. La estrategia a futuro consiste en ampliar la cobertura dialectal para incorporar todas las variedades representativas del país; sin embargo, en esta tesis se valida inicialmente la cadena de preprocesamiento sobre estas dos variantes

representativas.

4.1.2. Datos profesionales

Para complementar el corpus *in-the-wild* y disponer de material de mayor calidad contra el cual contrastar el análisis objetivo, se incorporan conjuntos de datos profesionales disponibles en trabajos previos. Dado que no existe una colección pública extensa exclusivamente de español de Argentina, se incluyen también recursos con variantes dialectales cercanas cuando procede.

- ELRA Dataset (Guevara-Rukoz et al., 2020): aproximadamente 8 horas de audio con dialecto bonaerense, 44 hablantes.
- CML Dataset (Oliveira et al., 2023): subset de 8 horas de audio con dialecto en español de España, 15 hablantes.
- HaCASpa Dataset (Gabriel, 2011): aproximadamente 10 horas de audio con dialecto de mendoza, 50 hablantes.

El conjunto profesional suma un total de 26 horas y 109 hablantes, con una distribución de acentos que refleja la diversidad regional. Este material se utiliza como referencia para evaluar la calidad acústica y las condiciones de grabación alcanzables mediante la cadena de preprocesamiento aplicada al corpus *in-the-wild*.

4.2. DESARROLLO DE LA CADENA DE PRE PROCESAMIENTO

La cadena de preprocesamiento diseñada en esta Tesis es una secuencia modular y reproducible de etapas destinadas a transformar material *in-the-wild* en subconjuntos utilizables para entrenamiento de TTS. Las etapas principales son las siguientes:

1. Post-procesado y metadatos: Normalización de niveles, etiquetado de metadatos (origen, duración, dialecto, condiciones de captura) y generación de los subconjuntos finales para evaluación y para alimentación a modelos TTS.
2. Voice Activity Detection (VAD): Eliminación de segmentos sin voz y segmentación inicial en enunciados. En la implementación se usa Silero VAD (Team, 2024) con una es-

trategia adaptativa de optimización de hiperparámetros basada en clasificar el ritmo de habla (lento/normal/rápido) mediante los timestamps de Whisper y optimizar los parámetros del VAD por categoría. Además, se controla la longitud final de las unidades (concatenación / recorte) para ajustarlas a la distribución requerida por modelos TTS downstream.

3. Denoising / Speech enhancement: Aplicación opcional de la cadena para mitigar ruido y artefactos de grabación. Se evalúan modelos prácticos y eficientes en CPU, además de la opción sin denoising, considerando el balance entre mejora perceptual y preservación de la identidad vocal. Los modelos seleccionados son Demucs (Défossez et al., 2020) y DeepFilterNet (Schroter et al., 2022).
4. Filtrado de calidad no intrusivo: Evaluación y filtrado mediante modelos de calidad perceptual no intrusiva para aceptar o rechazar fragmentos según puntuación mínima. Se utiliza modelos predictivos de MOS (Mean-Opinion-Score) como métrica conjunta de calidad. Se evalúan los modelos NISQA (Mittag et al., 2021) y DNS MOS (Reddy et al., 2021).
5. Transcripción (STT): Obtención de transcripciones automáticas necesario para obtener los pares texto-audio que se requieren para el entrenamiento; en esta etapa se prioriza la precisión a costa de un mayor tiempo de cómputo, dado el impacto de errores de transcripción en la calidad final del corpus. Se utiliza el modelo de Whisper Large para la transcripción (Radford et al., 2023).

La implementación enfatiza portabilidad y bajo costo computacional, de modo que grupos con recursos limitados puedan reproducir la cadena y comparar variantes de configuración sin necesidad de utilizar hardware de alto rendimiento como serían GPUs. El diagrama de flujo de toda la cadena propuesta se presenta en la Figura 1.

4.2.1. Diferentes configuraciones

Para evaluar el impacto de decisiones de diseño en la confección de cadenas de pre procesamiento, se proponen las siguientes variantes:

- Condiciones de denoising: DeepFilterNet (DFN), Demucs, y *no-denoising*. Estas alternativas representan puntos intermedios entre eficiencia, mejora perceptual y preser-




Figura 1. Diagrama de flujo del proceso completo para generar el dataset.

vacación de timbre.

- Modelos de calidad no intrusiva: NISQA y DNSMOS, seleccionados por su uso extendido y su diferente sensibilidad a condiciones de ruido. Estos modelos son los mas usados en la literatura, donde se utiliza uno u el otro pero no se han contrastado para determinar el modelo mas optimo.
- Umbrales de filtrado: Para NISQA se evaluaron (3.0, 3.5, 3.8, 4.2) y para DNSMOS (2.7, 3.0, 3.2, 3.4). Los umbrales se eligieron de forma empírica analizando el nivel predicho de MOS para todo el conjunto de datos original.

La selección de umbrales parte de un análisis empírico presentado en la Figura 2, donde se calcula el valor de MOS resultante de NISQA y DNS MOS para todos los segmentos del dataset original. Es interesante notar como DNS MOS presenta un valor medio inferior y menos varianza. En consecuencia, para hacer una comparación justa, se seleccionaron los umbrales para garantizar un filtrado equitativo para los dos modelos.

En la Figura 3 se presentan de manera gráfica las diferentes variantes a analizar. Ca-




Figura 2. Resultado de MOS por cantidad de segmentos del dataset original para los 2 modelos a comparar.

da configuración genera un subconjunto procesado sobre el que se calculan las métricas objetivas (ver sección siguiente) para permitir una comparación reproducible y dirigida por métrica sin necesidad de entrenar modelos TTS para cada variante. A estas variantes de procesamiento se las denomina sub dataset.




Figura 3. Variantes propuestas para evaluar diferentes configuración de la cadena de procesamientos.

No se contemplaron variaciones en el orden de las etapas de la cadena por una limitación de los algoritmos de denoising utilizados. Sería interesante evaluar el rendimiento de la cadena si el primer proceso aplicado es el denoising en vez del VAD, pero la implementación de Demucs no soporta audios de gran duración (por problemas de saturación de memoria). De la misma forma, los algoritmos de estimación de calidad de audio, trabajan

con segmentos cortos, antes estas limitaciones, se mantiene siempre el orden establecido, donde el VAD segmenta audios de larga duración para que puedan ser procesados por las etapas siguientes sin problemas de saturación de memoria.

4.3. EVALUACIÓN DE LOS CONJUNTOS DE DATOS

La evaluación se articula alrededor de cuatro bloques de métricas complementarias que capturan cantidad, calidad de señal, condiciones acústicas y preservación de características del hablante. Estas métricas se combinan en una métrica compuesta que permite ordenar y seleccionar la mejor configuración según criterios definidos en la Sección 4.3.5.

Todas las métricas buscan cuantificar diferencias relativas entre el dataset original y los sub datasets resultantes de las diferentes variantes; de esta forma, se pueden aplicar esta misma metodología de procesamiento para caracterizar el funcionamiento de la cadena de procesamientos, independientemente de las características del conjunto de datos de partida.

4.3.1. Reducción del corpus

El tamaño del dataset se mide en duración total (horas) y la *reducción de datos* (RD) se cuantifica según Ecuación 5, donde el subíndice P hace referencia a las diferentes variantes del dataset procesado, y el subíndice O hace referencia a la cantidad de horas del dataset original.

$$RD_P = 1 - \frac{HORAS_P}{HORAS_O} \quad (5)$$

Un valor de RD más pequeño es preferible (menos pérdida de datos). Esta medida captura el trade-off básico entre condiciones del filtrado agresivas y cantidad de material utilizable.

4.3.2. Calidad de la grabación

La evaluación de la calidad de la grabación tiene por objetivo cuantificar, de forma objetiva y reproducible, las mejoras perceptuales y la fidelidad de la señal obtenidas tras aplicar las distintas etapas de la cadena (por ejemplo, denoising y filtrado). Para ello se emplean medidas complementarias: PESQ, SI-SDR y SNR; en un principio se contempla la posibilidad de utilizar también el STOI como un parámetro para cuantificar inteligibilidad, pero empíricamente no se encontraron diferencias significativas de este valor, con lo cual fue descartado.

PESQ (Perceptual Evaluation of Speech Quality) se utiliza como un indicador aproximado de la calidad subjetiva de la señal comparando la versión procesada con la referencia original; SI-SDR (Scale-Invariant Signal-to-Distortion Ratio) mide la fidelidad de la señal de forma robusta frente a cambios de escala y permite evaluar cuánto contenido de la señal original se preserva tras el procesamiento; la definición teórica para calcular estos parámetros requiere de tener una versión original de la señal y una versión degradada, como en este caso se quiere comparar ambos dataset de forma independiente, se utiliza el modulo Pytorch Squim (Kumar et al., 2023), que permite predecir los valores de PESQ, SI-SDR de forma no intrusiva (estimación ciega).

El SNR se estima mediante WADA-SNR (C. Kim y Stern, 2008) para obtener una cifra robusta de relación señal-ruido basada en la distribución de la amplitud de la onda. Todas estas métricas se computan a nivel de segmento y luego se resumen mediante la media y la desviación estándar para cada subconjunto, de modo que sea posible comparar distribuciones antes y después del procesamiento. Finalmente, las puntuaciones individuales se integran en el bloque *Calidad señal* (CS) donde se suma la influencia de todos estos valores Ecuación 6, teniendo en cuenta que se espera que los valores de PESQ, SI-SDR y SNR suban (mejoría) al aplicar la cadena de procesamientos. Los subíndices respetan la condiciones anterior donde P es por procesado y O es original, estos subíndices se mantiene consistentes para todas las métricas.

$$CS_P = \frac{PESQ_O}{PESQ_P} + \frac{SI-SDR_O}{SI-SDR_P} + \frac{SNR_O}{SNR_P} \quad (6)$$

4.3.3. Condiciones acústicas

Las métricas acústicas buscan describir las condiciones de sala y la presencia de reverberación o de energía tardía en las grabaciones, aspectos que afectan la utilidad de los audios para entrenamiento de TTS, especialmente la alineación temporal entre texto y mel-spectrograma. En este trabajo se emplean descriptores clásicos como T_{30} (tiempo de reverberación aproximado) y medidas de claridad como C_{50} y D_{50} , que resumen la proporción de energía inicial frente a la energía reverberada y permiten detectar grabaciones con exceso de reverberación o mala claridad.

Nuevamente, es necesario calcular estos parámetros de forma ciega y sin referencia de las condiciones del entorno original, con estas limitaciones, estas métricas se estiman mediante un modelo CNN que fue entrenado para calcular parámetros acústicos de forma ciega, y fue validado para voces del español argentino, de manera que la estimación sea práctica sobre material *in-the-wild* sin requerir respuestas impulsivas de sala (Ortiz, 2023). Las mediciones se calculan por segmento y se agregan mediante estadísticos (media y desvío) para cada subconjunto; en la métrica compuesta se incorporan las mejores relativas para evaluar si una configuración reduce la reverberación y mejora la claridad respecto del conjunto original.

En este caso, estas dos métricas se suman para contabilizar la influencia de las *Condiciones acústicas* (CA) en la Ecuación 7, donde el T_{30} mejora si disminuye, pero el C_{50} mejora si se incrementa. Se descarta el D_{50} ya que los resultados empíricos fueron muy similares al análisis del C_{50} , con lo cual no se estaría agregando información redundante y se decide en consecuencia eliminar el aporte de esta métrica. El análisis de estas variables permite discriminar configuraciones que mejoran la «condición de sala» del corpus sin sacrificar en exceso otros atributos.

$$CA_P = \frac{T_{30,P}}{T_{30,O}} + \frac{C_{50,O}}{C_{50,P}} \quad (7)$$

4.3.4. Diferencias del habla

Las medidas de diferencias del habla están pensadas para garantizar que las etapas de preprocesamiento, en particular los algoritmos de denoising, no alteren indebidamente la identidad del hablante ni la variabilidad prosódica del corpus, aspectos críticos para síntesis con preservación de timbre y estilo. En la tesis se consideran dos indicadores principales: la desviación estándar del F0 (F0-STD) y la distorsión mel-cepstral media (MCD).

El F0-STD captura la variabilidad prosódica de los hablantes; su cálculo se realiza a nivel de segmento usando el estimador PESTO (Riou et al., 2023) para extracción robusta de pitch, y se compara entre versión original y procesada para detectar reducciones anómalas de variabilidad que indiquen pérdida de naturalidad o sesgo en la selección de hablantes. El MCD se calcula entre los coeficientes mel-cepstrales de la señal original y de la señal procesada (especialmente relevante en audios sometidos a denoising) para cuantificar cambios tímbricos (Kominek et al., 2008); en la formulación adoptada el MCD se expresa como incremento porcentual o normalizada respecto a un valor de referencia aceptable de 5 dB según (Xie et al., 2024), de esta forma se penalizan las configuraciones que alteran significativamente el timbre.

Estas dos componentes se combinan en el bloque *Diferencias del habla* (DH), donde cualquier diferencia relativa de F0-STD es penalizada, y lo mismo para el MCD respecto al valor de referencia Ecuación 8. Cabe aclarar que el MCD solo se calcula para las variantes con denoising, esto favorece de alguna forma a las variantes sin denoising que no modifican las características del hablante.

$$DH_P = \left| 1 - \frac{F0std_P}{F0std_O} \right| + \frac{MCD_P}{5} \quad (8)$$

4.3.5. Métrica conjunta

Para ordenar configuraciones se propone una métrica compuesta que suma los cuatro bloques anteriores: reducción del dataset (RD), calidad de señal (CS), condiciones acústicas (CA) y diferencias de habla (DH). Esta métrica compuesta, plantea de forma matemática las relaciones de compromiso que se asumen con la cadena de procesamientos.

Se plantea la métrica compuesta como un objetivo de optimización Ecuación 9, donde se busca minimizar el aporte negativo de cada variable para poder identificar la mejor variante P de la cadena de procesamientos.

$$\min_{P \in \text{Conf}} \left\{ RD_P + CS_P + CA_P + DH_P \right\} \quad (9)$$

Con esta formulación, configuraciones que mantienen mayor cantidad de horas, mejoran la calidad de señal, mejoran (o mantienen) condiciones acústicas y preservan características del hablante obtendrán puntuaciones más bajas (mejor). Se propone una configuración inicial donde todos los bloques tienen el mismo peso; la elección de pesos distintos permite priorizar, por ejemplo, la preservación vocal frente a la cantidad de horas si el objetivo es síntesis con alta fidelidad identitaria.

4.4. ENTRENAMIENTO DEL MODELO DE ESTIMACIÓN DE DENSIDAD

Si bien la evaluación mediante métricas acústicas tradicionales (Sección 4.3) ofrece una aproximación robusta e interpretable para caracterizar los conjuntos de datos, este análisis presenta limitaciones inherentes al restringir la evaluación a un conjunto discreto de características diseñadas manualmente. Estas métricas, aunque útiles, pueden introducir sesgos al no capturar la totalidad de las dependencias complejas y de alta dimensión presentes en la señal de audio y del problema en sí.

Para mitigar estas limitaciones y proporcionar una perspectiva complementaria, se propone un método de evaluación basado en el aprendizaje de representaciones, utilizando un modelo de estimación de densidad. El objetivo fundamental de estos modelos es aprender la distribución de probabilidad intrínseca $p_{data}(x)$ de un conjunto de datos de entrenamiento, obteniendo una aproximación de la función de densidad de probabilidad (PDF) subyacente. La principal ventaja de este enfoque *data-driven* radica en su naturaleza no supervisada: el modelo extrae patrones latentes y características comunes de la distribución de referencia sin depender de etiquetas explícitas o de la selección arbitraria de parámetros acústicos, reduciendo así la intervención humana exclusivamente a la curaduría del conjunto de entrenamiento.

En el contexto de esta tesis, se adopta la arquitectura y metodología propuestas por

de Oliveira et al., 2025, quienes utilizan modelos generativos basados en difusión probabilística para modelar la distribución del habla. Su investigación demuestra que, al utilizar audios de alta fidelidad como referencia para aprender la distribución base, el modelo es capaz de estimar la calidad de muestras fuera del conjunto de entrenamiento mediante la evaluación de su verosimilitud. Los resultados reportados indican que este enfoque presenta una correlación con la calidad perceptual superior a métricas tradicionales como PESQ o SNR, y una mayor alineación con la preferencia subjetiva humana en comparación con el MOS predicho.

La implementación propuesta en este trabajo utiliza el mismo principio de aprendizaje no supervisado, empleando el conjunto de datos profesionales (descrito en la Sección 4.1.2) para entrenar el modelo. De esta forma, se establece una distribución de referencia que representa el "habla de alta calidad en español". Una vez entrenado, el modelo permite calcular la verosimilitud de los audios pertenecientes a los distintos sub-datasets generados por la cadena de procesamiento. Bajo la hipótesis de que una mayor verosimilitud indica una mayor cercanía a la distribución de calidad profesional, este método permite ordenar las diferentes variantes de la cadena de procesamiento según su similitud acústica y estadística con el corpus profesional, determinando así qué configuración logra preservar mejor las características deseables de la señal.

4.4.1. Configuración del modelo e hiperparámetros

El entrenamiento del modelo de estimación de densidad se realizó utilizando un entorno de computación de alto rendimiento, centrado en una GPU NVIDIA GeForce RTX 5090 con 32 GB de memoria de video (VRAM). Este recurso fue fundamental para gestionar la carga computacional requerida por los modelos de difusión de alta fidelidad, permitiendo un consumo de potencia de aproximadamente 532W durante los picos de entrenamiento. Queremos expresar nuestro agradecimiento al [**Nombre de la institución o laboratorio**] por facilitar el acceso a este equipamiento de última generación.

La arquitectura del modelo de (de Oliveira et al., 2025) se basa en el framework EDM2 (Elucidating the Design Space of Diffusion-Based Generative Models), configurada para operar con audios a una tasa de muestreo de 16 kHz. A diferencia de los modelos de difusión discretos tradicionales, se empleó un esquema de ruido continuo, optimizando el entrena-

miento mediante la minimización de la función de pérdida de score-matching. Los hiperparámetros específicos utilizados se detallan en la Tabla 3.

Tabla 3. Tiempo y métricas de control del entrenamiento del modelo de difusión.

Parámetro / Recurso	Valor / Descripción
Arquitectura del modelo	EDM2-Diffusion (Tiempo continuo)
Unidad de Procesamiento Gráfico (GPU)	NVIDIA GeForce RTX 5090
Memoria de video (VRAM)	32 GB GDDR7
Entorno de software	PyTorch 2.6 / CUDA 13.1
Tamaño de lote (<i>Batch size</i>)	16 muestras por GPU
Precisión de cálculo	Punto flotante de 16 bits (fp16)
Tasa de aprendizaje máxima (α_{ref})	$1,09 \times 10^{-2}$

4.5. MODELO DE TTS ZERO-SHOT

La validación exhaustiva de una cadena de curaduría de datos requeriría, en un escenario ideal, el entrenamiento completo de un modelo de síntesis para cada uno de los subconjuntos de datos generados. Sin embargo, debido a las restricciones de cómputo y a los tiempos de convergencia asociados al entrenamiento de múltiples modelos neuronales, esta aproximación resulta inviable en los contextos de esta investigación. Además, de las limitaciones estructurales, este método tendría sus propias limitaciones metodológicas, dado que la variabilidad inherente al proceso de entrenamiento de modelos de síntesis podría introducir ruido en la evaluación, dificultando la atribución de diferencias en la calidad de síntesis exclusivamente a las características del conjunto de datos utilizado.

Ante esta limitación, se propone una estrategia alternativa basada en la clonación de voz mediante modelos de TTS *zero-shot*. La hipótesis metodológica subyacente postula que existe una correlación directa entre la calidad acústica de la muestra de referencia (el audio proveniente de la cadena de procesamiento) y la calidad perceptual de la voz sintetizada. Se tomaron solo 200 muestras de cada configuración, para garantizar que la evaluación sea representativa y estadísticamente significativa, sin incurrir en un costo computacional prohibitivo, aunque se reconoce que un mayor número de muestras podría ofrecer una visión más completa de la variabilidad de la síntesis.

Para la ejecución de este experimento, se seleccionaron dos modelos representativos del estado del arte en síntesis *zero-shot*, fundamentados en paradigmas generativos dia-

metralmente opuestos. En primer lugar, se utilizó el modelo F5-TTS Chen et al., 2024. Esta elección se fundamenta en tres características críticas para la investigación:

1. Capacidad de clonación con referencias cortas: El modelo ha demostrado un rendimiento robusto utilizando muestras de referencia de muy corta duración (inferiores a 30 segundos). Esta característica es indispensable, dado que las configuraciones más estrictas de la cadena de procesamiento (e.g., umbrales altos de NISQA) pueden resultar en subconjuntos de datos con una disponibilidad limitada de segmentos continuos.
2. Coherencia Arquitectónica: F5-TTS se basa en el paradigma de *Flow Matching*, una generalización de los modelos de difusión. Esto alinea la arquitectura del modelo de síntesis con la del modelo de estimación de densidad utilizado para la evaluación (Sección 4.4), manteniendo una consistencia metodológica en el uso de modelos generativos modernos.
3. Disponibilidad y Reproducibilidad: Al ser un modelo de código abierto (*open source*), garantiza la reproducibilidad de los resultados y permite la inspección de su funcionamiento interno.

Para contrastar y enriquecer este análisis, se incorporó un segundo sintetizador: Qwen TTS (Hue et al., 2026). La selección de esta segunda arquitectura, basada en Modelos de Lenguaje Grande (LLMs), introduce un contrapeso metodológico fundamental:

1. Contraste Arquitectónico (Espacio Discreto vs. Continuo): A diferencia de la naturaleza continua de F5-TTS, los modelos basados en LLMs operan sobre representaciones discretizadas del audio generadas mediante *codecs* neuronales (*tokens* acústicos). Esto permite evaluar cómo reacciona un modelo de naturaleza autoregresiva frente a los mismos datos de referencia.
2. Resiliencia a Artefactos y Filtrado Intrínseco: El proceso de discretización de los *codecs* neuronales actúa como un filtro de normalización intrínseco, otorgando al modelo una mayor resiliencia computacional frente a ruidos residuales o distorsiones leves de fase. Su inclusión permite determinar si el impacto destructivo o beneficioso del preprocesamiento afecta de manera uniforme a todos los sintetizadores, o si depende intrínsecamente de su arquitectura subyacente.

El protocolo experimental consiste en utilizar audios representativos de los diferentes sub-datasets (seleccionados tanto por métricas objetivas como por estimación de densidad) como entradas de referencias para el sistema F5-TTS. Para garantizar que la evaluación no esté sesgada por el contenido lingüístico, las oraciones a sintetizar se extraen del corpus “*Los Sentidos*” Gurlekian et al., 2021. Este texto ha sido seleccionado específicamente por su diseño para cubrir la diversidad fonética y alofónica característica del español de Argentina.

Finalmente, para cuantificar la calidad de las síntesis resultantes y cerrar el ciclo de evaluación, se emplea un predictor de MOS (*Mean Opinion Score*) entrenado específicamente para evaluar sistemas de TTS en idioma español Sosa Welford y Pepino, 2025, lo que permite obtener una métrica de calidad perceptual automatizada y consistente.

Es fundamental remarcar que los resultados de este último experimento presenta un carácter preliminar y exploratorio. La predicción de la percepción subjetiva de calidad (MOS del TTS) está sujeta a múltiples factores inherentes a los propios modelos sintetizadores (como su entrenamiento previo, su capacidad de adaptación al locutor y la complejidad del texto objetivo). Por tanto, si bien este análisis revela tendencias de suma importancia, se requiere de futuras evaluaciones con metodologías estandarizadas de pruebas de escucha humana y validación cruzada para establecer conclusiones categóricas.

5. RESULTADOS Y ANÁLISIS

5.1. RESULTADOS DE LAS DIFERENTES VARIANTES DE LA CADENA

5.1.1. Ejemplo de cálculo

Se calcula el promedio de cada métrica para las diferentes configuraciones propuestas, y se calcula la mejora porcentual. Por ejemplo, para el SNR, el valor promedio calculado en el dataset original es de 19.08 dB. Al analizar el SNR para todas las variantes, se encuentra que el valor mas bajo de SNR es de 19.89 dB, mientras que el valor mas alto es de 33.78 dB. Los resultados ordenados según el porcentaje de mejora se puede ver en Tabla 4.

Tabla 4. Mejora SNR por métrica de calidad y algoritmo de denoising.

Filtro de calidad y umbral	Algoritmo de denoising	Mejora SNR (%)
NISQA = 3	Sin denoising	4.07
NISQA = 3.5	Sin denoising	4.93
DNSMOS = 2.7	Sin denoising	6.93
DNSMOS = 3.4	Sin denoising	7.56
DNSMOS = 3.0	Sin denoising	9.92
DNSMOS = 3.2	Sin denoising	10.00
NISQA = 3.8	DeepFilterNet	10.13
NISQA = 4.2	Sin denoising	11.67
DNSMOS = 3.4	DeepFilterNet	12.52
NISQA = 3.5	DeepFilterNet	14.78
NISQA = 3.8	Sin denoising	15.58
DNSMOS = 3.2	DeepFilterNet	15.65
NISQA = 3.0	DeepFilterNet	15.72
NISQA = 4.2	DeepFilterNet	17.55
DNSMOS = 3.0	DeepFilterNet	17.86
DNSMOS = 2.7	DeepFilterNet	18.84
DNSMOS = 3.4	Demucs	39.66
NISQA = 4.2	Demucs	40.34
NISQA = 3.8	Demucs	40.54
NISQA = 3.5	Demucs	41.24
DNSMOS = 3.2	Demucs	41.78
NISQA = 3.0	Demucs	42.16
DNSMOS = 3.0	Demucs	43.25
DNSMOS = 2.7	Demucs	43.52

Este análisis es el que se pondera para cada variable en las 4 categorías de métricas propuestas.

5.1.2. Métricas separadas

En una instancia exploratoria previa a la definición de la métrica conjunta, se exploran los resultados del dataset de prueba ante las diferentes métricas propuestas.

Primero se compara la relación entre calidad de audio y cantidad de horas del dataset. La Figura 4 muestra, en el eje horizontal, el porcentaje de reducción del dataset producido por el filtrado (más a la derecha significa pérdida de más horas) y, en el eje vertical, el incremento relativo de la puntuación PESQ expresado en porcentaje. Sobre la misma gráfica se comparan las tres variantes de la etapa de realce consideradas: DeepFilterNet, Demucs y la condición sin denoise. El comportamiento observado evidencia un trade-off claro entre cantidad y calidad: umbrales de filtrado más estrictos producen mejoras mayores en PESQ pero sacrifican un mayor número de horas de grabación. En concreto, las variantes con denoising aportan ganancias moderadas en PESQ (típicamente inferiores al 8 % según el umbral), mientras que la variante sin realce logra aumentos mayores en PESQ (superiores al 10 %) a costa de una reducción de dataset mucho más agresiva. Entre los métodos de realce usados, Demucs tiende a ofrecer las mayores mejoras de PESQ a lo largo de los umbrales evaluados, y DeepFilterNet presenta ganancias más pequeñas para filtros equivalentes; esta diferencia implica que la elección del algoritmo de realce y del umbral de NISQA debe hacerse en función del balance deseado entre calidad perceptual y preservación de horas útiles.




Figura 4. Comparación entre PESQ y cantidad de horas de diferentes variantes con NISQA.

En la Figura 5 se relaciona la reducción porcentual de horas con la mejora relativa en T_{30} (tiempo de reverberación estimado) cuando se emplea DNSMOS como métrica de filtrado. En la gráfica, un aumento en la mejora de T_{30} implica una reducción de la energía tardía y, por ende, una menor reverberación aparente en los segmentos retenidos. Los

resultados muestran que el filtrado aporta ganancias en condiciones sin denoise de forma especialmente notable, cuando no se aplica realce previo el filtrado selecciona segmentos con menor reverberación y la mejora en T_{30} es sustancial. En cambio, una vez aplicada la supresión de ruido, las ganancias en T_{30} son más moderadas (por debajo aproximadamente del 5 % en los umbrales considerados). Además, no se detecta una diferencia significativa en T_{30} entre DeepFilterNet y Demucs. En conjunto, la figura subraya que el filtrado basado en DNSMOS puede reducir la reverberación del subconjunto resultante, pero el beneficio marginal depende fuertemente de si previamente se aplicó un algoritmo de realce y de la agresividad del umbral.




Figura 5. Comparación entre T_{30} y cantidad de horas de diferentes variantes con DNS MOS.

Además, de comparar la cantidad de horas, también se pueden relacionar otras variables, como puede ser la desviación de frecuencia fundamental $F0-STD$ y la mejoría de calidad cuantificada por PESQ Figura 6. En este análisis se ilustra la relación entre la mejora relativa de PESQ (eje horizontal) y la diferencia porcentual en la desviación estándar de $F0$ ($F0-STD$, eje vertical) para las variantes evaluadas con DNSMOS. Esta representación revela un efecto colateral relevante: a medida que aumenta la mejora perceptual (PESQ) por filtrado más estricto, suele observarse una reducción de la variabilidad prosódica medida por $F0-STD$. La explicación práctica es que el filtrado agresivo tiende a eliminar segmentos y hablantes de peor calidad, lo cual reduce la heterogeneidad prosódica del subconjunto retenido. No obstante, los métodos de realce que mejor preservan el timbre de voz muestran cambios menores en $F0-STD$ ante el mismo grado de filtrado, lo que indica que ciertos denoisers permiten mejorar la calidad percibida sin sacrificar tanto la variabilidad prosódica. En la práctica, la figura pone de manifiesto el compromiso entre mejorar la calidad objetiva del audio y mantener la diversidad de patrones de entonación: selección excesiva orientada

únicamente a PESQ puede empobrecer la variabilidad del corpus, con posible impacto en tareas de síntesis que requieran conservar rasgos prosódicos y de identidad.




Figura 6. Comparación entre F0-std y PESQ para diferentes variantes con DNS MOS.

Este análisis pone en evidencia las relaciones de compromiso entre las métricas seleccionadas y como la mejor variante no será la que alcance un mejor resultado en particular, sino la que logre un mejor balance de todos los criterios en conjunto.

5.1.3. Métricas compuestas

Una vez validado el comportamiento de cada métricas de forma individual, se analiza las métricas compuestas definidas en la Sección 4.3. Primero, la calidad de la señal, presenta el comportamiento similar a la tendencia explicada al analizar PESQ. Esto es evidente, ya que tanto PESQ, SI-SDR y SNR sigen la misma tendencia, como se presenta en las gráficas completas en el Anexo A.

En la Figura 7, se compara la métrica compuesta de reducción de datos (RD), respecto a la calidad de la señal (CS). Como la métrica se diseñó para minimizar el objetivo total, se puede ver que el mínimo coincide con la variante que filtra menor cantidad de datos y utiliza Demucs como algoritmo de denoising, resultado que coincide con el análisis de las métricas de forma aislada.

Se analizaron y compararon todas las combinaciones de las diferentes métricas. Los resultados completos de este análisis se presentan en el Anexo B. Los resultados mas destacados son la comparación entre calidad de señal y condiciones acústicas Figura 8, donde el agrupamiento de las métricas indica que el filtrado tiene muy poco impacto.




Figura 7. Comparación entre reducción de datos y calidad de señal para diferentes variantes con Nisqa.




Figura 8. Comparación entre calidad de señal y condiciones acústicas para diferentes variantes con DNSMOS.

5.1.4. Optimización de la cadena

Al sumar todas las métricas compuestas, se obtiene la métrica conjunta o total, con la cual se puede ordenar las variantes de la cadena y así definir cual es la configuración optima para procesar un conjunto de datos del habla.

En la Tabla 5, se presenta el valor de cada métrica parcial y el valor de la métrica conjunta, para todas las variantes, ordenadas de menor a mayor (siendo el mínimo la mejor variantes y máximo la peor variante). En la tabla se presentan las métricas parciales abreviadas, donde *RD* es reducción del dataset, *CS* es calidad de señal, *CA* es calidad acústica, *DH* es diferencias del habla, y *TOT* es la métrica conjunta, que contempla la suma de todas las métricas parciales.

La mejor configuración es la que utiliza Demucs como algoritmo de denoiser y DNSMOS como algoritmo de filtrado con umbral de MOS en 2.7. Esta configuración obtiene un

Tabla 5. Métricas compuestas y total para todas las configuraciones.

Filtrado	Umbral	Denoiser	RD	CS	CA	DH	TOT
DNSMOS	2,7	Demucs	0,02	2,30	1,29	0,48	4.08
DNSMOS	3,0	Demucs	0,13	2,27	1,27	0,51	4,17
NISQA	3,0	Demucs	0,17	2,28	1,27	0,60	4,31
NISQA	3,5	Demucs	0,29	2,25	1,28	0,58	4,41
NISQA	3,8	Demucs	0,40	2,25	1,30	0,55	4,51
DNSMOS	3,2	Demucs	0,35	2,25	1,27	0,63	4,51
DNSMOS	2,7	DeepFilterNet	0.01	2,66	1,37	0,62	4,65
NISQA	4,2	Demucs	0,64	2.22	1,29	0,52	4,68
DNSMOS	3,0	DeepFilterNet	0,12	2,63	1,37	0,61	4,73
NISQA	3,0	DeepFilterNet	0,15	2,67	1,37	0,63	4,83
DNSMOS	3,2	DeepFilterNet	0,35	2,62	1,35	0,60	4,93
DNSMOS	2,7	No denoising	0,19	2,85	1,82	0.07	4,93
NISQA	3,5	DeepFilterNet	0,30	2,65	1,38	0,63	4,96
DNSMOS	3,0	No denoising	0,45	2,72	1,66	0,12	4,96
DNSMOS	3,4	Demucs	0,80	2,23	1.24	0,78	5,05
NISQA	3,0	No denoising	0,37	2,82	1,79	0,09	5,08
DNSMOS	3,2	No denoising	0,68	2,65	1,58	0,20	5,10
NISQA	3,8	DeepFilterNet	0,45	2,66	1,37	0,64	5,13
NISQA	3,8	No denoising	0,79	2,53	1,69	0,20	5,21
NISQA	3,5	No denoising	0,62	2,74	1,74	0,13	5,22
DNSMOS	3,4	DeepFilterNet	0,79	2,59	1,32	0,58	5,29
NISQA	4,2	DeepFilterNet	0,63	2,58	1,37	0,81	5,39
DNSMOS	3,4	No denoising	0,93	2,65	1,54	0,28	5,39
NISQA	4,2	No denoising	0,89	2,53	1,65	0,46	5,53

valor total de 4.08, mientras que la peor variante alcanza un valor total de 5.53

Es interesante analizar como la cadena que alcanza la mejor puntuación general, no es la mejor opción en ninguna de las métricas individuales (marcadas en negrita), sino que ofrece la mejor relación de compromiso entre las 4 condiciones evaluadas.

5.1.5. Análisis del peso de cada métrica

Se analiza la varianza de cada métrica en función de las distintas configuraciones para determinar cual métrica tiene mas peso en el ordenamiento propuesto por la metodología de evaluación. En los resultados presentados cada conjunto de métrica tiene el mismo peso, pero al analizar la varianza de los resultados a traves de la diferentes configuraciones se evidencia que por las características del dataset, ciertas métricas tienen mayor influencia que otra. En la Tabla 6, se presentan los resultados de este análisis comparando desvío estándar y máxima desviación para todas las métricas conjuntas.

Tabla 6. Desvío estándar y máxima desviación para cada métrica compuesta respecto a las diferentes configuraciones de cadena bajo evaluación.

	RD: Reducción datos	CS: Calidad señal	CA: Condiciones acústicas	DH: Diferencias del habla
Desvío	0,28	0,20	0,18	0,22
$\Delta_{\text{máx}}$	0,92	0,62	0,58	0,74

En concordancia con los resultados, el conjunto de métricas que tiene mas variación es la reducción de datos. Esto tiene sentido dado que los filtrados mas permisivos prácticamente no reducían la cantidad de horas del dataset, mientras que los filtrados con un umbral mas agresivo reducían considerablemente la cantidad de horas del conjunto de datos.

FALTA: Variar los pesos que se le da a cada métrica para que el desvío quede igual y analizar como queda el ranking de la mejor configuración con este ajuste (a esta altura me parece agregar un layer más de complejidad que no se si suma mucho, lo dejaría para trabajos futuros).

5.2. COMPARACIÓN ENTRE CONJUNTOS DE DATOS

5.2.1. Dataset profesional vs procesado

El conjunto de datos profesionales detallado en (4.1.2), utiliza condiciones de grabación óptimas, con micrófonos de alta calidad, entornos controlados y técnicas de post-procesamiento avanzadas. Esto se traduce en una calidad acústica superior, con menor ruido de fondo, menor reverberación y una representación más fiel de la voz humana. En contraste, el dataset *in-the-wild* procesado mediante la cadena propuesta, aunque mejora significativamente la calidad del audio original, sigue presentando limitaciones inherentes a las condiciones de grabación no controladas.

Al utilizar las mismas métricas de análisis para caracterizar al dataset profesional, se puede evaluar el grado de mejora alcanzado por la cadena de procesamiento y comparar objetivamente las condiciones acústicas y de calidad entre ambos conjuntos de datos. Este análisis permite identificar en qué aspectos específicos el dataset procesado se acerca o se aleja de las condiciones ideales representadas por el dataset profesional, y así determinar si la cadena de procesamiento logra mitigar efectivamente las limitaciones del material

in-the-wild o si persisten brechas significativas en términos de calidad acústica, ruido residual o variabilidad prosódica, que no se pueden resolver únicamente con procesamiento de señales.

En la Figura 9 se compara el resultado de PESQ para la condición base (dataset *in-the-wild* sin procesar), el peor y mejor resultado de la cadena de procesamiento, y el valor promedio de los dataset profesionales. Esto pretende mostrar que si bien se genera una mejora objetiva en el dataset original, simplemente con procesamiento no se pueden igualar las condiciones de un conjunto de datos grabado en condiciones óptimas.




Figura 9. Diferencias del valor de PESQ promedio según diferentes conjuntos de datos.

En cambio, para el parámetro de T_{30} , se observa que la mejor variante con procesamiento mejora la condición de reverberancia promedio alcanzada por el promedio de dataset tradicionales Figura 10. Esto deja en evidencia que la variación producto del procesamiento depende específicamente de cada métrica, donde se puede evaluar casos como el PESQ donde no se iguala el valor del dataset original, o casos como el T_{30} donde se mejora la condición de referencia. Esta tendencia se repite para C_{50} , donde la mejor variante de la cadena de procesamiento mejora el valor promedio del dataset profesional, mientras que métricas de calidad como SNR y SI-SDR, aunque mejoran respecto al dataset original, no alcanzan el valor promedio del dataset profesional. Todos los resultados de esta comparación para las métricas individuales se presentan en el Anexo C.

FALTA: Agregar en el anexo los gráficos que faltan de esta sección.

Estos resultados son congruentes con las agrupaciones realizadas en el estudio de mé-




Figura 10. Diferencias del valor de T30 promedio según diferentes conjuntos de datos.

tricas, donde se evidenció que las métricas de calidad de señal y acústica no necesariamente están correlacionadas, y que el procesamiento puede mejorar ciertas condiciones acústicas sin necesariamente mejorar la calidad de señal en la misma proporción.

Por último, para analizar la variabilidad prosódica y de identidad del hablante, se compara la frecuencia fundamental promedio de los hablantes de los dataset evaluados Figura 11, donde el dataset ITW presenta una mayor variabilidad y un valor promedio mayor, indicando que no hay ningún tipo de sesgo hacia hablantes con voz mas grave, como suele ocurrir en los dataset profesionales, donde se tiende a seleccionar hablantes con voz mas grave para evitar problemas de sibilancia y ruido. Además, el valor de $F0-STD$ es mayor para el dataset ITW, lo que indica una mayor variabilidad en la frecuencia fundamental, lo cual es positivo para tareas de síntesis de voz que requieren diversidad prosódica.

Estos resultados evidencian la necesidad de incorporar conjuntos de datos *in-the-wild* si se busca capturar el fenómeno del habla en su diversidad y complejidad real, ya que los dataset profesionales, aunque de alta calidad, pueden presentar sesgos significativos en términos de identidad de hablante y patrones prosódicos, lo cual limita su aplicabilidad para tareas que requieren generalización a condiciones reales de uso.




Figura 11. Diferencias del valor de F0 promedio según diferentes conjuntos de datos.

5.3. COMPARACIÓN POR ESTIMACIÓN DE DENSIDAD

En la Sección 4.4.1, se describen los detalles de la configuración usada para entrenar el modelo. En la Tabla 7 se resumen los resultados mas importantes del proceso de entrenamiento, donde se puede ver lo costoso que es entrenar un modelo de difusión de alta fidelidad.

Tabla 7. Especificaciones técnicas e hiperparámetros del entrenamiento del modelo de difusión.

Parámetro / Recurso	Valor / Descripción
Duración total del entrenamiento	33,554 kwav (33.5M de muestras)
Tiempo de cómputo total	≈ 92 horas
Función de pérdida final (<i>Loss</i>)	−1,218
Mecanismo de promediado	EMA (Exponential Moving Average) 0.100

En la Figura 12 se muestra la función de pérdida en función de los audios evaluados (la unidad 1 kwav equivale a 1000 audios evaluados), donde se observa que el entrenamiento ha convergido de manera efectiva, lo cual indica que el modelo ha aprendido a estimar la distribución de los datos, permitiendo así realizar comparaciones significativas entre las diferentes variantes de la cadena de procesamiento.

Los modelos de difusión son costosos de entrenar, pero también tienen un alto tiempo de ejecución en la etapa de inferencia (para procesar 10 horas de audio se necesitan aproximadamente 24 horas de cómputo). Para optimizar los recursos de infraestructura, se evalúa el modelo de difusión en 8 variantes de la cadena, seleccionando variantes representativas




Figura 12. Función de pérdida en función de los audios evaluados durante el entrenamiento del modelo de difusión.

de cada categoría de métricas objetivas.

Al igual que con el cálculo de métricas objetivas, se sample de forma aleatoria muestras de cada variante para clasificar la calidad de ese conjunto. Se toma la mitad de muestras por configuración y se recorta los primeros 5 segundos del audio para evitar saturaciones de memoria del modelo de difusión, lo cual es un problema común al procesar audios largos con este tipo de modelos. Si bien esta simplificación es necesaria para poder hacer el cálculo, trajo el inconveniente de distorsionar los resultados cuando el inicio del audio casi no contenía voz, lo cual pasa en una sección muy menor del total de los audios, pero distorsiona los resultados ya que dichas secciones presenta un valor de calidad muy alto, y no es representativo de la calidad general del audio. Para solucionar este problema, se implementó un filtro adicional para eliminar los audios que presentaban un valor de calidad muy alto, lo cual permitió obtener resultados mas representativos de la calidad general del audio.

En la Tabla 8 se presentan los resultados de la estimación de densidad para cada variante seleccionada, además, se adjunta el valor de calidad final según el análisis por métricas objetivas. Una mayor similitud (mayor log-likelihood) implica que el conjunto de datos resultante de la variante bajo estudio, se parece mas a la distribución de los datos originales, que al ser audios de calidad sacados del corpus profesional, una mayor similitud indica una mayor calidad de audio.

Similar a lo que se observa en el análisis de las métricas objetivas, el umbral y tipo de filtrado no presentan una tendencia clara en la estimación del modelo de densidad, mientras que el algoritmo de denoising es el factor que mas influye en la verosimilitud, donde

Tabla 8. Comparación entre métricas de estimación de densidad (Likelihood) y la métrica objetiva total (TOT), ordenado por verosimilitud.

Filtrado	Umbral	Denoiser	Likelihood ↑	TOT ↓
DNSMOS	2,7	DeepFilterNet	2,37	4,65
NISQA	3,8	DeepFilterNet	2,29	5,13
DNSMOS	2,7	No denoising	2,12	4,93
NISQA	4,2	No denoising	2,01	5,53
DNSMOS	3,4	Demucs	1,87	5,05
NISQA	4,2	Demucs	1,85	4,68
DNSMOS	2,7	Demucs	1,72	4,08
NISQA	3,0	Demucs	1,69	4,31

la variante con DeepFilterNet obtiene los mejores resultados, seguida por la condición sin denoising, y por último la variante con Demucs. Este resultado, se debe a que el modelo de difusión califica negativamente el procesamiento agresivo de Demucs, el cual aunque mejora la calidad objetiva del audio, también introduce artefactos que afectan la distribución de los datos y, por ende, la verosimilitud estimada por el modelo de difusión. En contraposición, DeepFilterNet, que es un algoritmo de denoising mas suave, logra mejorar la calidad del audio sin introducir artefactos tan severos, lo cual se refleja en una mayor verosimilitud según el modelo de difusión.

En la Figura 13 se presenta la distribución (estimada mediante el método de Kernel Density Estimation) de la verosimilitud para 3 configuraciones usando diferentes algoritmos de denoising. Se puede observar, que si bien Demucs tiene el promedio mas bajo, también tiene una distribución mas estrecha, lo cual indica que aunque el promedio es menor, la mayoría de los audios presentan una verosimilitud similar, mientras que en la condición sin denoising y con DeepFilterNet, aunque el promedio es mayor, también hay una mayor variabilidad entre los audios.

Según el modelo de densidad, Demucs se comporta como un algoritmo de denoising agresivo, que puede introducir artefactos que hagan que no suene natural, pero logra unificar la distribución de los datos y tener un conjunto de mas homogéneo. En cambio, aplicar DeepFilterNet es menos invasivo, lo cual mejora la calidad del audio sin introducir artefactos tan severos, pero no logra una unificar las diferentes condiciones originales. En la condición sin denoising, aunque el promedio de verosimilitud es mayor que con Demucs, también hay una mayor variabilidad entre los audios, lo cual indica que el modelo de difusión valora la diversidad de condiciones acústicas presentes en el dataset original, pero también penaliza




Figura 13. Distribución de la verosimilitud para diferentes algoritmos de denoising.

la presencia de segmentos con baja calidad.

Cuando el objetivo final de los datos es entrenar un modelo de TTS, tener una base de datos homogénea es fundamental para garantizar que el modelo pueda converger con facilidad y generar audio de buena calidad de forma consistente. En general, esto se consigue a costa de disminuir la naturalidad y flexibilidad del modelo, lo cual puede ser un problema para tareas de síntesis de voz que requieren generalización a condiciones reales de uso. Dentro de este paradigma que presenta un compromiso entre calidad y diversidad, utilizar Demucs prioriza la homogeneidad del dataset, lo cual puede ser beneficioso para tareas de síntesis que requieren alta calidad y consistencia, pero puede limitar la capacidad del modelo para generalizar a condiciones acústicas variadas. En cambio, utilizar DeepFilterNet o no aplicar denoising prioriza la diversidad de condiciones acústicas, lo cual puede ser beneficioso para tareas de síntesis que requieren generalización a condiciones reales de uso, pero puede dificultar la convergencia del modelo y generar audio de menor calidad de forma consistente.

5.4. COMPARACIÓN ENTRE MÉTRICAS OBJETIVAS Y ESTIMACIÓN DE DENSIDAD

El análisis comparativo entre la metodología tradicional, basada en un conjunto de métricas objetivas y la metodología basada en la estimación de densidad mediante modelos de difusión, revela una divergencia fundamental en la forma en que ambas aproximaciones conceptualizan la calidad del audio.

Al observar la Tabla 8, resulta evidente que el ordenamiento de las variantes de la cadena de procesamiento se invierte drásticamente dependiendo del criterio utilizado. Esta contradicción no representa un fallo metodológico, sino que expone las limitaciones y los sesgos inherentes de cada sistema de evaluación.

El hallazgo más significativo es el posicionamiento diametralmente opuesto de los algoritmos de separación de fuentes. Según la métrica objetivas, la configuración óptima para procesar el dataset recae invariablemente en Demucs (logrando el mínimo global de 4,08). Las métricas intrusivas clásicas (como PESQ o SI-SDR) premian de manera casi lineal la ausencia de energía en las bandas donde se espera silencio, favoreciendo la agresividad de Demucs al remover el ruido de fondo.

Sin embargo, desde la perspectiva de la estimación de densidad, Demucs obtiene los peores puntajes de verosimilitud (alrededor de 1,72 a 1,87). El modelo de difusión fue entrenado con un corpus masivo que contiene las sutilezas acústicas y el piso de ruido natural propio de las grabaciones físicas. Cuando Demucs opera sobre la señal, genera "agujeros espectrales" (silencios absolutos en ciertas bandas de frecuencia rodeados de energía) que son topológicamente imposibles en el mundo real. El solucionador de la Ecuación Diferencial Ordinaria (ODE) del modelo de difusión detecta estos vacíos antinaturales como anomalías severas en el espectrograma, alejando drásticamente el audio de la distribución de entrenamiento y, por ende, castigando su likelihood. En la Figura 14 se puede observar un ejemplo comparando 3 espectrogramas (sin procesar, procesado con Demucs y procesado con DeepFilterNet) donde se aprecian los huecos espectrales generados por Demucs, que no se encuentran presentes en el audio sin procesar ni en el audio procesado con DeepFilterNet, lo cual explica la baja verosimilitud de los audios procesados con Demucs según el modelo de difusión.




Figura 14. Ejemplo del mismo audio procesado con diferentes algoritmos de denoising.

Por el contrario, DeepFilterNet domina el ranking de estimación de densidad (con valores superiores a 2,29). Al estar diseñado bajo un paradigma de realce perceptual en lugar de separación ciega de fuentes, respeta la envolvente espectral y preserva componentes armónicas sutiles. Para el modelo de difusión, un audio con DeepFilterNet sigue perteneciendo a la distribución "natural" del habla humana, aunque bajo el microscopio de las métricas objetivas ($TOT \approx 4,65 - 5,13$) sea penalizado por dejar residuos de ruido.

Cabe aclarar que la métrica por estimación de densidad no contempla la reducción de datos que si contempla el resultado total de las métricas objetivas, pero al analizar la tendencia solo con los valores de calidad de señal (CS) y condiciones acústicas (CA). Para analizar esta diferencia se presentan la Figura 15 donde se compara la predicción del modelo de difusión con respecto a la métricas de calidad de señal y condiciones acústicas. Se puede ver que sigue una tendencia similar a la métrica conjunta, donde el algoritmo de denoising es el factor que mas influye en la verosimilitud, mientras que el umbral de filtrado no presenta una tendencia clara. Al las métricas por separado, se comprueba el mismo patrón donde Demucs obtiene mejores resultados objetivos pero peores resultados de verosimilitud, mientras que DeepFilterNet obtiene mejores resultados de verosimilitud pero peores

resultados objetivos.




Figura 15. Comparación de la predicción del modelo de difusión con las métricas de calidad de señal y condiciones acústicas.

5.4.1. Conclusión del Análisis Cruzado

La integración de ambas metodologías demuestra que evaluar pipelines de procesamiento de habla exige definir claramente el objetivo del sistema downstream.

Si el objetivo es alimentar un sistema de reconocimiento automático del habla (ASR), donde la claridad de la formante vocal es más crítica que la naturalidad del fondo, el ordenamiento provisto por las métricas objetivas y el uso de separadores agresivos como Demucs es el camino adecuado.

No obstante, si el corpus resultante se destinará al entrenamiento de modelos generativos, como síntesis de texto a voz (TTS) o clonación de voz, la métrica de estimación de densidad resulta ser un evaluador más robusto y orgánico. En este escenario, priorizar algoritmos de realce conservadores como DeepFilterNet o, en su defecto, depender exclusivamente del filtrado estricto por umbrales (sin aplicar denoising), garantiza que los datos de entrenamiento no hereden distorsiones espectrales que el modelo generativo inevitablemente replicaría.

Estos resultados también indican que se debe expandir el análisis de las métricas obje-

tivas para incorporar penalizaciones explícitas por artefactos de denoising, o bien, desarrollar nuevas métricas que puedan capturar la naturalidad espectral y la coherencia temporal, aspectos que el modelo de difusión parece valorar de manera inherente. La principal ventaja que tiene el análisis guiado por métricas objetivas es que permite evaluar de forma rápida y con bajo costo computacional una gran cantidad de variantes, lo cual es fundamental para poder optimizar la cadena de procesamiento, sobre todo cuando esta esta pensada para ser aplicada a grandes cantidades de datos.

5.5. VALIDACIÓN MODELO DE TTS ZERO-SHOT

Para esta validación, se seleccionaron las mismas 8 configuraciones que se seleccionaron para el modelo de estimación de densidad, con el objetivo de comparar los resultados obtenidos por el modelo de difusión con los resultados de MOS obtenidos al evaluar los modelos de TTS zero-shot.

FALTA: Compara calidad de clonación respecto a la calidad o subset del audio original.

Para minimizar los tiempos de evaluación de esta prueba, se tomaron 100 audios de forma aleatorio de cada variante de la cadena, y se utilizaron como referencia para el modelo de TTS zero-shot. La elección de tomar esta cantidad de muestras se debe a las limitaciones de infraestructura para poder escalar el experimento.

- Presentar gráficos de MOS vs Métricas compuestas
- Presentar gráficos de MOS vs estimación densidad
- Concluir cual es la mejor métrica según análisis subjetivo

5.6. EVALUACIÓN EXPLORATORIA EN TAREAS DE SÍNTESIS ZERO-SHOT

A continuación, se presentan los resultados comparativos entre la capacidad predictiva de las métricas objetivas (TOT) y la estimación de densidad (Log-Likelihood) frente a la calidad del habla sintetizada.

5.6.1. Predicción basada en Métricas Objetivas (TOT)

En la Figura 16 se ilustra la relación entre la puntuación total de métricas objetivas (TOT) en el eje horizontal y la calidad subjetiva estimada del audio sintetizado (MOS del TTS) en el eje vertical.




Figura 16. Relación entre la métrica objetiva total (TOT) y la calidad subjetiva sintetizada (MOS).

Como se observa en el gráfico, se observa una tendencia contraria a la esperada: las variantes con menos puntuación total (recordando que la métrica se define como un valor a minimizar) no producen audios sintéticos de mayor preferencia, de hecho observamos una correlación negativa entre la métrica TOT y la calidad subjetiva del audio sintetizado. Esto indica que las métricas objetivas no son un buen predictor de la calidad percibida por los oyentes en el contexto de síntesis de voz *zero-shot*.

Este resultado está sesgado por la penalización de otorgamos a la variable de reducción de datos, ya que al tratarse modelos de TTS *zero-shot*, la cantidad de datos no es un factor relevante para la calidad del audio sintetizado.

Al realizar el análisis estadístico, la regresión lineal arroja una correlación de Pearson de $r = 0,5822$ ($p = 0,0774$) para Qwen TTS y $r = 0,4912$ ($p = 0,1494$) para F5 TTS. En ambos casos, el p -value es superior al nivel de significancia estricto del 5 % ($\alpha = 0,05$). Esto implica que no existe evidencia estadística significativa para afirmar que la métrica objetiva TOT es inversamente proporcional al MOS esperado por modelos TTS *zero-shot*.

5.6.2. Predicción basada en Estimación de Densidad (Log-Likelihood)

Por el contrario, al evaluar la capacidad predictiva del modelo de estimación de densidad basado en difusión, el panorama cambia drásticamente. La Figura 17 muestra la dispersión de los datos utilizando el *Log-Likelihood* promedio en el eje horizontal.




Figura 17. Relación entre la estimación de densidad (Log-Likelihood) y la calidad subjetiva sintetizada (MOS).

La regresión sobre estos datos revela una correlación positiva fuerte y consistente para ambos sintetizadores: $r = 0,8191$ ($p = 0,0128$) para Qwen TTS y $r = 0,8111$ ($p = 0,0145$) para F5 TTS. Al obtener un $p\text{-value} < 0,05$, la correlación es estadísticamente significativa al nivel del 5 %.

Este resultado evidencia que un aumento en el puntaje de verosimilitud otorgado por el modelo de difusión se traduce linealmente en una mejora perceptible en la calidad de la síntesis de voz generada. Las configuraciones de preprocesamiento agrupadas a la izquierda del gráfico (baja verosimilitud, correspondientes a filtrados agresivos con Demucs) resultaron de forma consistente en audios sintetizados de menor calidad ($MOS < 3,2$). En contraposición, las variantes que preservaron la topología original de la señal (DeepFilterNet y No Denoising), ubicadas a la derecha del espectro de verosimilitud, permitieron a los modelos TTS *zero-shot* alcanzar las puntuaciones más altas de MOS ($\approx 3,4 - 3,6$).

5.6.3. Discusión Final

Los resultados de este experimento exploratorio convergen con la hipótesis planteada en las secciones anteriores. Las métricas objetivas intrusivas, al enfocarse primordialmente en la relación señal a ruido y en modelos psicoacústicos tradicionales (PESQ), fallan al intentar capturar la integridad estructural requerida por las redes neuronales generativas modernas.

La capacidad del modelo de estimación de densidad para predecir de forma estadísticamente significativa el desempeño en tareas de TTS refuerza la postura de que los modelos fundacionales de habla son altamente sensibles a las distorsiones algorítmicas (artefactos de fase, huecos espectrales). Así, la verosimilitud computada mediante modelos de difusión continua emerge no solo como una métrica teórica de distancia distribucional, sino como un indicador empíricamente válido para seleccionar corpus de entrenamiento destinados a sistemas generativos.

Esto es fundamental en el diseño de pipelines de preprocesamiento de audio para sistemas de ASR y TTS, donde la elección de algoritmos de denoising y filtrado no debe basarse únicamente en métricas objetivas tradicionales, sino también en la preservación de la topología acústica que los modelos generativos esperan encontrar.

La conclusión final también pone en evidencia la necesidad la necesidad de explorar nuevas métricas de evaluación de calidad acústica que sean funcionales a las arquitecturas de modelos generativos actuales, y así poder optimizar todas las etapas de la cadena de procesamiento de audio, desde la captura hasta la síntesis, garantizando que los datos de entrenamiento sean representativos y útiles para el aprendizaje profundo.

5.6.4. Sensibilidad Arquitectónica: Modelos Autoregresivos frente a Modelos de Difusión

Un hallazgo secundario, pero sumamente revelador en este experimento, es la brecha de rendimiento sistemática observada entre los dos sintetizadores evaluados. Al analizar las curvas de regresión (Figuras 16 y 17), resulta evidente que Qwen TTS logra puntuaciones subjetivas (MOS) consistentemente superiores a las de F5 TTS para prácticamente la totalidad de las configuraciones evaluadas, desplazando su recta de regresión verticalmente de

manera uniforme.

Esta disparidad empírica puede fundamentarse en la naturaleza intrínseca de las arquitecturas subyacentes de cada modelo:

Por un lado, Qwen TTS es un sistema basado en Modelos de Lenguaje Grande (LLMs). Esta arquitectura de naturaleza autoregresiva no opera directamente sobre las ondas de sonido continuas, sino sobre representaciones discretizadas del audio generadas mediante codecs neuronales (cuantización de vectores). En escenarios *zero-shot* con audios in-the-wild, este proceso de discretización en tokens acústicos actúa como un poderoso filtro de normalización intrínseco. El codec tiende a ignorar micro-artefactos, ruido residual de fondo o distorsiones de fase leves al momento de asignar el token, mientras que el fuerte condicionamiento lingüístico del LLM impone un conocimiento previo muy sólido sobre cómo debe sonar la prosodia humana, rescatando la síntesis incluso si el audio de referencia prompt es deficiente.

Por otro lado, F5 TTS es una arquitectura fundamentada en flow-matching y modelos de difusión. A diferencia del LLM, los modelos de difusión operan resolviendo ecuaciones diferenciales estocásticas en espacios latentes o espectrogramas continuos. Su objetivo matemático es el emparejamiento exacto de distribuciones. Esta característica los hace instrumentos de extremada alta fidelidad, pero a la vez, hiper-sensibles a la condición inicial. Si el audio de referencia ha sido procesado con un algoritmo agresivo (como Demucs) y presenta "huecos espectrales" o variaciones antinaturales, el modelo de difusión intentará modelar y reproducir fielmente esa anomalía acústica, propagando la degradación a la voz sintetizada final.

En conclusión, los resultados sugieren que los modelos TTS basados en difusión (F5) son evaluadores más estrictos y transparentes de la calidad topológica real de un dataset, ya que no enmascaran los defectos de la señal. Los modelos autoregresivos basados en LLMs (Qwen), en cambio, ofrecen una mayor resiliencia computacional y robustez acústica en entornos de producción donde los audios de referencia no pueden garantizarse bajo estándares estrictos de estudio.

6. CONCLUSIONES

En las conclusiones del Plan de Investigación, debe plantearse cómo será la exposición de los resultados y qué es lo que se espera obtener en resumen de las pruebas que se realicen.

7. LÍNEAS FUTURAS DE INVESTIGACIÓN

Este trabajo pretende contribuir a la unificación de criterios en el diseño y evaluación de cadenas de preprocesado, lo que facilitará la identificación de las configuraciones más adecuadas para distintos casos de uso. Entre las líneas futuras de investigación se destacan, en particular, el desarrollo de modelos de denoising o speech enhancement personalizados: mediante técnicas de adaptación, dichos modelos buscarían aproximar conjuntos de grabaciones diversas hacia el dominio acústico del corpus con el que fue entrenado el modelo TTS, aumentando así la robustez y la fidelidad de la síntesis en condiciones reales.

BIBLIOGRAFÍA

- Ardila, R., Branson, M., Davis, K., Kohler, M., Meyer, J., Henretty, M., Morais, R., Saunders, L., Tyers, F., & Weber, G. (2020). Common Voice: A Massively-Multilingual Speech Corpus. *Proceedings of the Twelfth Language Resources and Evaluation Conference*, 4218-4222. <https://aclanthology.org/2020.lrec-1.520/>
- Ayllón, D., Sánchez-Hevia, H., Figueroa, C., & Lanchantin, P. (2019). Investigating the Effects of Noisy and Reverberant Speech in Text-to-Speech Systems. *Proc. Interspeech*, 1511-1515. <https://doi.org/10.21437/Interspeech.2019-3104>
- Bäckström, T., Räsänen, O., Zewoudie, A., Zarazaga, P. P., Koivusalo, L., Das, S., Mellado, E. G., Mansali, M. B., Ramos, D., Kadiri, S., Alku, P., & Vali, M. H. (2022). *Introduction to Speech Processing* (2.^a ed.). <https://doi.org/10.5281/zenodo.6821775>
- Chen, Y., Wu, Z., Ren, Y., Tan, X., & Zhao, Z. (2024). F5-TTS: A Fairytaler that Fakes Fluent and Faithful Speech with Flow Matching. *arXiv preprint arXiv:2410.06885*.
- Cooper, E. (2019,). *Text-to-Speech Synthesis Using Found Data for Low-Resource Languages* [PhD. thesis]. Columbia University.
- de Oliveira, D., Richter, J., Lemercier, J.-M., Welker, S., & Gerkmann, T. (2025). Non-intrusive Speech Quality Assessment with Diffusion Models Trained on Clean Speech. *Interspeech 2025*, 2330-2334. <https://doi.org/10.21437/Interspeech.2025-1728>
- Défossez, A., Synnaeve, G., & Adi, Y. (2020). Real Time Speech Enhancement in the Waveform Domain. *Proc. Interspeech*, 3291-3295. <https://doi.org/10.21437/Interspeech.2020-2409>
- de Weinberg, M., & de Mirande, N. (2004). *El español de la Argentina y sus variedades regionales*. Asociación Bernardino Rivadavia, Proyecto Cultural Weinberg/Fontanella. <https://books.google.com.ar/books?id=fpxiAAAAMAAJ>
- Gabriel, C. (2011). Hamburg Corpus of Argentinean Spanish (HaCASpa).
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2020). Generative adversarial networks. *Commun. ACM*, 63(11), 139-144. <https://doi.org/10.1145/3422622>
- Guevara-Rukoz, A., Demirsahin, I., He, F., Chu, S.-H. C., Sarin, S., Pipatsrisawat, K., Gutkin, A., Butryna, A., & Kjartansson, O. (2020). Crowdsourcing Latin American Spanish

- for Low-Resource Text-to-Speech. *Language Resources and Evaluation Conference (LREC)*, 6504-6513. <https://aclanthology.org/2020.lrec-1.801/>
- Gurlekian, J., Güemes, M. M., Evin, D. A., & Torres, H. M. (2021). Normalización del texto "Los sentidosz su aplicación en la evaluación de habla continua. *Onomázein*.
- He, H., Shang, Z., Wang, C., Li, X., Gu, Y., Hua, H., Liu, L., Yang, C., Li, J., Shi, P., Wang, Y., Chen, K., Zhang, P., & Wu, Z. (2024). Emilia: An Extensive, Multilingual, and Diverse Speech Dataset For Large-Scale Speech Generation. *IEEE Spoken Language Technology Workshop (SLT)*, 885-890. <https://doi.org/10.1109/SLT61566.2024.10832365>
- Hernandez-Mena, C. D. (2019). TEDx Spanish Corpus. Audio and transcripts in Spanish taken from the TEDx Talks.
- Ho, J., Jain, A., & Abbeel, P. (2020). Denoising diffusion probabilistic models. *Proceedings of the 34th International Conference on Neural Information Processing Systems*.
- Huang, R., Zhao, Z., Liu, H., Liu, J., Cui, C., & Ren, Y. (2022). ProDiff: Progressive Fast Diffusion Model for High-Quality Text-to-Speech. *Proceedings of the 30th ACM International Conference on Multimedia*, 2595-2605.
- Hunt, A. J., & Black, A. W. (1996). Unit selection in a concatenative speech synthesis system using a large speech database. *Proceedings of IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP)*, 373-376.
- ISO 3382-2:2008 Acoustics – Measurement of room acoustic parameters – Part 2: Reverberation time in ordinary rooms. (2008). International Organization for Standardization.
- ITU-T. (2001, febrero). *Perceptual evaluation of speech quality (PESQ): An objective method for end-to-end speech quality assessment of narrow-band telephone networks and speech codecs* (inf. téc. N.º P.862). International Telecommunication Union.
- ITU-T. (2018). *P.863: Perceptual Objective Listening Quality Prediction* (inf. téc. N.º P.863). International Telecommunication Union.
- Jeong, M., Kim, H., Cheon, S. J., Choi, B. J., & Kim, N. S. (2021). Diff-TTS: A Denoising Diffusion Model for Text-to-Speech. *Interspeech 2021*, 3605-3609. <https://doi.org/10.21437/Interspeech.2021-468>
- Jung, J., Zhang, W., Maiti, S., Wu, Y., Wang, X., Kim, J.-H., Matsunaga, Y., Um, S., Tian, J., Shim, H.-j., Evans, N., Chung, J. S., Takamichi, S., & Watanabe, S. (2025). The Text-to-speech in the Wild (TITW) Database. *Proc. Interspeech*, 4798-4802. <https://doi.org/10.21437/Interspeech.2025-2536>

- Kim, C., & Stern, R. (2008). Robust signal-to-noise ratio estimation based on waveform amplitude distribution analysis. *Proc. Interspeech*, 2598-2601.
- Kim, J., Kong, J., & Son, J. (2021). Conditional Variational Autoencoder with Adversarial Learning for End-to-End Text-to-Speech. *International Conference on Machine Learning*, 5530-5540.
- Kingma, D. P., & Welling, M. (2013). Auto-Encoding Variational Bayes.
- Kominek, J., Schultz, T., & Black, A. W. (2008). Synthesizer voice quality of new languages calibrated with mean mel cepstral distortion. *Proc. Speech Technology Under-Resourced Languages*, 63-68.
- Kong, J., Kim, J., & Bae, J. (2020). HiFi-GAN: generative adversarial networks for efficient and high fidelity speech synthesis. *Proceedings of the 34th International Conference on Neural Information Processing Systems*.
- Kong, Z., Ping, W., Huang, J., Zhao, K., & Catanzaro, B. (2021). DiffWave: A Versatile Diffusion Model for Audio Synthesis. *International Conference on Learning Representations*. <https://openreview.net/forum?id=a-xFK8Ymz5J>
- Kumar, A., Tan, K., Ni, Z., Manocha, P., Zhang, X., Henderson, E., & Xu, B. (2023). Torchaudio-Squim: Reference-Less Speech Quality and Intelligibility Measures in Torchaudio. *IEEE International Conference of Acoustics, Speech and Signal Processing (ICASSP)*, 1-5. <https://doi.org/10.1109/ICASSP49357.2023.10096680>
- Le Roux, J., Wisdom, S., Erdogan, H., & Hershey, J. (2019). SDR – Half-baked or Well Done?, 626-630. <https://doi.org/10.1109/ICASSP.2019.8683855>
- Li, X., Jia, K., Sun, H., Dai, J., & Jiang, Z. (2024). Muyan-TTS: A Trainable Text-to-Speech Model Optimized for Podcast Scenarios with a \$50K Budget. *arXiv preprint arXiv:2504.19146*. <https://arxiv.org/abs/2504.19146>
- Li, X., Takamichi, S., Saeki, T., Chen, W., Shiota, S., & Watanabe, S. (2023). Yodas: Youtube-Oriented Dataset for Audio and Speech. *2023 IEEE Automatic Speech Recognition and Understanding Workshop (ASRU)*, 1-8. <https://doi.org/10.1109/ASRU57964.2023.10389689>
- Ma, L., Guo, D., Song, K., Jiang, Y., Wang, S., Xue, L., Xu, W., Zhao, H., Zhang, B., & Xie, L. (2024). WenetSpeech4TTS: A 12,800-hour Mandarin TTS Corpus for Large Speech Generation Model Benchmark. *Proc. Interspeech*, 1840-1844. <https://doi.org/10.21437/Interspeech.2024-2343>

- Mittag, G., Naderi, B., Chehadi, A., & Möller, S. (2021). NISQA: A Deep CNN-Self-Attention Model for Multidimensional Speech Quality Prediction with Crowdsourced Datasets. *Proc. Interspeech*, 2127-2131. <https://doi.org/10.21437/Interspeech.2021-299>
- Oliveira, F. S., Casanova, E., Junior, A. C., Soares, A. S., & Galvão Filho, A. R. (2023). CML-TTS: Multilingual Dataset for Speech Synthesis in Low-Resource Languages. *Text, Speech, and Dialogue: 26th International Conference, TSD 2023, Pilsen, Czech Republic, September 4–6, 2023, Proceedings*, 188-199. https://doi.org/10.1007/978-3-031-40498-6_17
- Ortega Riera, P., Passano, N., Paez, D., Bach, F., Pupkin, I., Sacerdoti, E., Yommi, M., & Martín, H. (2023). Implementación y Evaluación de un Sistema de Clonación de Voz Rioplatense para Asistencia en la Comunicación Oral. *Jornadas de Acústica, Audio y Sonido*.
- Ortiz, M. (2023). Estimación ciega de parámetros acústicos de un recinto. *Master Thesis*.
- Popov, V., Vovk, I., Gogoryan, V., Sadekova, T., & Kudinov, M. (2021). Grad-TTS: A Diffusion Probabilistic Model for Text-to-Speech. *International Conference on Machine Learning*, 8599-8608.
- Pratap, V., Xu, Q., Sriram, A., Synnaeve, G., & Collobert, R. (2020). MLS: A Large-Scale Multilingual Dataset for Speech Research. *Interspeech 2020*, 2757-2761. <https://doi.org/10.21437/Interspeech.2020-2826>
- Radford, A., Kim, J., Xu, T., Brockman, G., Mcleavey, C., & Sutskever, I. (2023). Robust Speech Recognition via Large-Scale Weak Supervision. *Proceedings of the 40th International Conference on Machine Learning, 202*, 28492-28518.
- Reddy, C. K. A., Gopal, V., & Cutler, R. (2021). Dnsmos: A Non-Intrusive Perceptual Objective Speech Quality Metric to Evaluate Noise Suppressors. *IEEE International Conference of Acoustics, Speech and Signal Processing (ICASSP)*, 6493-6497. <https://doi.org/10.1109/ICASSP39728.2021.9414878>
- Ren, Y., Hu, C., Tan, X., Qin, T., Zhao, S., Zhao, Z., & Liu, T.-Y. (2021a). FastSpeech 2: Fast and High-Quality End-to-End Text to Speech. *International Conference on Learning Representations (ICLR)*.
- Ren, Y., Hu, C., Tan, X., Qin, T., Zhao, S., Zhao, Z., & Liu, T.-Y. (2021b). FastSpeech 2: Fast and High-Quality End-to-End Text to Speech. *International Conference on Learning Representations*.

- Riou, A., Lattner, S., Hadjeres, G., & Peeters, G. (2023). PESTO: Pitch Estimation with Self-supervised Transposition-equivariant Objective. *Proceedings of the 24th International Society for Music Information Retrieval Conference (ISMIR)*.
- Sabra, A., Wronka, C., Mao, M., & Hijazi, S. (2024). SECP: A Speech Enhancement-Based Curation Pipeline for Scalable Acquisition of Clean Speech. *IEEE International Conference of Acoustics, Speech and Signal Processing (ICASSP)*, 11981-11985. <https://doi.org/10.1109/ICASSP48485.2024.10446973>
- Schroter, H., Escalante-B, A. N., Rosenkranz, T., & Maier, A. (2022). Deepfilternet: A Low Complexity Speech Enhancement Framework for Full-Band Audio Based On Deep Filtering. *IEEE International Conference of Acoustics, Speech and Signal Processing (ICASSP)*, 7407-7411. <https://doi.org/10.1109/ICASSP43922.2022.9747055>
- Shen, J., Pang, R., Weiss, R. J., Schuster, M., Jaitly, N., Yang, Z., Chen, Z., Zhang, Y., Wang, Y., Skerry-Ryan, R. J., Saurous, R. A., Agiomyrgiannakis, Y., & Wu, Y. (2018). Natural TTS Synthesis by Conditioning WaveNet on Mel Spectrogram Predictions. *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 4779-4783. <https://doi.org/10.1109/ICASSP.2018.8461368>
- Shen, J., Pang, R., Weiss, R. J., Schuster, M., Jaitly, N., Yang, Z., Chen, Z., Zhang, Y., Wang, Y., Skerry-Ryan, R., et al. (2018). Natural TTS synthesis by conditioning wavenet on mel spectrogram predictions. *2018 IEEE international conference on acoustics, speech and signal processing (ICASSP)*, 4779-4783.
- Song, Y., Sohl-Dickstein, J., Kingma, D. P., Kumar, A., Ermon, S., & Poole, B. (2021). Score-Based Generative Modeling through Stochastic Differential Equations. *International Conference on Learning Representations*. <https://openreview.net/forum?id=PxTIG12RRHS>
- Sosa Welford, A., & Pepino, L. (2025). A Dataset for Automatic Assessment of TTS Quality in Spanish. *Interspeech 2025*, 4813-4817. <https://doi.org/10.21437/Interspeech.2025-973>
- Taal, C., Hendriks, R., Heusdens, R., & Jensen, J. (2011). An Algorithm for Intelligibility Prediction of Time–Frequency Weighted Noisy Speech. *Audio, Speech, and Language Processing, IEEE Transactions on*, 19, 2125-2136. <https://doi.org/10.1109/TASL.2011.2114881>

- Tan, X., Qin, T., Soong, F. K., & Liu, T.-Y. (2021). A Survey on Neural Speech Synthesis. *arXiv preprint arXiv:2106.15561*. <https://arxiv.org/abs/2106.15561>
- Team, S. (2024). Silero VAD: pre-trained enterprise-grade Voice Activity Detector (VAD), Number Detector and Language Classifier.
- Tokuda, K., Nankaku, Y., Toda, T., Zen, H., Yamagishi, J., & Oura, K. (2013). Speech synthesis based on hidden Markov models. *Proceedings of the IEEE*, 101(5), 1234-1252. <https://doi.org/10.1109/JPROC.2013.2251852>
- Torres, H. M., Gurlekian, J. A., Evin, D. A., & Cossio Mercado, C. G. (2019). Emilia: a speech corpus for Argentine Spanish text to speech synthesis. *Language Resources and Evaluation*, 53(3), 419-447.
- van den Oord, A., Dieleman, S., Zen, H., Simonyan, K., Vinyals, O., Graves, A., Kalchbrenner, N., Senior, A., & Kavukcuoglu, K. (2016). WaveNet: A Generative Model for Raw Audio. *9th ISCA Workshop on Speech Synthesis Workshop (SSW 9)*, 125.
- Van Den Oord, A., Kalchbrenner, N., & Kavukcuoglu, K. (2016). Pixel recurrent neural networks. *Proceedings of the 33rd International Conference on International Conference on Machine Learning - Volume 48*, 1747-1756.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need [NeurIPS 2017]. *Advances in Neural Information Processing Systems*.
- Wang, C., Riviere, M., Lee, A., Wu, A., Talnikar, C., Haziza, D., Williamson, M., Pino, J., & Dupoux, E. (2021). VoxPopuli: A Large-Scale Multilingual Speech Corpus for Representation Learning, Semi-Supervised Learning and Interpretation. *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, 993-1003. <https://doi.org/10.18653/v1/2021.acl-long.80>
- Xie, T., Rong, Y., Zhang, P., & Liu, L. (2024). Towards Controllable Speech Synthesis in the Era of Large Language Models: A Survey. *arXiv preprint arXiv:2412.06602*. <https://arxiv.org/abs/2412.06602>
- Yu, C., Lu, H., Yuan, N., & Hu, C. (2020). DurlAN: Duration Informed Attention Network for Multimodal Synthesis. *Interspeech 2020*, 2027-2031. <https://doi.org/10.21437/Interspeech.2020-1848>

Yu, J., Chen, H., Bian, Y., Li, X., Luo, Y., Tian, J., Liu, M., Jiang, J., & Wang, S. (2024). Auto-Prep: An Automatic Preprocessing Framework for In-The-Wild Speech Data. *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 1136-1140. <https://doi.org/10.1109/ICASSP48485.2024.10447759>

ANEXO I

COMPARACIÓN ENTRE TODAS LAS MÉTRICAS INDIVIDUALES

Comparación para métrica de calidad de señal




Figura 18. Comparación entre PESQ y horas del dataset para diferentes variantes con DNSMOS.




Figura 19. Comparación entre SI-SDR y horas del dataset para diferentes variantes con DNSMOS.




Figura 20. Comparación entre SNR y horas del dataset para diferentes variantes con NISQA.

Comparación para métrica de condiciones acústicas

COMPARACIÓN ENTRE TODAS LAS MÉTRICAS COMPUESTAS




Figura 21. Comparación entre T30 y horas del dataset para diferentes variantes con NISQA.




Figura 22. Comparación entre C50 y horas del dataset para diferentes variantes con DNSMOS.

FALTA: Ver si vale la pena poner todo esto o con lo que está alcanza.

METRICAS COMPARACIÓN ENTRE DATASET ITW VS PROFESIONAL




Figura 23. Comparación entre F0-std y PESQ del dataset para diferentes variantes con DNSMOS.




Figura 24. Comparación entre SI-SDR de los datasets ITW y Profesional.




Figura 25. Comparación entre SNR de los datasets ITW y Profesional.




Figura 26. Comparación entre C50 de los datasets ITW y Profesional.