UNTREF UNIVERSIDAD NACIONAL DE TRES DE FEBRERO

INGENIERÍA EN SONIDO

Evaluación de cadenas de procesamientos en la creación de conjuntos de datos del habla

Tesis final presentada para obtener el título de Ingeniero de Sonido de la Universidad Nacional de Tres de Febrero (UNTREF)

TESISTA: Matías Di Bernardo (42.229.438)
TUTOR/A: (Ing.) Guillermo Marzik
COTUTOR/A: (Lic.) Gala Lucía Gonzalez Barrios

Fecha de defensa: Septiembre 2026 | Caseros, Buenos Aires, Argentina

AGRADECIMIENTOS

En primer lugar, quiero agradecer a mi familia por su apoyo incondicional y por brindarme la confianza y el aliento necesarios para poder terminar la carrera. A mis padres, Diego Di Bernardo y Sandra Gabbiani, por su amor, paciencia y comprensión durante todo este proceso. A mi hermano, Ramiro Di Bernardo, por su compañía y apoyo constante.

Quisiera expresar mi gratitud a mi tutor, el Ing. Guillermo Marzik, por su invaluable guía en esta tesis, así como por facilitar los recursos necesarios para su realización. Su experiencia y sus conocimientos han sido fundamentales para el éxito de este trabajo.

También agradezco a la Lic. Gala Lucía Gonzalez Barrios por fomentar un ambiente de aprendizaje positivo y por su constante disposición para compartir su experiencia en el área de investigación. A ella le debo también mi participación en el grupo de investigación Intercambios Transorgánicos (IT), marco en el cual se inscribe esta tesis. En este espacio encontré el lugar ideal para potenciar mis habilidades e indagar en los temas que me apasionan, por lo cual le estoy eternamente agradecido.

Todos los integrantes con los que compartí mis años en IT aportaron enormemente a mi formación y mi crecimiento académico. Especialmente Emmanuel Misley, Ignacio Correa, Simón Mellino y Mateo García Iacovelli, con quienes compartí gran parte de esta etapa y cuyo trabajo fue fundamental para el desarrollo de esta tesis.

Extiendo mi agradecimiento a mis compañeros de la carrera de Ingeniería de Sonido de la UNTREF, quienes compartieron conmigo incontables horas de estudio, trabajos prácticos, mediciones, sesiones en la biblioteca, asados, charlas, y más. Un agradecimiento muy especial a la "*Liga de la Acústica*", cuya amistad me llevaré para toda la vida.

Hago extensivo este reconocimiento a todo el cuerpo docente de la carrera. Su dedicación, esfuerzo y transmisión de conocimientos han sido pilares en mi formación académica y profesional, permitiéndome llevar adelante esta investigación de manera satisfactoria.

Por último, en un contexto donde se cuestiona el valor de las universidades públicas, quiero reivindicar y agradecer a la Universidad Nacional de Tres de Febrero (UNTREF), a su Rector el Lic. Martín Kaufmann, así como a todo el personal docente y no docente. Asimismo, quiero destacar al coordinador, el Ing. Alejandro Bidondo, por su visión y dedicación en la creación de esta hermosa carrera.

DEDICATORIA

A la rebeldía del pensamiento,

único refugio de lo verdadero.

ÍNDICE DE CONTENIDOS

RESUMEN . . . . . **xi**

ABSTRACT . . . . . **xii**

1 INTRODUCCIÓN **1**

1.1 FUNDAMENTACIÓN 1

1.2 OBJETIVOS 3

1.2.1 Objetivo general 3

1.2.2 Objetivos específicos 3

1.3 ESTRUCTURA DE LA INVESTIGACIÓN 4

2 MARCO TEÓRICO **6**

2.1 DESCRIPTORES DE CALIDAD DE AUDIO 6

2.1.1 Métricas de degradación de la señal 6

2.1.2 Métricas de entorno 8

2.1.3 Métricas del habla 9

2.2 TEXT-TO-SPEECH (TTS) 9

2.3 REDES NEURONALES 10

2.4 INTELIGENCIA ARTIFICIAL GENERATIVA 11

2.5 MODELOS DE DIFUSIÓN 12

3 ESTADO DEL ARTE **13**

3.1 MODELOS DE TTS 13

3.1.1 Modelos Autoregresivos 13

3.1.2 Modelos No Autoregresivos y Paralelos 14

3.1.3 Modelos basados en Difusión y Flow Matching 14

3.2 CADENAS DE PRE PROCESAMIENTO 15

3.3 CONJUNTOS DE DATOS DEL HABLA EN ESPAÑOL 16

4 DESARROLLO **18**

4.1 RECOPILACIÓN DE BASES DE DATOS 18

4.1.1 Datos *in-the-wild* 18

4.1.2 Datos profesionales 18

4.2 DESARROLLO DE LA CADENA DE PRE PROCESAMIENTO 19
4.2.1 Diferentes esquemas de procesamiento 20
4.3 EVALUACIÓN DE LOS CONJUNTOS DE DATOS 22
4.3.1 Reducción del corpus 23
4.3.2 Calidad de la grabación 24
4.3.3 Condiciones acústicas 25
4.3.4 Diferencias del habla 26
4.3.5 Métrica conjunta 26
4.4 ENTRENAMIENTO DEL MODELO DE ESTIMACIÓN DE DENSIDAD 27
4.4.1 Tratamiento de valores extremos y agregación 28
4.4.2 Configuración del modelo e hiperparámetros 29
4.5 MODELO DE TTS ZERO-SHOT 29

5 RESULTADOS Y ANÁLISIS 32
5.1 RESULTADOS DE LAS DIFERENTES VARIANTES DE LA CADENA 32
5.1.1 Ejemplo de cálculo 32
5.1.2 Métricas separadas 33
5.1.3 Métricas compuestas 35
5.1.4 Optimización de la cadena de procesamiento 36
5.1.5 Análisis del peso de cada métrica 37
5.2 COMPARACIÓN ENTRE CONJUNTOS DE DATOS 38
5.2.1 Dataset profesional vs procesado 38
5.3 COMPARACIÓN POR ESTIMACIÓN DE DENSIDAD 41
5.4 COMPARACIÓN ENTRE MÉTRICAS OBJETIVAS Y ESTIMACIÓN DE DENSIDAD . 44
5.4.1 Conclusión del Análisis Cruzado 45
5.5 EVALUACIÓN EXPLORATORIA DE TTS ZERO-SHOT 47
5.5.1 Relación con las Métricas Objetivas (TOT) 47
5.5.2 Relación con la Estimación de Densidad (Log-Likelihood) 48
5.5.3 Discusión Final 49

6 CONCLUSIONES 51

7 LÍNEAS FUTURAS DE INVESTIGACIÓN 53

BIBLIOGRAFÍA **55**

ANEXO I: Comparación métricas individuales **62**

ANEXO II: Comparación métricas compuestas **64**

ANEXO III: Comparación entre dataset ITW vs Profesional **64**

Índice de Figuras

Figura 1. Diagrama de flujo del proceso completo para generar el dataset. 21
Figura 2. Resultado de MOS por cantidad de segmentos del dataset original para los 2 modelos a comparar. 22
Figura 3. Variantes propuestas para evaluar diferentes algoritmos y parámetros de la cadena de procesamientos. 23
Figura 4. Comparación entre PESQ y cantidad de horas de diferentes variantes con NISQA. 33
Figura 5. Comparación entre T30 y cantidad de horas de diferentes variantes con DNS MOS. 34
Figura 6. Comparación entre F0-std y PESQ para diferentes variantes con DNS MOS. 35
Figura 7. Comparación entre reducción de datos y calidad de señal para diferentes variantes con Nisqa. 36
Figura 8. Comparación entre calidad de señal y condiciones acústicas para diferentes variantes con DNSMOS. 36
Figura 9. Diferencias del valor de PESQ promedio según diferentes conjuntos de datos. 39
Figura 10. Diferencias del valor de T30 promedio según diferentes conjuntos de datos. 40
Figura 11. Diferencias del valor de F0 promedio según diferentes conjuntos de datos. 40
Figura 12. Función de pérdida en función de los audios evaluados durante el entrenamiento del modelo de difusión. 41
Figura 13. Distribución filtrada de la verosimilitud para tres configuraciones de denoising. 43
Figura 14. Ejemplo del mismo audio procesado con diferentes algoritmos de denoising. 45
Figura 15. Relación entre la media de likelihood y las métricas de calidad de señal (CS) y condiciones acústicas (CA). El color indica el algoritmo de denoising, la forma distingue CS (círculo, eje izquierdo) de CA (cuadrado, eje derecho) y las etiquetas indican la métrica acústica y su umbral. 46
Figura 16. Relación entre la métrica objetiva total (TOT) y la calidad subjetiva sintetizada (MOS). 47

Figura 17.Medias de likelihood y MOS emparejadas por configuración para seis configuraciones coincidentes. 49
Figura 18.Comparación entre PESQ y horas del dataset para diferentes variantes con DNSMOS. 62
Figura 19.Comparación entre SI-SDR y horas del dataset para diferentes variantes con DNSMOS. 62
Figura 20.Comparación entre SNR y horas del dataset para diferentes variantes con NISQA. 62
Figura 21.Comparación entre T30 y horas del dataset para diferentes variantes con NISQA. 63
Figura 22.Comparación entre C50 y horas del dataset para diferentes variantes con DNSMOS. 63
Figura 23.Comparación entre F0-std y PESQ del dataset para diferentes variantes con DNSMOS. 63
Figura 24.Comparación entre RD y CA del dataset para diferentes variantes con DNSMOS. 64
Figura 25.Comparación entre RD y DH del dataset para diferentes variantes con DNSMOS. 64
Figura 26.Comparación entre SI-SDR de los datasets ITW y Profesional. 64
Figura 27.Comparación entre SNR de los datasets ITW y Profesional. 65
Figura 28.Comparación entre C50 de los datasets ITW y Profesional. 65

Índice de Tablas

Tabla 1. Comparación entre diferentes etapas en una cadena de pre procesamiento para TTS. 16
Tabla 2. Resumen de conjuntos de datos en español. 17
Tabla 3. Tiempo y métricas de control del entrenamiento del modelo de difusión. 29
Tabla 4. Mejora SNR por métrica de calidad y algoritmo de denoising. 32
Tabla 5. Métricas compuestas y total para todas las configuraciones. 37
Tabla 6. Desvío estándar y máxima desviación para cada métrica compuesta respecto a las diferentes versiones de cadena bajo evaluación. 38
Tabla 7. Especificaciones técnicas e hiperparámetros del entrenamiento del modelo de difusión. 41
Tabla 8. Comparación entre las medias de likelihood y la métrica objetiva total (TOT), ordenadas por verosimilitud. 42

RESUMEN

Los modelos de texto a voz dependen de datos de entrenamiento abundantes y de calidad, un desafío para idiomas y variedades dialectales como el español de Argentina. Los conjuntos de datos de fuentes heterogéneas son una alternativa, pero requieren preprocesamiento. Este trabajo evalúa el efecto de distintas cadenas de procesamiento mediante medidas objetivas y subjetivas, y estudia su impacto en datos destinados al entrenamiento de TTS.

Se desarrolló una cadena modular y reproducible con detección de voz, realce y filtrado perceptual, y se compararon DeepFilterNet y Demucs, NISQA y DNSMOS, y distintos umbrales. La métrica compuesta considera reducción del corpus, calidad y condiciones acústicas, y preservación de características del hablante. Para todos los resultados de likelihood se excluyeron recortes individuales con log-likelihood mayor que 4.0. Además, se entrenó un modelo de densidad por difusión con un corpus profesional y se evaluó de forma exploratoria la clonación de voz con modelos *zero-shot*.

Los criterios dieron ordenamientos distintos: Demucs con DNSMOS 2.7 obtuvo el mejor resultado acústico, mientras que DeepFilterNet presentó las mayores medias de likelihood (2.37 y 2.30). Exploratoriamente, esto sugiere que una supresión de ruido más agresiva favorece las métricas acústicas y un procesamiento conservador preserva estructuras valoradas por el modelo de densidad; ocho configuraciones no bastan para confirmar ni generalizar esta interpretación. En TTS se compararon medias de seis configuraciones coincidentes, y la asociación entre likelihood y MOS fue descriptivamente más marcada para F5 que para Qwen, lo que apunta a una posible utilidad aplicada. Estos resultados no validan las métricas como predictores de calidad. Se necesitan mejores descriptores para estudiar cómo interactúan las etapas de procesamiento, en particular las basadas en redes neuronales profundas.

Palabras clave: síntesis de voz, conjuntos de datos del habla, preprocesamiento de audio, lenguajes de bajos recursos

ABSTRACT

Text-to-speech systems require abundant, high-quality training data, which is a challenge for languages and dialectal varieties such as Argentine Spanish. Datasets collected from heterogeneous sources offer an alternative but require preprocessing. This study evaluates the effects of different processing pipelines using objective and subjective measures and examines their impact on data intended for TTS training.

A modular, reproducible pipeline combining voice activity detection, signal enhancement, and perceptual filtering was developed. DeepFilterNet and Demucs, NISQA and DNSMOS, and different thresholds were compared. The composite metric considers corpus reduction, signal quality and acoustic conditions, and preservation of speaker characteristics. All likelihood results exclude individual crops with log-likelihood values greater than 4.0. In addition, a diffusion-based density model was trained on a professional reference corpus, and voice cloning with zero-shot synthesis models was evaluated exploratorily.

The criteria produced different rankings: Demucs with DNSMOS 2.7 achieved the best acoustic result, while DeepFilterNet had the highest mean likelihood values (2.37 and 2.30). Exploratorily, this suggests that more aggressive noise suppression favors the acoustic metrics, whereas conservative processing preserves structures valued by the density model; eight configurations are insufficient to confirm or generalize this interpretation. For TTS, means from six matched configurations were compared. The association between likelihood and MOS was descriptively stronger for F5 than for Qwen, suggesting possible practical utility. These results do not validate the metrics as predictors of quality. Better descriptors are needed to study interactions among processing stages, particularly those based on deep neural networks.

Keywords: speech synthesis, speech datasets, audio preprocessing, low-resource languages

1. INTRODUCCIÓN

1.1. FUNDAMENTACIÓN

Los modelos de texto a habla (TTS, por sus siglas en inglés) experimentaron un avance tecnológico exponencial en los últimos años: mediante redes neuronales profundas se alcanzaron resultados de elevada calidad sonora e inteligibilidad (Tan et al., 2021). No obstante, la fuerte dependencia de estos sistemas respecto a los datos de entrenamiento dificulta la obtención de voces sintetizadas con naturalidad para la gran diversidad de hablantes, dado que las decisiones de diseño en la industria suelen imponer un estándar lingüístico hegemónico sobre qué voces merecen ser representadas (Markl, 2023). Esta dificultad es especialmente notable en regiones con escasez de conjuntos de datos extensos, como ocurre en distintas provincias de Argentina.

En este marco, se han desarrollado sistemas de TTS en español rioplatense (Ortega Riera et al., 2023) que alcanzan resultados aceptables, pero se enfrentan a la limitada cantidad de datos específicos de los diferentes dialectos de Argentina, lo cual impide lograr sistemas más robustos y naturales. Tradicionalmente, la generación de bases de datos para entrenar modelos de TTS se orienta a recopilar grandes volúmenes de grabaciones de alta calidad (realizadas en estudios profesionales) y a emplear hablantes con características específicas (por ejemplo, locutores), lo que da lugar a un corpus homogéneo en sus características acústicas y prosódicas, pero que genera numerosos sesgos y falta de representatividad cuando se quiere adaptar dichos sistemas a variantes dialectales que no están contempladas en la recolección de datos inicial (Koenecke et al., 2020). El modelo de recolección de datos tradicional fue importante para la convergencia de modelos basados en aprendizaje profundo, pero representa una barrera de entrada para numerosos idiomas y variedades dialectales que no disponen de recursos para producir dichos datasets.

La literatura en procesamiento del habla denomina “idiomas de bajos recursos” (low-resource languages) a estos casos; dentro de ellos se incluyen dialectos específicos de una lengua, como serían las variantes propias de determinadas provincias argentinas. Para entrenar modelos de TTS con mayor naturalidad se ha explorado la utilización de datos recolectados en Internet (Cooper, 2019), conformando conjuntos heterogéneos procedentes de diversas fuentes y de calidad de audio variable. Estos corpus suelen denominarse datos sal-

vajes (ITW, “in-the-wild” por sus siglas en inglés). Además, con el avance de la inteligencia artificial generativa, han surgido diferentes mejoras en la arquitecturas de los sistemas de TTS mas actuales (Xie et al., 2024), lo que hace que los conjuntos de datos ITW sean una fuente especialmente atractiva para capturar la gran diversidad del fenómeno del habla.

El principal problema de entrenar modelos de TTS con conjuntos ITW es la elevada variabilidad en la calidad de las grabaciones, lo que incide directamente en la capacidad de los modelos neuronales para aprender los patrones subyacentes y, en muchos casos, impide la convergencia hacia resultados satisfactorios. Para abordar esta limitación, recientemente se han propuesto cadenas de preprocesamiento que extraen, a partir de un gran conjunto de datos, subgrupos con mejor calidad de audio (J. Yu et al., 2024). Si bien existen distintas variantes de estas cadenas en la literatura, no se ha llevado a cabo una caracterización acústica exhaustiva de la variabilidad que generan los conjuntos resultantes tras su aplicación. La validación suele basarse en el entrenamiento de modelos TTS y en la evaluación de su convergencia; sin embargo, no se suele caracterizar toda la cadena mediante parámetros acústicos que permitan comparar diferentes implementaciones bajo criterios comunes, ni definir configuraciones óptimas según objetivos distintos (por ejemplo, maximizar la calidad del audio frente a maximizar la cantidad de horas del corpus). El impacto de la calidad de los datos en el entrenamiento de modelos de TTS ha sido profundamente estudiado (Ayllón et al., 2019), pero no se han analizado las diferencias entre los dataset ITW y los dataset profesionales mediante un análisis objetivo.

La investigación propuesta en esta tesis tiene como objetivo determinar la eficacia de estas cadenas de procesamiento mediante parámetros acústicos. Este tipo de análisis no solo facilita la iteración y la optimización de los procesos de filtrado de audios de habla, sino que también abre la posibilidad de desarrollar con mayor facilidad bases de datos para lenguajes de bajos recursos, contribuyendo así a disponer de sistemas TTS de mayor calidad para una amplia variedad de idiomas y acentos locales.

1.2. OBJETIVOS

1.2.1. Objetivo general

El objetivo de esta investigación es evaluar, con parámetros objetivos y subjetivos, el impacto de cadenas de procesamiento de conjuntos de datos *in-the-wild* para el entrenamiento de modelos de texto a voz basados en redes neuronales profundas.

1.2.2. Objetivos específicos

Los objetivos específicos son:

- Crear un dataset *in-the-wild* en español de Argentina. Recopilar datasets de voces profesionales en español (grabaciones de alta calidad realizadas por hablantes profesionales).
- Desarrollar una cadena automática de preprocesamiento modular para la generación de conjuntos de datos de habla, y procesar el conjunto de datos ITW con la cadena bajo diferentes configuraciones operativas.
- Evaluar métricas acústicas en los distintos conjuntos de datos generados y comparar dichos resultados con los obtenidos en datasets tradicionales y determinar, según criterios acústicos, cuál de los conjuntos generados puede considerarse óptimo (comparando media y desvío de los diferentes conjuntos).
- Entrenar un modelo de estimación de distribuciones y comparar la similitud entre los diferentes conjuntos en el espacio latente. Determinar el conjunto de datos óptimo según criterios de similitud basados en estimación de densidad.
- Comparar los resultados del análisis acústico con los derivados del análisis por estimación de densidad. Analizar de forma estadística la relevancia de las diferencias observadas en los distintos parámetros.
- Validar los resultados en el contexto de clonación de voz mediante modelos TTS zero-shot.

1.3. ESTRUCTURA DE LA INVESTIGACIÓN

Esta tesis corresponde a una investigación de carácter tecnológico orientada al desarrollo y evaluación de una herramienta de software para la selección automática de audios, destinada a la generación de conjuntos de datos de habla. Validar este tipo de herramientas, priorizando un bajo costo computacional y el uso de datos *in-the-wild*, es fundamental para democratizar la creación de corpus acústicos en lenguajes de bajos recursos. Al posibilitar la construcción autónoma de un dataset representativo de los diversos acentos de Argentina, se reduce la dependencia estructural frente a corporaciones tecnológicas extranjeras, las cuales históricamente han dictado los estándares de representación lingüística (Ricaurte, 2019). En este sentido, la herramienta desarrollada contribuye al avance de las tecnologías del habla en el país y sienta bases concretas hacia la soberanía tecnológica nacional, entendida aquí como la capacidad inalienable de las instituciones locales para desarrollar, controlar y gestionar sus propias tecnologías de representación cultural y comunicacional.

El desarrollo de esta tesis se enmarca en el proyecto Archivoz del grupo de investigación Intercambios Transorgánicos, fundado y liderado por la Lic. Gala Lucia Gonzalez Barrios, y radicado desde el 2015 en el Muntref Centro de Arte y Ciencia. Dentro del grupo de investigación, comenzó en 2019 el proyecto Archivoz, que tiene como objetivo elaborar preguntas y propuestas para el desarrollo de tecnologías del habla, principalmente enfocado en pacientes que atravesaron una laringectomía como parte de el tratamiento de supervivencia al cáncer de laringe. La laringectomía consta de la remoción de la laringe, y con esta las cuerdas vocales. Las personas laringectomizadas, entonces, pueden tener la capacidad motora y cognitiva para la fonación pero al carecer de cuerdas vocales no se puede generar el sonido de la voz laríngea (Gonzalez Barrios, 2021).

Una de las propuestas de esta investigación es el desarrollo de sistemas de TTS que permitan a los pacientes recuperar la capacidad de comunicarse mediante la síntesis de su propia voz, utilizando para ello modelos de clonación de voz y técnicas de aprendizaje profundo.

Organización del documento:

En el capítulo 2 se presenta el marco teórico: se exponen los fundamentos de la inteligencia artificial y se describen las arquitecturas aplicables a los modelos modernos de TTS,

incluyendo tanto modelos secuenciales como modelos generativos. Además, se detallan las métricas acústicas seleccionadas para la caracterización de los datos.

El capítulo 3 ofrece una recapitulación de los modelos de TTS actuales y de las cadenas de procesamiento que han surgido en los últimos años.

En el capítulo 4 se describen con detalle las etapas del desarrollo: recopilación de datos, diseño y construcción del software, metodología de comparación propuesta y el entrenamiento de modelos mediante redes neuronales.

El capítulo 5 presenta los resultados y el análisis de los experimentos descritos en la sección anterior.

Finalmente, el capítulo 6 expone las conclusiones generales de la tesis, y el capítulo 7 propone líneas de investigación futuras y posibles aplicaciones no exploradas en el presente trabajo.

2. MARCO TEÓRICO

2.1. DESCRIPTORES DE CALIDAD DE AUDIO

2.1.1. Métricas de degradación de la señal

Las métricas de degradación de la señal cuantifican, a nivel objetivo, la diferencia entre una señal de referencia (habitualmente la señal limpia o de alta calidad) y una señal procesada o degradada (por ejemplo, una señal comprimida o con ruido de fondo). A continuación se describen las más empleadas en evaluación de voz y TTS.

La métrica de Evaluación Perceptual de calidad del habla, (PESQ por sus siglas en inglés) es un índice objetivo diseñado para predecir la calidad percibida de la voz en telefonía y sistemas de comunicación (ITU-T, 2001). Compara la señal de referencia y la señal degradada mediante un modelo perceptual que incluye etapas de alineamiento temporal, modelado perceptual y mapeo a una escala MOS-LQO (Mean Opinion Score — Listening Quality Objective). PESQ fue normalizado originalmente como la recomendación ITU-T P.862 y se utiliza ampliamente para evaluación de códecs y transmisiones telefónicas.

Esta métrica tiene la limitación del rango de frecuencia que evalúa (va entre 200 Hz a 3500 Hz), para un análisis mas completo surge la métrica denominada POLQA, que es la tercera generación de métricas ITU para evaluación de calidad de voz general ITU-T P.863 (ITU-T, 2018). Mejora y extiende PESQ en ancho de banda (incluye super-wideband y full-band), es más robusta frente a ciertas distorsiones modernas (ecualización, delays, codificación amplia banda) y proporciona predicciones MOS más fiables en escenarios actuales.

Para evaluar de forma objetiva la calidad de la señal de audio se tienen métricas como la Relación Señal a Ruido (SNR por sus siglas en inglés) y la Relación Distorsión a Ruido de Escalado Invariante (SI-SDR por sus siglas en inglés). El SNR es la relación entre la potencia de la señal útil y la potencia del ruido de fondo, normalmente expresada en decibelios (Ecuación 1). Es una medida física simple, muy útil para caracterizar condiciones de captura o transmisión, pero su correlación con la percepción humana puede ser pobre cuando las distorsiones son no-gaussianas, no-aditivas o hay alteraciones de fase y tiempo; por ello suele utilizarse junto con métricas perceptuales.

$$\mathrm{SNR}_{\mathrm{dB}} = 10 \log_{10} \left(\frac{P_{\text{señal}}}{P_{\text{ruido}}} \right) \tag{1}$$

El SI-SDR es una versión modificada y más robusta del SDR tradicional diseñada para evitar penalizaciones por escalado de amplitud entre referencia y estimado (Le Roux et al., 2019). En la práctica, SI-SDR proyecta la señal estimada sobre la referencia (elimina la diferencia de escala) y calcula la relación señal/residuo resultante; por su formulación, es ampliamente usada en separación de fuentes y evaluación de redes de denoising o separación en el dominio temporal.

Por último, entre las métricas de calidad de señales del habla se puede incluir el STOI (inteligibilidad objetiva de tiempo corto por sus siglas en inglés), que estima inteligibilidad de habla en condiciones ruidosas mediante una medida de correlación entre segmentos de tiempo-frecuencia de la señal limpia y la señal degradada (Taal et al., 2011). Fue propuesta para predecir la inteligibilidad de señal procesada (p. ej. filtrado espectral, separación) y ha mostrado alta correlación con experimentos de inteligibilidad humana en muchos escenarios. No mide naturalidad, sino inteligibilidad.

Por su definición matemática, el cálculo de estas métricas es de carácter intrusivo, lo que significa que requieren inexcusablemente de una señal de referencia limpia (o la señal de ruido aislado, en el caso del SNR) para cuantificar la degradación mediante comparación directa. En contextos de aplicación empírica, como la curaduría de conjuntos de datos *in-the-wild*, rara vez se dispone de esta señal original inalterada.

Para sortear esta limitación práctica, han surgido métodos de estimación ciega o no intrusivos, los cuales permiten predecir la calidad de un audio analizando únicamente la señal degradada. Mientras que los estimadores ciegos tradicionales se basaban en el modelado estadístico de las características del tracto vocal y del ruido, el estado del arte actual emplea arquitecturas de aprendizaje profundo (redes convolucionales, transformers y representaciones auto-supervisadas). Estos sistemas neuronales se entrenan sobre bases de datos que si tienen referencia para aprender un mapeo directo entre las características acústicas del audio de entrada y las puntuaciones que arrojarían de manera teórica las métricas intrusivas. Ejemplos recientes y de amplio uso en la literatura incluyen marcos de estimación objetiva como *Torchaudio-Squim* (Kumar et al., 2023), diseñado para predecir valores de

PESQ y SI-SDR sin referencia, así como modelos orientados a predecir la calidad perceptual subjetiva (MOS) como NISQA (Mittag et al., 2021) y DNSMOS (Reddy et al., 2021).

Hay que destacar, que ninguna métrica captura todos los aspectos perceptuales simultáneamente (naturalidad, inteligibilidad, artefactos, coloración). En evaluación de TTS y sistemas de procesamiento de voz es habitual combinar métricas intrusivas (PESQ/POLQA, SI-SDR, MCD) con medidas de inteligibilidad (STOI) y, cuando es posible, pruebas subjetivas (MOS).

2.1.2. Métricas de entorno

Las métricas de entorno (o de acústica de salas) describen propiedades de la sala o del campo acústico que afectan la percepción de la voz y la música.

Uno de los parámetros principales, es el tiempo de reverberación T, que se define clásicamente como el tiempo que tarda el nivel sonoro en decaer 60 dB tras cortar la fuente (Sabine). Por razones prácticas se calculan estimadores como T_{30} (pendiente del decaimiento entre -5 dB y -35 dB extrapolada a -60 dB) o T_{20} (entre -5 y -25 dB). El T_{30} es de uso corriente en caracterización objetiva de salas y está normalizado por ISO 3382 («ISO 3382-2:2008 Acoustics – Measurement of room acoustic parameters – Part 2: Reverberation time in ordinary rooms», 2008). Los valores de T afectan inteligibilidad, claridad y sensación de espacialidad acústica.

Otros parámetros que se usan para evaluar la percepción de audios en auditorios es la claridad C_{50} (para voz) y C_{80} (para música), ya que miden la relación energía temprana/energía tardía. Este parámetro se define matemáticamente como:

$$C_{50} = 10 \log_{10} \frac{\int_0^{50,\text{ms}} p^2(t)dt}{\int_{50,\text{ms}}^{\infty} p^2(t)dt} \tag{2}$$

donde $p(t)$ es la respuesta al impulso en la posición de escucha. Valores altos de C_{50} indican mayor proporción de energía temprana (mejor inteligibilidad para voz).

El D_{50} (a menudo expresado en porcentaje) es la fracción de energía que llega en los primeros 50 ms respecto a la energía total; es otra forma de cuantificar claridad/inteligibilidad para voz (relacionado con C_{50}). Se calcula a partir de la respuesta al impulso y es relevante

para evaluación de recintos educativos, salas de conferencia y estudios de grabación.

2.1.3. Métricas del habla

Las métricas del habla describen propiedades prosódicas y espectrales de la voz que influyen en la naturalidad y en la identificación del hablante. Dentro de esta categoría, una de las métricas principales es la frecuencia fundamental de la voz F_0, cuyo valor representa la frecuencia de vibración principal de las cuerdas vocales de los diferentes hablantes (Bäckström et al., 2022) y constituye la base de la percepción del *pitch*. Se estima mediante algoritmos de detección de pitch (autocorrelación, cepstrum, algoritmos basados en modelos probabilísticos) y se usa para análisis prosódico, control de entonación en TTS y evaluación de naturalidad. La distribución estadística de F_0, su variación temporal (contorno), y su relación con la energía son indicadores usados tanto en evaluación objetiva como perceptual.

Otra métrica muy utilizada en el análisis de sistemas de TTS es la distorsión media cepstral (MCD por sus siglas en inglés). MCD (a veces llamado Mel-Cepstral Distance) cuantifica la distancia entre dos secuencias de coeficientes mel-cepstrales (por ejemplo, señal natural vs. señal sintetizada) y se expresa en dB (Kominek et al., 2008). La expresión matemática de esta métrica para un cuadro de tiempo t se presenta en la Ecuación 3:

$$\text{MCD} = \frac{10}{\ln 10}\sqrt{2\sum_{k=1}^{K}(y_{t,k} - \hat{y}_{t,k})^2} \tag{3}$$

donde $y_{t,k}$ y $\hat{y}_{t,k}$ representan el k-ésimo coeficiente mel-cepstral de la señal de referencia y de la señal evaluada respectivamente, y K es el número total de coeficientes considerados. Se calcula comúnmente como una raíz cuadrada de la suma de cuadrados normalizada entre vectores de coeficientes y es ampliamente utilizada para evaluar la calidad espectral en TTS y vocoders; sin embargo, su correlación con la calidad percibida no es perfecta y debe complementarse con pruebas perceptuales.

2.2. TEXT-TO-SPEECH (TTS)

Los sistemas de text-to-speech (TTS) convierten texto en señal de voz (Tan et al., 2021). Históricamente pueden agruparse en tres grandes enfoques:

- Enfoque concatenativo: Ensamblan fragmentos pre grabados de voz (unidades) para formar enunciados. Ofrecen alta naturalidad cuando el corpus es homogéneo y extenso, pero presentan baja flexibilidad y alto coste de recopilación (Hunt y Black, 1996).
- Enfoque paramétrico: Modelan parámetros acústicos (por ejemplo, mediante cadenas ocultas de Markov) y luego sintetizan la señal a partir de los parámetros predichos. Tienen mayor flexibilidad y requieren un menor tamaño de corpus, aunque su calidad perceptual suele ser inferior a la voz grabada (Tokuda et al., 2013).
- Enfoque neuronal: Emplean redes neuronales para mapear texto a representaciones intermedias (p. ej. mel-espectrogramas) y vocoders neuronales para generar la forma de onda. Dentro de este grupo hay variantes auto regresivas (mayor fidelidad pero más lentas) y no-autoregresivas (más rápidas y escalables). Los sistemas actuales de mayor calidad combinan un modelo de predicción de espectrogramas, como pueden ser Tacotron2 (Shen et al., 2018b) o FastSpeech (Ren et al., 2021a), con un vocoder neural, como pueden ser WaveNet (van den Oord et al., 2016) o HiFi-GAN (J. Kong et al., 2020).

En el presente trabajo se explora las opciones de síntesis neuronal, que han demostrado un salto cualitativo en calidad y flexibilidad, aunque requieren grandes cantidades de datos y potencia computacional para entrenamiento. La evolución de estos sistemas se desarrolla en la Sección 3.1.

2.3. REDES NEURONALES

Las redes neuronales son modelos parametrizados por capas de neuronas artificiales que aprenden funciones complejas a partir de datos (Goodfellow et al., 2016). En TTS y procesamiento de audio se emplean arquitecturas diversas: redes convolucionales (CNN) para extracción de características tiempo-frecuencia; redes recurrentes y Transformers (Vaswani et al., 2017) para modelado secuencial; y mecanismos de *attention* en tareas seq2seq.

Las redes permiten aprender mapeos directos (texto $\rightarrow$ espectrograma) y modelos generativos (vocoder, modelos de densidad). Su flexibilidad explica el salto cualitativo en TTS, pero también la fuerte dependencia de la cantidad y calidad de los datos de entrenamiento.

2.4. INTELIGENCIA ARTIFICIAL GENERATIVA

La inteligencia artificial generativa (IAG) comprende técnicas cuyo objetivo es modelar la distribución de datos para generar muestras nuevas que sean plausibles, ya sea para imágenes, texto, o audio. La generación de estas muestras puede ser condicionadas o no por información adicional (*prompts*). Los principales paradigmas contemporáneos son:

- Modelos autoregresivos: modelan la probabilidad conjunta como producto de condicionales (p. ej. PixelRNN en imágenes (Van Den Oord et al., 2016) o WaveNet en audio (van den Oord et al., 2016)). Son conceptualmente simples y producen alta calidad pero pueden ser lentos en inferencia por su naturaleza secuencial.

- VAE (Variational Autoencoders): modelos latentes que optimizan una cota variacional de la verosimilitud. Buen control del espacio latente y entrenamiento estable, pero en general ofrecen menor fidelidad en muestras crudas (Kingma y Welling, 2013).

- GANs (Generative Adversarial Networks): enfrenta dos redes neuronales, un generador vs un discriminador que compiten como adversarios, donde una red se encarga de generar muestras, y la red adversaria busca identificar si las muestras generadas son falsas o no. Esta arquitectura genera muestras de alta fidelidad rápida y eficientemente (Goodfellow et al., 2020), aunque el entrenamiento puede ser inestable. Este tipo de modelo se ha aplicado con éxito a vocoders y síntesis auditiva (ej. HiFi-GAN por J. Kong et al., 2020).

- Modelos basados en score / difusión: incluyen los modelos de difusión y score-matching (DDPM, score-based models) que adicionan ruido progresivamente a datos reales y aprenden a invertir ese proceso para muestrear (Ho et al., 2020). Actualmente han mostrado resultados competitivos o superiores en calidad de muestras y estabilidad de entrenamiento en imagen y audio (ej. DiffWave por Z. Kong et al., 2021).

En audio/TTS, cada paradigma tiene ventajas: los autoregresivos (WaveNet) alcanzaron alta naturalidad; los GANs (HiFi-GAN) ofrecen inferencia rápida y alta fidelidad; y los modelos de difusión (DiffWave) combinan calidad con mayor estabilidad y flexibilidad condicional. La elección depende de trade-offs entre calidad, velocidad y control.

2.5. MODELOS DE DIFUSIÓN

Los modelos de difusión son una clase de generadores probabilísticos basados en procesos estocásticos de adición y eliminación de ruido. Su formulación moderna se fundamenta en dos ideas principales: (1) definir un proceso directo (forward) que corrompe los datos añadiendo ruido gaussiano progresivamente hasta obtener ruido casi puro; (2) aprender el proceso inverso (reverse) —un modelo condicional que predice pasos de denoising— para transformar ruido en datos sintéticos.

La definición matemática plantea una muestra de datos x_0, donde el proceso directo añade ruido en (T) pasos:

$$q(x_t \mid x_{t-1}) = \mathcal{N}(x_t; \sqrt{1-\beta_t}, x_{t-1}, \beta_t), \tag{4}$$

con una escala de varianzas (β_t). El proceso inverso se parametriza como:

$$p_\theta(x_{t-1} \mid x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t)), \tag{5}$$

y se entrena minimizando una variación de la evidencia (ELBO) o una pérdida de denoising equivalente. El trabajo de Ho et al., 2020 formaliza esta familia (DDPM) y conecta la aproximación por denoising con score-matching (Song et al., 2021).

Los modelos de difusión proporcionan calidad competitiva sin entrenamiento adversario y permiten control condicional (por ejemplo, condicionamiento en mel-espectrogramas para vocoders). La principal limitación práctica es el costo de muestreo (múltiples pasos), aunque variantes (DDIM, sampling acelerado, distillation) reducen el número de pasos sin pérdida sustancial de calidad.

3. ESTADO DEL ARTE

3.1. MODELOS DE TTS

El desarrollo de sistemas de síntesis de voz basados en redes neuronales ha experimentado una rápida evolución, transitando desde modelos secuenciales complejos hacia arquitecturas generativas probabilísticas. A continuación, se describe la progresión tecnológica de estos sistemas, clasificados según su paradigma de generación.

3.1.1. Modelos Autoregresivos

La primera generación de modelos neuronales de alta fidelidad se basó en el paradigma autoregresivo, donde la generación de cada segmentos del espectrograma de mel depende del segmento generado anteriormente.

El modelo más representativo de esta etapa es Tacotron 2 (Shen et al., 2018a). Esta arquitectura combina una red recurrente (LSTM) con un mecanismo de atención para mapear la secuencia de caracteres a un espectrograma de Mel, el cual es posteriormente convertido a forma de onda mediante un vocoder (originalmente WaveNet). Si bien Tacotron 2 estableció un nuevo estándar de naturalidad, su mecanismo de atención es propenso a errores de alineación, resultando en problemas de robustez como la repetición o la omisión de palabras.

Para mitigar los fallos de robustez del mecanismo de atención, surgió DurIAN (Duration Informed Attention Network) (C. Yu et al., 2020). Este modelo reemplaza el mecanismo de atención tradicional por un modelo de alineación que utiliza la duración de los fonemas (predicha o extraída mediante alineamiento forzado). Aunque DurIAN sigue generando los cuadros acústicos de manera autoregresiva, la incorporación de información explicita de duración mejora significativamente la estabilidad de la síntesis, eliminando gran parte de los artefactos presentes en Tacotron 2.

3.1.2. Modelos No Autoregresivos y Paralelos

La principal limitación de los modelos autoregresivos es su lenta velocidad de inferencia, dado que la generación no puede paralelizarse. Para resolver esto, surgieron arquitecturas capaces de generar el espectrograma completo en un solo paso.

FastSpeech 2 (Ren et al., 2021b) marcó un hito en esta categoría al proponer una red totalmente "*feed-forward*", basada en bloques de transformers. A diferencia de sus predecesores, FastSpeech 2 entrena predictores de varianza explícitos (duración, energía y frecuencia fundamental F_0) directamente sobre la entrada de texto. Esto no solo permite una inferencia extremadamente rápida (paralela), sino que también otorga un mayor control sobre la prosodia y una mayor robustez frente a datos ruidosos.

Posteriormente, el modelo VITS (Variational Inference with adversarial learning for end-to-end Text-to-Speech) (J. Kim et al., 2021) propuso un enfoque unificado. VITS combina flujos de normalización (Normalizing Flows) y una arquitectura de Autoencoder Variacional (VAE) con entrenamiento adversario (GAN). A diferencia de los sistemas en dos etapas (modelo acústico + vocoder), VITS es un sistema completo que genera directamente la forma de onda, logrando una calidad de estado del arte con una naturalidad superior a los modelos de dos etapas previos.

3.1.3. Modelos basados en Difusión y Flow Matching

Con el auge de la Inteligencia Artificial Generativa, los modelos basados en difusión probabilística (DDPM) y, más recientemente, el paradigma de *Flow Matching*, han demostrado capacidades superiores para modelar la compleja distribución de la voz humana. Estas arquitecturas se destacan especialmente en tareas de adaptación de hablante y de síntesis *zero-shot*, es decir, la capacidad del modelo para generar la voz de un locutor inédito a partir de una referencia acústica sumamente breve (generalmente de unos pocos segundos), sin requerir ningún tipo de reentrenamiento o ajuste fino (*fine-tuning*) de sus parámetros.

Diff-TTS (Jeong et al., 2021) fue uno de los pioneros en aplicar modelos de difusión probabilística para la estimación de espectrogramas de Mel. Este modelo formula la síntesis como un proceso de refinamiento iterativo, transformando ruido gaussiano en una señal

de voz condicionada por el texto. Si bien la calidad es alta, el costo computacional de los múltiples pasos de muestreo es elevado.

Para abordar la latencia inherente a la difusión, Grad-TTS (Popov et al., 2021) introdujo un marco basado en ecuaciones diferenciales estocásticas (SDE) con un alineamiento monótono estricto, permitiendo un trade-off flexible entre velocidad y calidad. En la misma línea de optimización, ProDiff (Huang et al., 2022) emplea técnicas de destilación progresiva (progressive distillation) para reducir drásticamente el número de pasos de muestreo requeridos, permitiendo síntesis de alta calidad en tan solo 2 o 4 pasos de difusión.

Finalmente, el estado del arte ha convergido hacia el paradigma de *Flow Matching*, una generalización de los modelos de difusión que aprende campos vectoriales para transformar distribuciones simples en distribuciones de datos complejas mediante trayectorias más rectas y eficientes. El modelo F5-TTS (Chen et al., 2024) representa la culminación actual de esta tendencia. F5-TTS utiliza una arquitectura basada en *Diffusion Transformers* (DiT) con un esquema de entrenamiento *Flow Matching*. A diferencia de los modelos anteriores que requieren alineamientos complejos o predictores de duración explícitos, F5-TTS entrena con un sistema de máscaras binarias (bloquea segmentos aleatorios del audio y deja que el modelo aprenda a predecir ese segmento), permitiendo capacidades de clonación de voz *zero-shot* y control de emociones con una naturalidad sin precedentes y una velocidad de inferencia competitiva gracias a la eficiencia del Flow Matching.

3.2. CADENAS DE PRE PROCESAMIENTO

En los últimos años se han desarrollado numerosas cadena de procesamiento, todas con diferentes configuraciones y particularidades. El objetivo de estas cadenas de preprocesamiento es mejorar, filtrar y estandarizar un conjunto de datos de audios grandes proveniente de diferentes fuentes (dataset ITW). Como el procesamiento implica diferentes etapas, y varía según las necesidades de los modelos a entrenar, han surgido muchas propuestas de implementación, todas con sus respectivas particularidades. Para ilustrar las diferencias en las diferentes etapas se conforma la Tabla 1, donde se comparan diferencias de modelos, configuraciones y criterios en el desarrollo de cadena de pre procesamiento automático para la creación de datasets.

Tabla 1. Comparación entre diferentes etapas en una cadena de pre procesamiento para TTS.

Nombre del estudio	Algoritmo de Denoising	Voice Activity Detection	Estimador MOS y umbral	Sistema TTS evaluados
AutoPrep - (J. Yu et al., 2024)	BSRRN	TDNN	DNS MOS: 2.4	DurIAN TTS
Text-to-Speech in the wild - (Jung et al., 2025)	Demucs	Whisper X Pipeline	Nisqa: 3	GradTTS y VITS
WeNeetSpeech - (Ma et al., 2024)	MBTFNet	Rezamblyzer	DNS MOS: 3.6, 3.8, 4	VALL-E y NS2
SCEP - (Sabra et al., 2024)	U-Net	Casual DNN	Usan SNR y PESQ	No evalúa
Muyan TTS - (Li et al., 2024)	FRCRN y VoiceFixer	No usa	Nisqa: 3.8	FireRedTTS y CozyVoice2
Emilia - (He et al., 2024)	UVR-MDX-N et Inst	Silero VAD	DNS MOS: 3	VoiceBox

Las diferencias entre las etapas planteadas en esta Tabla se explican en la Sección 4.2, donde se explica las particularidades de la implementación propia de la cadena de procesamientos. La gran discrepancia entre modelos de las diferentes implementaciones es una de las motivaciones para el desarrollo de esta tesis, con el objetivo de esclarecer el desarrollo de este tipo de procesamientos en el desarrollo de conjuntos de datos.

3.3. CONJUNTOS DE DATOS DEL HABLA EN ESPAÑOL

Es relevante mencionar la falta de conjuntos de datos del habla en español, en principal de la variante español de Argentina. En la Tabla 2 se recopilaron diferentes conjuntos de datos de habla en español, especificando la cantidad de horas y hablante, la región que lingüística que representa y el tipo. Los diferentes tipos hacen referencia a la fuente de donde fueron recopilados los datos. Además de los conjuntos profesionales e *in-the-wild* que ya fueron discutidos, se presentan dataset de tipo conversacional (de entrevistas o llamadas telefónicas) y los dataset *crowdsourced*, donde se recopilan audios de voces de voluntarios a través de internet.

Este análisis de los dataset en el estado del arte pone en evidencia la necesidad de conformar un corpus del español de Argentina, donde es fundamental extender la representatividad cultural de nuestra región, y capturar los diferentes acentos de todas las regiones del país, ya que como se ve en la recopilación, casi todo el material disponible del dialecto

Tabla 2. Resumen de conjuntos de datos en español.

Nombre dataset	Cantidad horas	Cantidad hablantes	Región dialecto	Tipo dataset
Google LREC - Guevara-Rukoz et al., 2020	8	44	Buenos Aires	Profesional
Emilia - Torres et al., 2019	4	1	Buenos Aires	Profesional
HaCASpa - Gabriel, 2011	10	50	Buenos Aires/Mendoza	Conversacional
CORdEBA - UNLP, 2014	6	25	Buenos Aires	Conversacional
Common Voice - Ardila et al., 2020	587	260	Diversas	Crowdsourced
YODAS - Li et al., 2023	50k	N/A	Diversas	In-the-wild
CML TTS - Oliveira et al., 2023	400	115	España	Profesional
MLS - Pratap et al., 2020	1.5k	120	España	Profesional
VoxPopuli - Wang et al., 2021	166	305	España	Conversacional
Tedx Spanish - Hernandez-Mena, 2019	24	N/A	México	Espontáneo

de Argentina se centra en la región porteña. Los dataset calificados como dialecto diverso es porque en su confección no delimitaron entre los diferentes dialectos del español, y agruparon todo en una misma categoría, lo que incluya español de las diferentes regiones de Latino América y de España.

4. DESARROLLO

4.1. RECOPILACIÓN DE BASES DE DATOS

Con el fin de garantizar la reproducibilidad y transparencia de los experimentos, se han recopilado el código fuente utilizado para generar los gráficos y resultados parciales presentados en esta tesis. Se puede encontrar el material en el siguiente repositorio web: https://github.com/MatiasDiBernardo/Audio-Analysis-Tesis.

4.1.1. Datos *in-the-wild*

Para evaluar las cadenas de procesamiento sobre conjuntos de datos de habla se emplea el corpus en español de Argentina recopilado por el grupo de investigación Intercambios Transorgánicos. Este corpus consta de 24 horas de grabaciones realizadas en condiciones heterogéneas, tanto en calidad de audio como en diversidad de hablantes, y proviene mayoritariamente de fuentes públicas en internet. Por su variabilidad y carácter no controlado, este conjunto *in-the-wild* resulta idóneo para validar procedimientos de preprocesado de audio. En lo sucesivo, se hará referencia a esta colección como el conjunto de datos *original* (versión sin procesamientos).

Con el objetivo de captar diferencias dialectales relevantes para Argentina, la selección de hablantes sigue la clasificación regional propuesta por (de Weinberg y de Mirande, 2004). En concreto, el corpus incluye 32 hablantes con acento bonaerense y 27 con acento centro (que constituye principalmente a la provincia de Córdoba), para un total de 59 hablantes. La estrategia a futuro consiste en ampliar la cobertura dialectal para incorporar todas las variedades representativas del país; sin embargo, en esta tesis se valida inicialmente la cadena de preprocesamiento sobre estas dos variantes representativas.

4.1.2. Datos profesionales

Para complementar el corpus *in-the-wild* y disponer de material de mayor calidad contra el cual contrastar el análisis objetivo, se incorporan conjuntos de datos profesionales disponibles en trabajos previos. Dado que no existe una colección pública extensa exclusi-

vamente de español de Argentina, se incluyen también recursos con variantes dialectales cercanas cuando procede.

- ELRA Dataset (Guevara-Rukoz et al., 2020): aproximadamente 8 horas de audio con dialecto bonaerense, 44 hablantes.
- CML Dataset (Oliveira et al., 2023): subset de 8 horas de audio con dialecto en español de España, 15 hablantes.
- HaCASpa Dataset (Gabriel, 2011): aproximadamente 10 horas de audio con dialecto de Mendoza, 50 hablantes.

El conjunto profesional suma un total de 26 horas y 109 hablantes, con una distribución de acentos que refleja la diversidad regional. Este material se utiliza como referencia para evaluar la calidad acústica y las condiciones de grabación alcanzables mediante la cadena de preprocesamiento aplicada al corpus *in-the-wild*.

4.2. DESARROLLO DE LA CADENA DE PRE PROCESAMIENTO

La cadena de preprocesamiento diseñada en esta Tesis es una secuencia modular y reproducible de etapas destinadas a transformar material *in-the-wild* en subconjuntos utilizables para entrenamiento de TTS. Las etapas principales son las siguientes:

1. Post-procesado y metadatos: Normalización de niveles, etiquetado de metadatos (origen, duración, dialecto, condiciones de captura) y generación de los subconjuntos finales para evaluación y para alimentación a modelos TTS. Es importante destacar que esta etapa no altera la señal de audio, sino que organiza y prepara los datos para su posterior análisis.
2. Voice Activity Detection (VAD): Eliminación de segmentos sin voz y genera una segmentación inicial de fragmentos cortos de voz continua. En la implementación se usa Silero VAD (Team, 2024), que es algoritmo que cuenta con una serie de hiperparámetros que controlan la sensibilidad del detector y la longitud mínima de los segmentos. Se realizaron pruebas para determinar los valores óptimos de estos parámetros, y al no encontrar una relación de compromiso eficiente se implementó una estrategia adaptativa de optimización de hiperparámetros basada en clasificar el ritmo de habla

(lento/normal/rápido) mediante los timestamps de Whisper y optimizar los parámetros del VAD por categoría.

3. Denoising / Speech enhancement: Aplicación opcional de la cadena para mitigar ruido y artefactos de grabación. Se evalúan modelos prácticos y eficientes en CPU, además de la opción sin denoising, considerando el balance entre mejora perceptual y preservación de la identidad vocal. Los modelos seleccionados son Demucs (Défossez et al., 2020) y DeepFilterNet (Schroter et al., 2022).

4. Filtrado de calidad no intrusivo: Evaluación y filtrado mediante modelos de calidad perceptual no intrusiva para aceptar o rechazar fragmentos según puntuación mínima. Se utiliza modelos predictivos de MOS (Mean-Opinion-Score) como métrica conjunta de calidad. Se evalúan los modelos NISQA (Mittag et al., 2021) y DNS MOS (Reddy et al., 2021).

5. Transcripción (STT): Obtención de transcripciones automáticas necesarias para obtener los pares texto-audio que se requieren para el entrenamiento; en esta etapa se prioriza la precisión a costa de un mayor tiempo de cómputo, dado el impacto de errores de transcripción en la calidad final del corpus. Se utiliza el modelo de Whisper Large para la transcripción (Radford et al., 2023).

La implementación enfatiza portabilidad y bajo costo computacional, de modo que grupos con recursos limitados puedan reproducir la cadena y comparar variantes del algoritmo sin necesidad de utilizar hardware de alto rendimiento como serían GPUs. El diagrama de flujo de toda la cadena propuesta se presenta en la Figura 1.

4.2.1. Diferentes esquemas de procesamiento

Para evaluar el impacto de decisiones de diseño en la confección de cadenas de pre procesamiento, se proponen las siguientes variantes:

- Condiciones de denoising: DeepFilterNet (DFN), Demucs, y *no-denoising*. Estas alternativas representan puntos intermedios entre eficiencia, mejora perceptual y preservación de timbre.
- Modelos de calidad no intrusiva: NISQA y DNSMOS, seleccionados por su uso exten-

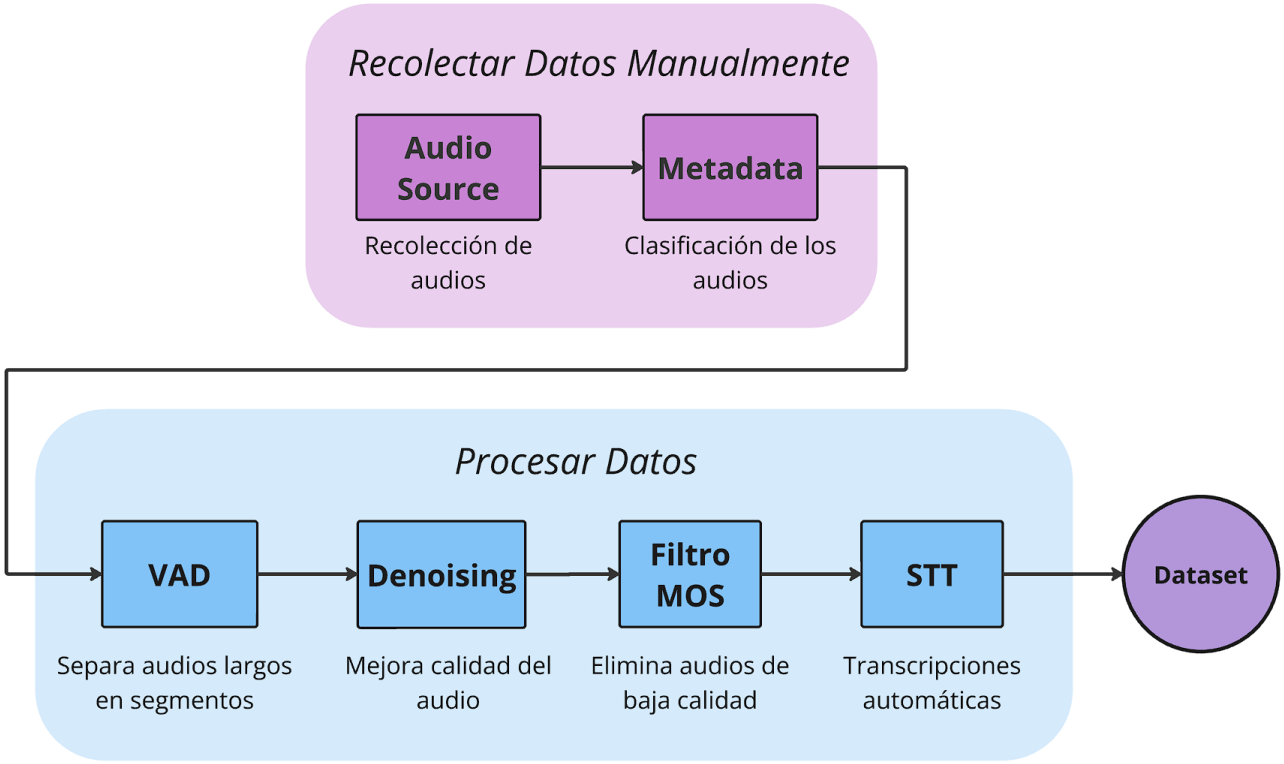


Figura 1. Diagrama de flujo del proceso completo para generar el dataset.

dido y su diferente sensibilidad a condiciones de ruido. Estos modelos son los mas usados en la literatura, donde se utiliza uno u el otro pero no se han contrastado para determinar el modelo mas optimo.

- Umbrales de filtrado: Para NISQA se evaluaron (3.0, 3.5, 3.8, 4.2) y para DNSMOS (2.7, 3.0, 3.2, 3.4). Los umbrales se eligieron de forma empírica analizando el nivel predicho de MOS para todo el conjunto de datos original.

La selección de umbrales parte de un análisis empírico presentado en la Figura 2, donde se calcula el valor de MOS resultante de NISQA y DNS MOS para todos los segmentos del dataset original. Es interesante notar como DNS MOS presenta un valor medio inferior y menos varianza. En consecuencia, para hacer una comparación justa, se seleccionaron los umbrales para garantizar un filtrado equitativo para los dos modelos.

En la Figura 3 se presentan de manera gráfica las diferentes variantes a analizar. Cada una genera un subconjunto procesado sobre el que se calculan las métricas objetivas (ver sección siguiente) para permitir una comparación reproducible y dirigida por métrica sin necesidad de entrenar modelos TTS para cada alternativa. A estas variantes de procesamiento se las denomina sub dataset.

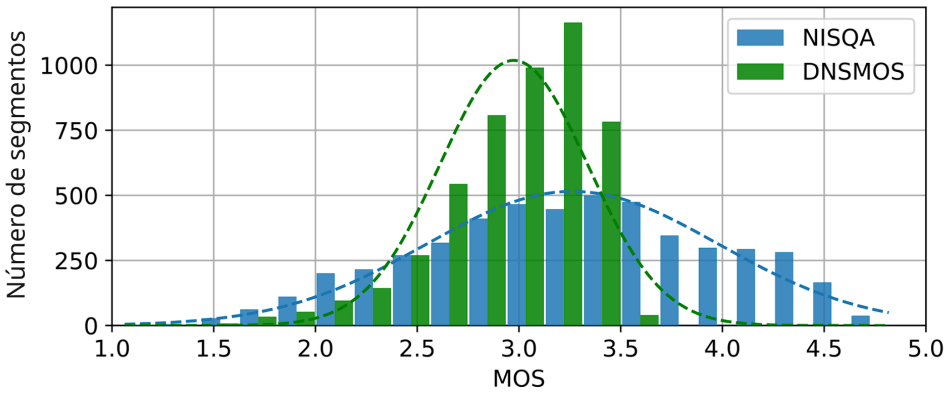


Figura 2. Resultado de MOS por cantidad de segmentos del dataset original para los 2 modelos a comparar.

No se contemplaron variaciones en el orden de las etapas de la cadena por una limitación de los algoritmos de denoising utilizados. Sería interesante evaluar el rendimiento de la cadena si el primer proceso aplicado es el denoising en vez del VAD, pero la implementación de Demucs no soporta audios de gran duración (por problemas de saturación de memoria). De la misma forma, los algoritmos de estimación de calidad de audio, trabajan con segmentos cortos, antes estás limitaciones, se mantiene siempre el orden establecido, donde el VAD segmenta audios de larga duración para que puedan ser procesados por las etapas siguientes sin problemas de saturación de memoria.

El desarrollo de esta cadena sigue los principios de código libre y reproducible, de modo que otros grupos puedan replicar los experimentos y comparar diversas combinaciones de procesos sin necesidad de disponer de hardware especializado. El código presenta un principio de diseño modular para que pueda ser fácilmente adaptado y extendido, con el fin de poder adaptar las distintas partes de la cadena. La implementación completa se encuentra disponible en el repositorio en Github https://github.com/MatiasDiBernardo/Lowcost-ITW-curation.

4.3. EVALUACIÓN DE LOS CONJUNTOS DE DATOS

La evaluación se articula alrededor de cuatro bloques de métricas complementarias que capturan cantidad, calidad de señal, condiciones acústicas y preservación de características del hablante. Estas métricas se combinan en una métrica compuesta que permite ordenar y seleccionar la mejor configuración según criterios definidos en la Sección 4.3.5.

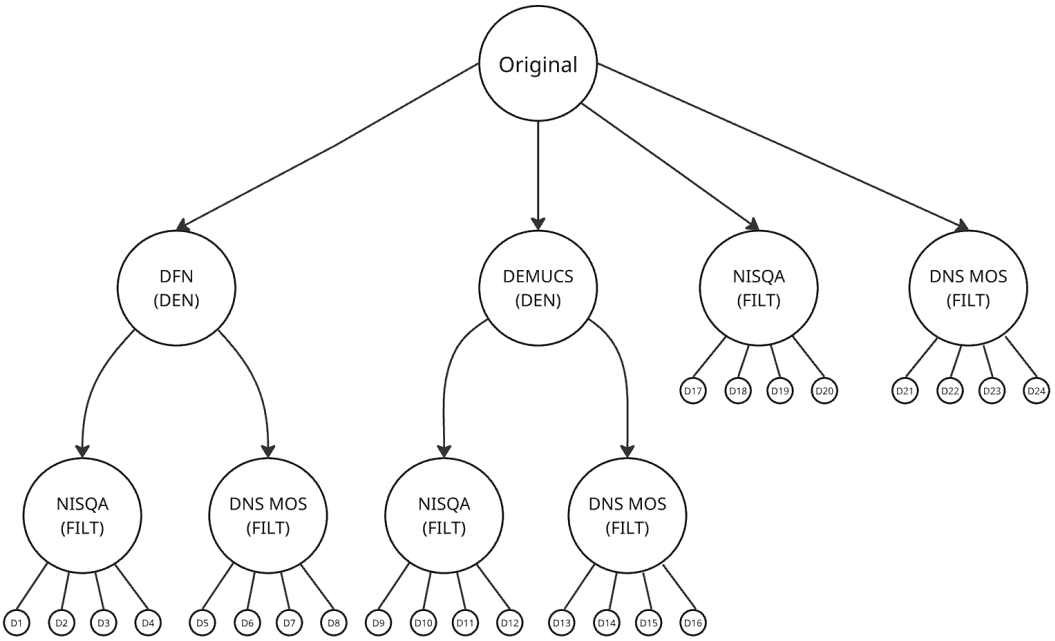


Figura 3. Variantes propuestas para evaluar diferentes algoritmos y parámetros de la cadena de procesamientos.

Todas las métricas buscan cuantificar diferencias relativas entre el dataset original y los sub datasets resultantes de las diferentes variantes; de esta forma, se pueden aplicar esta misma metodología de procesamiento para caracterizar el funcionamiento de la cadena de procesamientos, independientemente de las características del conjunto de datos de partida.

4.3.1. Reducción del corpus

El tamaño del dataset se mide en duración total (horas) y la *reducción de datos* (RD) se cuantifica según la Ecuación 6, donde el subíndice P hace referencia a las diferentes alternativas del dataset procesado, y el subíndice O hace referencia a la cantidad de horas del dataset original.

$$RD_P = 1 - \frac{\text{HORAS}_P}{\text{HORAS}_O} \tag{6}$$

Un valor de RD más pequeño es preferible (menos pérdida de datos). Esta medida captura la relación de compromiso básico entre condiciones del filtrado agresivas y cantidad de material utilizable.

4.3.2. Calidad de la grabación

La evaluación de la calidad de la grabación tiene por objetivo cuantificar, de forma objetiva y reproducible, las mejoras perceptuales y la fidelidad de la señal obtenidas tras aplicar las distintas etapas de la cadena (por ejemplo, denoising y filtrado). Para ello se emplean medidas complementarias: PESQ, SI-SDR y SNR; en un principio se contempla la posibilidad de utilizar también el STOI como un parámetro para cuantificar inteligibilidad, pero empíricamente no se encontraron diferencias significativas de este valor, con lo cual fue descartado.

PESQ (Perceptual Evaluation of Speech Quality) se utiliza como un indicador aproximado de la calidad subjetiva de la señal comparando la versión procesada con la referencia original; SI-SDR (Scale-Invariant Signal-to-Distortion Ratio) mide la fidelidad de la señal de forma robusta frente a cambios de escala y permite evaluar cuánto contenido de la señal original se preserva tras el procesamiento; la definición teórica para calcular estos parámetros requiere de tener una versión original de la señal y una versión degradada, como en este caso se quiere comparar ambos datasets de forma independiente, se utiliza el modulo Pytorch Squim (Kumar et al., 2023), que permite predecir los valores de PESQ, SI-SDR de forma no intrusiva (estimación ciega).

El SNR se estima mediante WADA-SNR (C. Kim y Stern, 2008) para obtener una cifra robusta de relación señal-ruido basada en la distribución de la amplitud de la onda. Todas estas métricas se computan a nivel de segmento y luego se resumen mediante la media y la desviación estándar para cada subconjunto, de modo que sea posible comparar distribuciones antes y después del procesamiento. Finalmente, las puntuaciones individuales se integran en el bloque *Calidad señal* (CS) donde se suma la influencia de todos estos valores Ecuación 7, teniendo en cuenta que se espera que los valores de PESQ, SI-SDR y SNR suban (mejoría) al aplicar la cadena de procesamientos. Los subindices respetan la condiciones anterior donde P es por procesado y O es original, estos subíndices se mantiene consistentes para todas las métricas.

$$CS_P = \frac{\text{PESQ}_O}{\text{PESQ}_P} + \frac{\text{SI-SDR}_O}{\text{SI-SDR}_P} + \frac{\text{SNR}_O}{\text{SNR}_P} \tag{7}$$

4.3.3. Condiciones acústicas

Las métricas acústicas buscan describir las condiciones de sala y la presencia de reverberación o de energía tardía en las grabaciones, aspectos que afectan la utilidad de los audios para entrenamiento de TTS, especialmente la alineación temporal entre texto y mel-spectrograma. En este trabajo se emplean descriptores clásicos como T_{30} (tiempo de reverberación aproximado) y medidas de claridad como C_{50} y D_{50}, que resumen la proporción de energía inicial frente a la energía reverberada y permiten detectar grabaciones con exceso de reverberación o poca claridad.

Nuevamente, es necesario calcular estos parámetros de forma ciega y sin referencia de las condiciones del entorno original,con estas limitaciones, estas métricas se estiman mediante un modelo CNN que fue entrenado para calcular parámetros acústicos de forma ciega, y fue validado para voces del español argentino, de manera que la estimación sea práctica sobre material *in-the-wild* sin requerir respuestas impulsivas de sala (Ortiz, 2023). Las mediciones se calculan por segmento y se agregan mediante estadísticos (media y desvío) para cada subconjunto; en la métrica compuesta se incorporan las mejores relativas para evaluar si una determinada combinación de procesos reduce la reverberación y mejora la claridad respecto del conjunto original.

En este caso, estas dos métricas se suman para contabilizar la influencia de las *Condiciones acústicas* (CA) en la Ecuación 8, donde el T_{30} mejora si disminuye, pero el C_{50} mejora si se incrementa. Se descarta el D_{50} ya que los resultados empíricos fueron muy similares al análisis del C_{50}, con lo cual se estaría agregando información redundante y se decide en consecuencia eliminar el aporte de esta métrica. El análisis de estas variables permite discriminar esquemas de procesamiento que mejoran la «condición de sala» del corpus sin sacrificar en exceso otros atributos.

$$CA_P = \frac{T_{30,P}}{T_{30,O}} + \frac{C_{50,O}}{C_{50,P}} \tag{8}$$

4.3.4. Diferencias del habla

Las medidas de diferencias del habla están pensadas para garantizar que las etapas de preprocesamiento, en particular los algoritmos de denoising, no alteren indebidamente la identidad del hablante ni la variabilidad prosódica del corpus, aspectos críticos para síntesis con preservación de timbre y estilo. En la tesis se consideran dos indicadores principales: la desviación estándar del F0 (F0-STD) y la distorsión mel-cepstral media (MCD).

El F0-STD captura la variabilidad prosódica de los hablantes; su cálculo se realiza a nivel de segmento usando el estimador PESTO (Riou et al., 2023) para extracción robusta de pitch, y se compara entre versión original y procesada para detectar reducciones anómalas de variabilidad que indiquen pérdida de naturalidad o sesgo en la selección de hablantes. El MCD se calcula entre los coeficientes mel-cepstrales de la señal original y de la señal procesada (especialmente relevante en audios sometidos a denoising) para cuantificar cambios tímbricos (Kominek et al., 2008); en la formulación adoptada el MCD se expresa como incremento porcentual o normalizado respecto a un valor de referencia aceptable de 5 dB según (Xie et al., 2024), de esta forma se penalizan los esquemas que alteran significativamente el timbre.

Estas dos componentes se combinan en el bloque *Diferencias del habla* (DH), donde cualquier diferencia relativa de F0-STD es penalizada, y lo mismo para el MCD respecto al valor de referencia Ecuación 9. Cabe aclarar que el MCD solo se calcula para las variantes con denoising, esto favorece de alguna forma a las alternativas sin denoising que no modifican las características del hablante.

$$DH_P = \left| 1 - \frac{\text{F0std}_P}{\text{F0std}_O} \right| + \frac{MCD_P}{5} \tag{9}$$

4.3.5. Métrica conjunta

Para ordenar configuraciones se propone una métrica compuesta que suma los cuatro bloques anteriores: reducción del dataset (RD), calidad de señal (CS), condiciones acústicas (CA) y diferencias de habla (DH). Esta métrica compuesta, plantea de forma matemática las relaciones de compromiso que se asumen con la cadena de procesamientos.

Se plantea la métrica compuesta como un objetivo de optimización en la Ecuación 10, donde se busca minimizar el aporte negativo de cada variable para poder identificar la mejor variante P de la cadena de procesamientos.

$$\min_{P \in \text{Conf}} \left\{ RD_P + CS_P + CA_P + DH_P \right\} \tag{10}$$

Con esta formulación, configuraciones que mantienen mayor cantidad de horas, mejoran la calidad de señal, mejoran (o mantienen) condiciones acústicas y preservan características del hablante obtendrán puntuaciones más bajas (mejor). Se propone un esquema inicial donde todos los bloques tienen el mismo peso; la elección de pesos distintos permite priorizar, por ejemplo, la preservación vocal frente a la cantidad de horas si el objetivo es síntesis con alta fidelidad identitaria.

4.4. ENTRENAMIENTO DEL MODELO DE ESTIMACIÓN DE DENSIDAD

Si bien la evaluación mediante métricas acústicas tradicionales (Sección 4.3) ofrece una aproximación robusta e interpretable para caracterizar los conjuntos de datos, este análisis presenta limitaciones inherentes al restringir la evaluación a un conjunto discreto de características diseñadas manualmente. Estas métricas, aunque útiles, pueden introducir sesgos al no capturar la totalidad de las dependencias complejas y de alta dimensión presentes en la señal de audio y del problema en sí.

Para mitigar estas limitaciones y proporcionar una perspectiva complementaria, se propone un método de evaluación basado en el aprendizaje de representaciones, utilizando un modelo de estimación de densidad. El objetivo fundamental de estos modelos es aprender la distribución de probabilidad intrínseca $p_{data}(x)$ de un conjunto de datos de entrenamiento, obteniendo una aproximación de la función de densidad de probabilidad (PDF) subyacente. La principal ventaja de este enfoque *data-driven* radica en su naturaleza no supervisada: el modelo extrae patrones latentes y características comunes de la distribución de referencia sin depender de etiquetas explícitas o de la selección arbitraria de parámetros acústicos, reduciendo así la intervención humana exclusivamente a la curaduría del conjunto de entrenamiento.

En el contexto de esta tesis, se adopta la arquitectura y metodología propuestas por

(de Oliveira et al., 2025), quienes utilizan modelos generativos basados en difusión probabilística para modelar la distribución del habla. Su investigación demuestra que, al utilizar audios de alta fidelidad como referencia para aprender la distribución base, el modelo es capaz de estimar la calidad de muestras fuera del conjunto de entrenamiento mediante la evaluación de su verosimilitud. Los resultados reportados indican que este enfoque presenta una correlación con la calidad perceptual superior a métricas tradicionales como PESQ o SNR, y una mayor alineación con la preferencia subjetiva humana en comparación con el MOS predicho.

La implementación propuesta en este trabajo utiliza el mismo principio de aprendizaje no supervisado, empleando el conjunto de datos profesionales (descrito en la Sección 4.1.2) para entrenar el modelo. De esta forma, se establece una distribución de referencia que representa el ”habla de alta calidad en español”. Una vez entrenado, el modelo permite calcular la verosimilitud de los audios pertenecientes a los distintos sub-datasets generados por la cadena de procesamiento. Bajo la hipótesis de que una mayor verosimilitud indica mayor cercanía a la distribución de referencia, este valor se utiliza como indicador comparativo entre las configuraciones evaluadas. No constituye por sí solo una medida directa de calidad perceptual ni permite determinar qué esquema preserva mejor la señal en todos los contextos.

4.4.1. Tratamiento de valores extremos y agregación

El log-likelihood se calcula para cada recorte de audio evaluado. Para el análisis se utiliza una serie filtrada post hoc: se excluyen las observaciones individuales cuyo log-likelihood es mayor que $4{,}0$ y se conservan las que son iguales o menores a ese umbral. La inspección de los resultados mostró valores extremos en la cola superior que influían desproporcionadamente en las medias y en las distribuciones por configuración; por eso se aplica el mismo corte a todas las observaciones, antes de calcular medias, distribuciones y asociaciones. El filtro actúa sobre observaciones individuales: no elimina corridas ni configuraciones completas. Al ser una decisión post hoc, sus resultados se interpretan como exploratorios y sujetos a validación con más configuraciones y datos.

4.4.2. Configuración del modelo e hiperparámetros

El entrenamiento del modelo de estimación de densidad se realizó utilizando un entorno de computación de alto rendimiento, centrado en una GPU NVIDIA GeForce RTX 5090 con 32 GB de memoria de video (VRAM). Este recurso fue fundamental para gestionar la carga computacional requerida por los modelos de difusión de alta fidelidad. Queremos expresar nuestro agradecimiento a la Subgerencia de Tecnología y Aplicaciones de Aceleradores de la Comisión Nacional de Energía Atómica por facilitar el acceso a este equipamiento de última generación.

La arquitectura del modelo de (de Oliveira et al., 2025) se basa en el framework EDM2 (Elucidating the Design Space of Diffusion-Based Generative Models), configurada para operar con audios a una tasa de muestreo de 16 kHz. A diferencia de los modelos de difusión discretos tradicionales, se empleó un esquema de ruido continuo, optimizando el entrenamiento mediante la minimización de la función de pérdida de score-matching. Los hiperparámetros específicos utilizados se detallan en la Tabla 3.

Tabla 3. Tiempo y métricas de control del entrenamiento del modelo de difusión.

Parámetro / Recurso	**Valor / Descripción**
Arquitectura del modelo	EDM2-Diffusion (Tiempo continuo)
Unidad de Procesamiento Gráfico (GPU)	NVIDIA GeForce RTX 5090
Memoria de video (VRAM)	32 GB GDDR7
Entorno de software	PyTorch 2.6 / CUDA 13.1
Tamaño de lote (*Batch size*)	16 muestras por batch
Precisión de cálculo	Punto flotante de 16 bits (fp16)
Tasa de aprendizaje máxima (α_{ref})	$1{,}09 \times 10^{-2}$

4.5. MODELO DE TTS ZERO-SHOT

La validación exhaustiva de una cadena de curaduría de datos requeriría, en un escenario ideal, el entrenamiento completo de un modelo de síntesis para cada uno de los subconjuntos de datos generados. Sin embargo, debido a las restricciones de cómputo y a los tiempos de convergencia asociados al entrenamiento de múltiples modelos neuronales, esta aproximación resulta inviable en los contextos de esta investigación. Además de las limitaciones estructurales, este método tendrías sus propias limitaciones metodológicas, dado que la variabilidad inherente al proceso de entrenamiento de modelos de síntesis podría

introducir ruido en la evaluación, dificultando la atribución de diferencias en la calidad de síntesis exclusivamente a las características del conjunto de datos utilizado.

Ante esta limitación, se propone una estrategia alternativa basada en la clonación de voz mediante modelos de TTS *zero-shot*. La hipótesis metodológica subyacente plantea que la calidad acústica de la muestra de referencia (el audio proveniente de la cadena de procesamiento) podría asociarse con la calidad perceptual de la voz sintetizada. Se tomaron 200 muestras de cada combinación como una evaluación preliminar compatible con el costo computacional disponible; este tamaño no garantiza representatividad estadística ni permite por sí solo establecer asociaciones concluyentes. Un número mayor de muestras y configuraciones permitiría caracterizar mejor la variabilidad de la síntesis.

Para la ejecución de este experimento, se seleccionaron dos modelos representativos del estado del arte en síntesis *zero-shot*, fundamentados en paradigmas generativos diametralmente opuestos. En primer lugar, se utilizó el modelo F5-TTS Chen et al., 2024. Esta elección se fundamenta en tres características críticas para la investigación:

1. Capacidad de clonación con referencias cortas: El modelo ha demostrado un rendimiento robusto utilizando muestras de referencia de muy corta duración (inferiores a 30 segundos). Esta característica es indispensable, dado que las variantes más estrictas de la cadena de procesamiento (e.g., umbrales altos de NISQA) pueden resultar en subconjuntos de datos con una disponibilidad limitada de segmentos continuos.

2. Coherencia Arquitectónica: F5-TTS se basa en el paradigma de *Flow Matching*, una generalización de los modelos de difusión. Esto alinea la arquitectura del modelo de síntesis con la del modelo de estimación de densidad utilizado para la evaluación (Sección 4.4), manteniendo una consistencia metodológica en el uso de modelos generativos modernos.

3. Disponibilidad y Reproducibilidad: Al ser un modelo de código abierto (*open source*), garantiza la reproducibilidad de los resultados y permite la inspección de su funcionamiento interno.

Para contrastar y enriquecer este análisis, se incorporó un segundo sintetizador: Qwen TTS (Hue et al., 2026). La selección de esta segunda arquitectura, basada en Modelos de Lenguaje Grande (LLMs), introduce un contrapeso metodológico fundamental:

1. Contraste Arquitectónico (Espacio Discreto vs. Continuo): A diferencia de la naturaleza continua de F5-TTS, los modelos basados en LLMs operan sobre representaciones discretizadas del audio generadas mediante *codecs* neuronales (*tokens* acústicos). Esto permite evaluar cómo reacciona un modelo de naturaleza autoregresiva frente a los mismos datos de referencia.

2. Resiliencia a Artefactos y Filtrado Intrínseco: El proceso de discretización de los *codecs* neuronales actúa como un filtro de normalización intrínseco, otorgando al modelo una mayor resiliencia computacional frente a ruidos residuales o distorsiones leves de fase. Su inclusión permite determinar si el impacto destructivo o beneficioso del preprocesamiento afecta de manera uniforme a todos los sintetizadores, o si depende intrínsecamente de su arquitectura subyacente.

El protocolo experimental consiste en utilizar audios representativos de los diferentes sub-datasets (seleccionados tanto por métricas objetivas como por estimación de densidad) como entradas de referencias para el sistema F5-TTS. Para garantizar que la evaluación no esté sesgada por el contenido lingüístico, las oraciones a sintetizar se extraen del corpus *"Los Sentidos"* (Gurlekian et al., 2021). Este texto ha sido seleccionado específicamente por su diseño para cubrir la diversidad fonética y alofónica característica del español de Argentina.

Finalmente, para cuantificar la calidad de las síntesis resultantes y cerrar el ciclo de evaluación, se emplea un predictor de MOS (*Mean Opinion Score*) entrenado específicamente para evaluar sistemas de TTS en idioma español (Sosa Welford y Pepino, 2025), lo que permite obtener una métrica de calidad perceptual automatizada y consistente.

Es fundamental remarcar que los resultados de este último experimento presentan un carácter preliminar y exploratorio. La predicción de la percepción subjetiva de calidad (MOS del TTS) está sujeta a múltiples factores inherentes a los propios modelos sintetizadores (como su entrenamiento previo, su capacidad de adaptación al locutor y la complejidad del texto objetivo). Por tanto, si bien este análisis revela tendencias de suma importancia, se requiere de futuras evaluaciones con metodologías estandarizadas de pruebas de escucha humana y validación cruzada para establecer conclusiones categóricas.

5. RESULTADOS Y ANÁLISIS

5.1. RESULTADOS DE LAS DIFERENTES VARIANTES DE LA CADENA

5.1.1. Ejemplo de cálculo

Se calcula el promedio de cada métrica para las diferentes variantes propuestas, y se calcula la mejora porcentual. Por ejemplo, para el SNR, el valor promedio calculado en el dataset original es de 19.08 dB. Al analizar el SNR para todas las variantes, se encuentra que el valor mas bajo de SNR es de 19.89 dB, mientras que el valor mas alto es de 33.78 dB. Los resultados ordenados según el porcentaje de mejora se puede ver en Tabla 4.

Tabla 4. Mejora SNR por métrica de calidad y algoritmo de denoising.

Filtro de calidad y umbral	Algoritmo de denoising	Mejora SNR (%)
NISQA = 3	Sin denoising	4.07
NISQA = 3.5	Sin denoising	4.93
DNSMOS = 2.7	Sin denoising	6.93
DNSMOS = 3.4	Sin denoising	7.56
DNSMOS = 3.0	Sin denoising	9.92
DNSMOS = 3.2	Sin denoising	10.00
NISQA = 3.8	DeepFilterNet	10.13
NISQA = 4.2	Sin denoising	11.67
DNSMOS = 3.4	DeepFilterNet	12.52
NISQA = 3.5	DeepFilterNet	14.78
NISQA = 3.8	Sin denoising	15.58
DNSMOS = 3.2	DeepFilterNet	15.65
NISQA = 3.0	DeepFilterNet	15.72
NISQA = 4.2	DeepFilterNet	17.55
DNSMOS = 3.0	DeepFilterNet	17.86
DNSMOS = 2.7	DeepFilterNet	18.84
DNSMOS = 3.4	Demucs	39.66
NISQA = 4.2	Demucs	40.34
NISQA = 3.8	Demucs	40.54
NISQA = 3.5	Demucs	41.24
DNSMOS = 3.2	Demucs	41.78
NISQA = 3.0	Demucs	42.16
DNSMOS = 3.0	Demucs	43.25
DNSMOS = 2.7	Demucs	43.52

Este análisis es el que se pondera para cada variable en las 4 categorías de métricas propuestas.

5.1.2. Métricas separadas

En una instancia exploratoria previa a la definición de la métrica conjunta, se exploran los resultados del dataset de prueba ante las diferentes métricas propuestas.

Primero se compara la relación entre calidad de audio y cantidad de horas del dataset. La Figura 4 muestra, en el eje horizontal, el porcentaje de reducción del dataset producido por el filtrado (más a la derecha significa pérdida de más horas) y, en el eje vertical, el incremento relativo de la puntuación PESQ expresado en porcentaje. Sobre la misma gráfica se comparan las tres variantes de la etapa de realce consideradas: DeepFilterNet, Demucs y la condición sin denoise. El comportamiento observado evidencia un trade-off claro entre cantidad y calidad: umbrales de filtrado más estrictos producen mejoras mayores en PESQ pero sacrifican un mayor número de horas de grabación. En concreto, las variantes con denoising aportan ganancias moderadas en PESQ (típicamente inferiores al 8 % según el umbral), mientras que la variante sin realce logra aumentos mayores en PESQ (superiores al 10 %) a costa de una reducción de dataset mucho más agresiva. Entre los métodos de realce usados, Demucs tiende a ofrecer las mayores mejoras de PESQ a lo largo de los umbrales evaluados, y DeepFilterNet presenta ganancias más pequeñas para filtros equivalentes; esta diferencia implica que la elección del algoritmo de realce y del umbral de NISQA debe hacerse en función del balance deseado entre calidad perceptual y preservación de horas útiles.

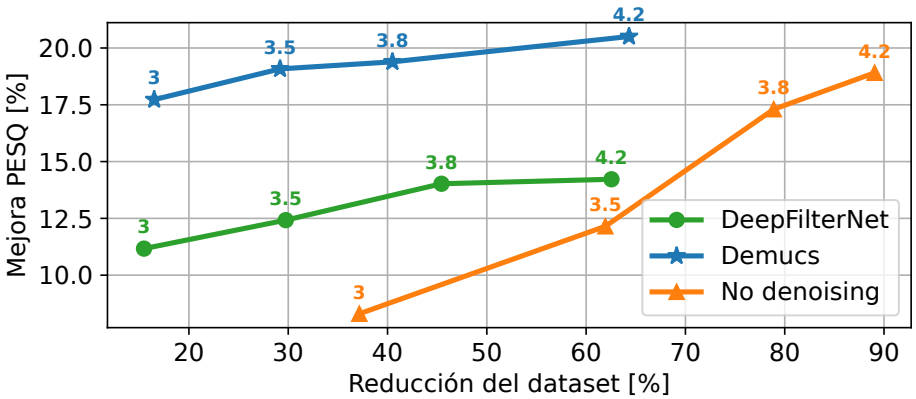


Figura 4. Comparación entre PESQ y cantidad de horas de diferentes variantes con NISQA.

En la Figura 5 se relaciona la reducción porcentual de horas con la mejora relativa en T_{30} (tiempo de reverberación estimado) cuando se emplea DNSMOS como métrica de filtrado. En la gráfica, un aumento en la mejora de T_{30} implica una reducción de la energía tardía y, por ende, una menor reverberación aparente en los segmentos retenidos. Los

resultados muestran que el filtrado aporta ganancias en condiciones sin denoise de forma especialmente notable, cuando no se aplica realce previo el filtrado selecciona segmentos con menor reverberación y la mejora en T_{30} es sustancial. En cambio, una vez aplicada la supresión de ruido, las ganancias en T_{30} son más moderadas (por debajo aproximadamente del 5 % en los umbrales considerados). Además, no se detecta una diferencia significativa en T_{30} entre DeepFilterNet y Demucs. En conjunto, la figura subraya que el filtrado basado en DNSMOS puede reducir la reverberación del subconjunto resultante, pero el beneficio marginal depende fuertemente de si previamente se aplicó un algoritmo de realce y de la agresividad del umbral.

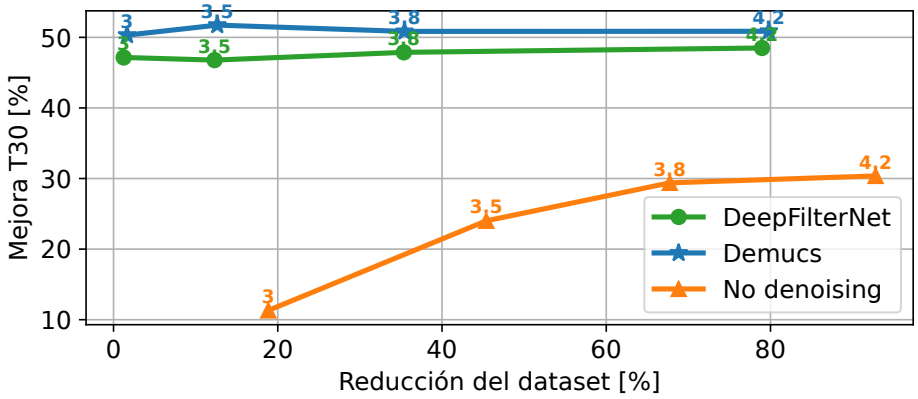


Figura 5. Comparación entre T30 y cantidad de horas de diferentes variantes con DNS MOS.

Además de comparar la cantidad de horas, también se pueden relacionar otras variables, como puede ser la desviación de frecuencia fundamental $F0\text{-}STD$ y la mejoría de calidad cuantificada por PESQ como se puede ver en la Figura 6. En este análisis se ilustra la relación entre la mejora relativa de PESQ (eje horizontal) y la diferencia porcentual en la desviación estándar de $F0$ ($F0\text{-}STD$, eje vertical) para las variantes evaluadas con DNSMOS. Esta representación revela un efecto colateral relevante: a medida que aumenta la mejora perceptual (PESQ) por filtrado más estricto, suele observarse una reducción de la variabilidad prosódica medida por $F0\text{-}STD$. La explicación práctica es que el filtrado agresivo tiende a eliminar segmentos y hablantes de peor calidad, lo cual reduce la heterogeneidad prosódica del subconjunto retenido. No obstante, los métodos de realce que mejor preservan el timbre de voz muestran cambios menores en $F0\text{-}STD$ ante el mismo grado de filtrado, esta es una de las principales diferencias entre DeepFilterNet contra Demucs, donde el primero mejorar la calidad percibida sin sacrificar tanto la variabilidad prosódica. En la práctica, la figura pone de manifiesto el compromiso entre mejorar la calidad objetiva del audio y man-

tener la diversidad de patrones de entonación: selección excesiva orientada únicamente a PESQ puede empobrecer la variabilidad del corpus, con posible impacto en tareas de síntesis que requieran conservar rasgos prosódicos y de identidad.

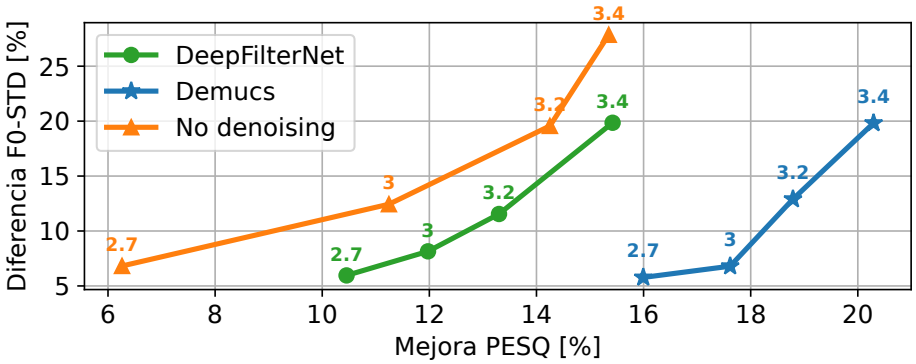


Figura 6. Comparación entre F0-std y PESQ para diferentes variantes con DNS MOS.

Este análisis pone en evidencia las relaciones de compromiso entre las métricas seleccionadas y como la mejor variante no será la que alcance un mejor resultado en particular, sino la que logre un mejor balance de todos los criterios en conjunto.

5.1.3. Métricas compuestas

Una vez validado el comportamiento de cada métricas de forma individual, se analizan las métricas compuestas definidas en la Sección 4.3. Primero, la calidad de la señal presenta un comportamiento similar a la tendencia explicada al analizar PESQ. Esto es evidente, ya que tanto PESQ, SI-SDR y SNR siguen la misma tendencia, como se presenta en las gráficas completas en el Anexo I.

En la Figura 7, se compara la métrica compuesta de reducción de datos (RD), respecto a la calidad de la señal (CS). Como la métrica se diseñó para minimizar el objetivo total, se puede ver que el mínimo coincide con la variante que filtra menor cantidad de datos y utiliza Demucs como algoritmo de denoising, resultado que coincide con el análisis de las métricas de forma aislada.

Se analizaron y compararon todas las combinaciones de las diferentes métricas. Los resultados mas destacados son la comparación entre calidad de señal y condiciones acústicas Figura 8, donde el agrupamiento de las métricas indica que el filtrado tiene muy poco impacto.

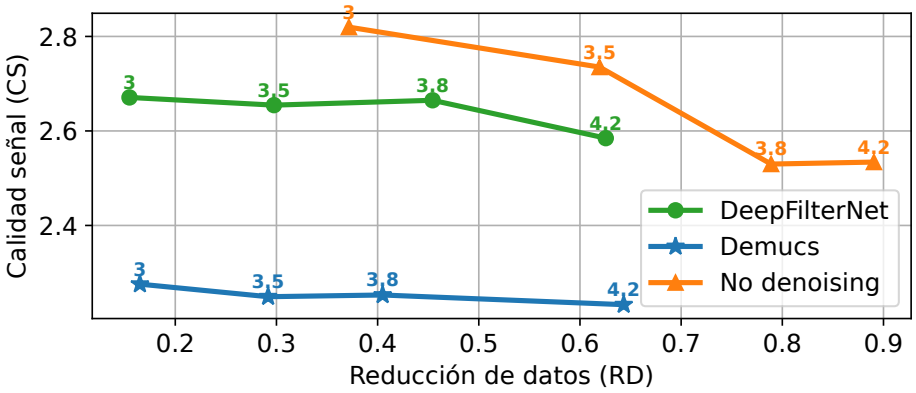


Figura 7. Comparación entre reducción de datos y calidad de señal para diferentes variantes con Nisqa.

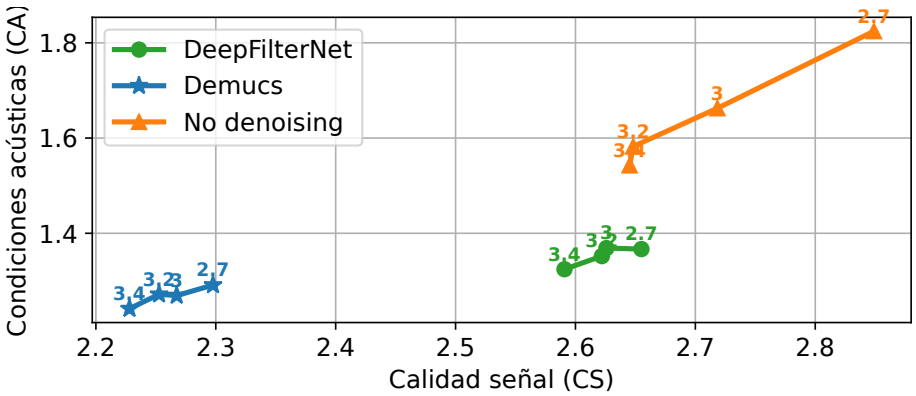


Figura 8. Comparación entre calidad de señal y condiciones acústicas para diferentes variantes con DNSMOS.

El mismo comportamiento se observa en las diferentes variantes de comparación. Se adjuntan más gráficos en el Anexo II.

5.1.4. Optimización de la cadena de procesamiento

Al sumar todas las métricas compuestas, se obtiene la métrica conjunta o total, con la cual se pueden ordenar las variantes de la cadena y así definir cuál es la combinación óptima para procesar un conjunto de datos del habla.

En la Tabla 5, se presenta el valor de cada métrica parcial y el valor de la métrica conjunta, para todas las variantes, ordenadas de menor a mayor (siendo el mínimo la mejor variante y el máximo la peor variante). En la tabla se presentan las métricas parciales abreviadas, donde RD es reducción del dataset, CS es calidad de señal, CA es calidad acústica, DH es diferencias del habla, y TOT es la métrica conjunta, que contempla la suma de todas las métricas parciales.

Tabla 5. Métricas compuestas y total para todas las configuraciones.

Filtrado	Umbral	Denoiser	RD	CS	CA	DH	TOT
DNSMOS	2,7	Demucs	0,02	2,30	1,29	0,48	**4.08**
DNSMOS	3,0	Demucs	0,13	2,27	1,27	0,51	4,17
NISQA	3,0	Demucs	0,17	2,28	1,27	0,60	4,31
NISQA	3,5	Demucs	0,29	2,25	1,28	0,58	4,41
NISQA	3,8	Demucs	0,40	2,25	1,30	0,55	4,51
DNSMOS	3,2	Demucs	0,35	2,25	1,27	0,63	4,51
DNSMOS	2,7	DeepFilterNet	**0.01**	2,66	1,37	0,62	4,65
NISQA	4,2	Demucs	0,64	**2.22**	1,29	0,52	4,68
DNSMOS	3,0	DeepFilterNet	0,12	2,63	1,37	0,61	4,73
NISQA	3,0	DeepFilterNet	0,15	2,67	1,37	0,63	4,83
DNSMOS	3,2	DeepFilterNet	0,35	2,62	1,35	0,60	4,93
DNSMOS	2,7	No denoising	0,19	2,85	1,82	**0.07**	4,93
NISQA	3,5	DeepFilterNet	0,30	2,65	1,38	0,63	4,96
DNSMOS	3,0	No denoising	0,45	2,72	1,66	0,12	4,96
DNSMOS	3,4	Demucs	0,80	2,23	**1.24**	0,78	5,05
NISQA	3,0	No denoising	0,37	2,82	1,79	0,09	5,08
DNSMOS	3,2	No denoising	0,68	2,65	1,58	0,20	5,10
NISQA	3,8	DeepFilterNet	0,45	2,66	1,37	0,64	5,13
NISQA	3,8	No denoising	0,79	2,53	1,69	0,20	5,21
NISQA	3,5	No denoising	0,62	2,74	1,74	0,13	5,22
DNSMOS	3,4	DeepFilterNet	0,79	2,59	1,32	0,58	5,29
NISQA	4,2	DeepFilterNet	0,63	2,58	1,37	0,81	5,39
DNSMOS	3,4	No denoising	0,93	2,65	1,54	0,28	5,39
NISQA	4,2	No denoising	0,89	2,53	1,65	0,46	5,53

La mejor versión de la cadena es la que utiliza Demucs como algoritmo de denoiser y DNSMOS como algoritmo de filtrado con umbral de MOS en 2.7, que obtiene un valor total de 4.08, mientras que la peor variante alcanza un valor total de 5.53

Es interesante analizar como la cadena que alcanza la mejor puntuación general, no es la mejor opción en ninguna de las métricas individuales (marcadas en negrita), sino que ofrece la mejor relación de compromiso entre las 4 condiciones evaluadas.

5.1.5. Análisis del peso de cada métrica

Se analiza la varianza de cada métrica en función de las distintas disposiciones de la cadena para determinar cual métrica tiene mas peso en el ordenamiento propuesto por la metodología de evaluación. En los resultados presentados cada conjunto de métrica tiene el mismo peso, pero al analizar la varianza de los resultados a traves de la diferentes configuraciones se evidencia que por las características del dataset, ciertas métricas tienen mayor

influencia que otra. En la Tabla 6, se presentan los resultados de este análisis comparando desvío estándar y máxima desviación para todas las métricas conjuntas.

Tabla 6. Desvío estándar y máxima desviación para cada métrica compuesta respecto a las diferentes versiones de cadena bajo evaluación.

	RD: Reducción datos	**CS: Calidad señal**	**CA: Condiciones acústicas**	**DH: Diferencias del habla**
Desvío	0,28	0,20	0,18	0,22
$\Delta_{máx}$	0,92	0,62	0,58	0,74

En concordancia con los resultados, el conjunto de métricas que tiene mas variación es la reducción de datos. Esto tiene sentido dado que los filtrados mas permisivos prácticamente no reducían la cantidad de horas del dataset, mientras que los filtrados con un umbral mas agresivo reducían considerablemente la cantidad de horas del conjunto de datos.

5.2. COMPARACIÓN ENTRE CONJUNTOS DE DATOS

5.2.1. Dataset profesional vs procesado

El conjunto de datos profesionales detallado en (4.1.2), utiliza condiciones de grabación óptimas, con micrófonos de alta calidad, entornos controlados y técnicas de post-procesamiento avanzadas. Esto se traduce en una calidad acústica superior, con menor ruido de fondo, menor reverberación y una representación más fiel de la voz humana. En contraste, el dataset *in-the-wild* procesado mediante la cadena propuesta, aunque mejora significativamente la calidad del audio original, sigue presentando limitaciones inherentes a las condiciones de grabación no controladas.

Al utilizar las mismas métricas de análisis para caracterizar al dataset profesional, se puede evaluar el grado de mejora alcanzado por la cadena de procesamiento y comparar objetivamente las condiciones acústicas y de calidad entre ambos conjuntos de datos. Este análisis permite identificar en qué aspectos específicos el dataset procesado se acerca o se aleja de las condiciones ideales representadas por el dataset profesional, y así determinar si la cadena de procesamiento logra mitigar efectivamente las limitaciones del material *in-the-wild* o si persisten brechas significativas en términos de calidad acústica, ruido residual o variabilidad prosódica, que no se pueden resolver únicamente con procesamiento de señales.

En la Figura 9 se compara el resultado de PESQ para la condición base (dataset *in-the-wild* sin procesar), el peor y mejor resultado de la cadena de procesamiento, y el valor promedio de los dataset profesionales. Esto pretende mostrar que si bien se genera una mejora objetiva en el dataset original, simplemente con procesamiento no se pueden igualar las condiciones de un conjunto de datos grabado en condiciones óptimas.

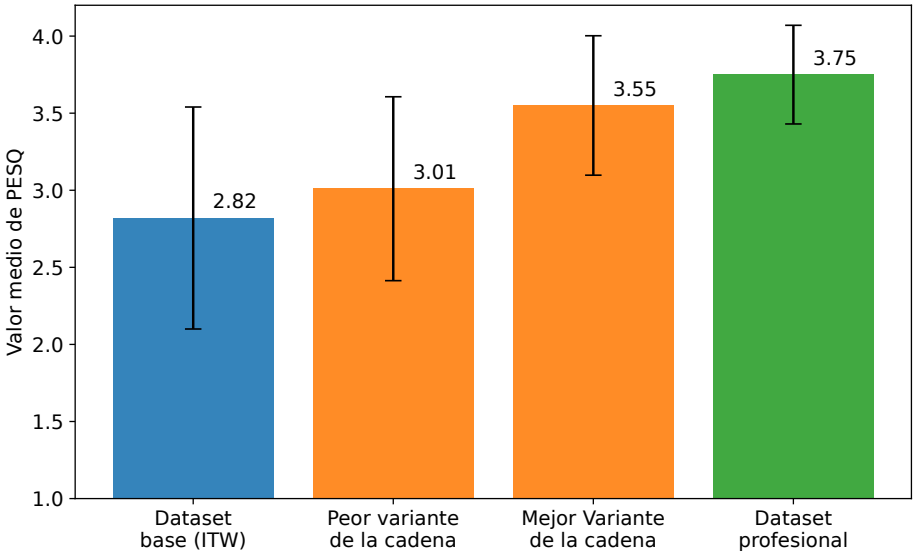


Figura 9. Diferencias del valor de PESQ promedio según diferentes conjuntos de datos.

En cambio, para el parámetro de T_{30}, se observa que la mejor variante con procesamientos mejora la condición de reverberancia promedio alcanzada por el promedio de dataset tradicionales como se observa en la Figura 10. Esto deja en evidencia que la variación producto del procesamiento depende específicamente de cada métrica, donde se puede evaluar casos como el PESQ donde no se iguala el valor del dataset original, o casos como el T_{30} donde se mejora la condición de referencia. Esta tendencia se repite para C_{50}, donde la mejor variante de la cadena de procesamiento mejora el valor promedio del dataset profesional, mientras que métricas de calidad como SNR y SI-SDR, aunque mejoran respecto al dataset original, no alcanzan el valor promedio del dataset profesional. Todos los resultados se de esta comparación para las métricas individuales se presentan en el Anexo III.

Estos resultados son congruentes con las agrupaciones realizadas en el estudio de métricas, donde se evidenció que las métricas de calidad de señal y acústica no necesariamente están correlacionadas, y que el procesamiento puede mejorar ciertas condiciones acústicas sin necesariamente mejorar la calidad de señal en la misma proporción.

Por último, para analizar la variabilidad prosódica y de identidad del hablante, en la

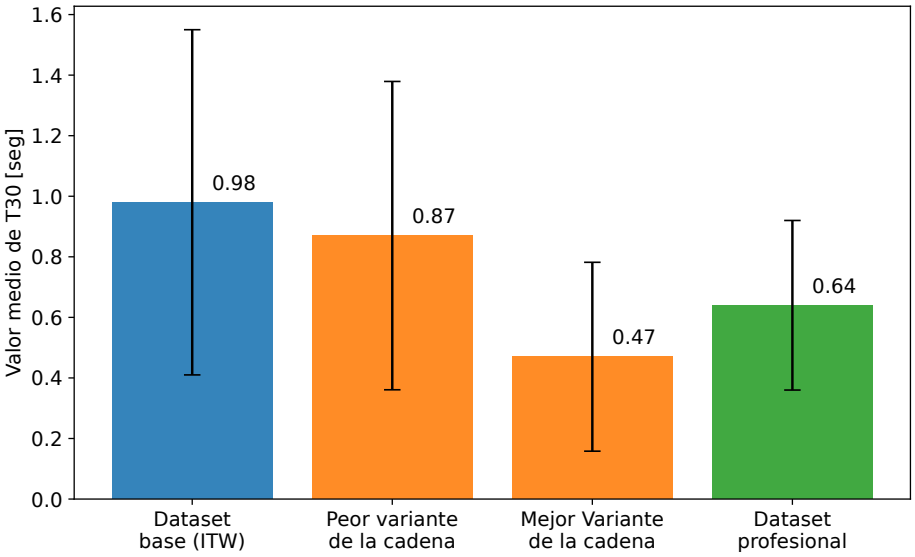


Figura 10. Diferencias del valor de T30 promedio según diferentes conjuntos de datos.

Figura 11 se compara la frecuencia fundamental promedio de los hablantes de los dataset evaluados, donde el dataset ITW presenta una mayor variabilidad y un valor promedio mayor, indicando que no hay ningún tipo de sesgo hacia hablantes con voz mas grave, como suele ocurrir en los dataset profesionales, donde se tiende a seleccionar hablantes con voz mas grave para evitar problemas de sibilancia y ruido. Además, el valor de $F0\text{-}STD$ es mayor para el dataset ITW, lo que indica una mayor variabilidad en la frecuencia fundamental, lo cual es positivo para tareas de síntesis de voz que requieren diversidad prosódica.

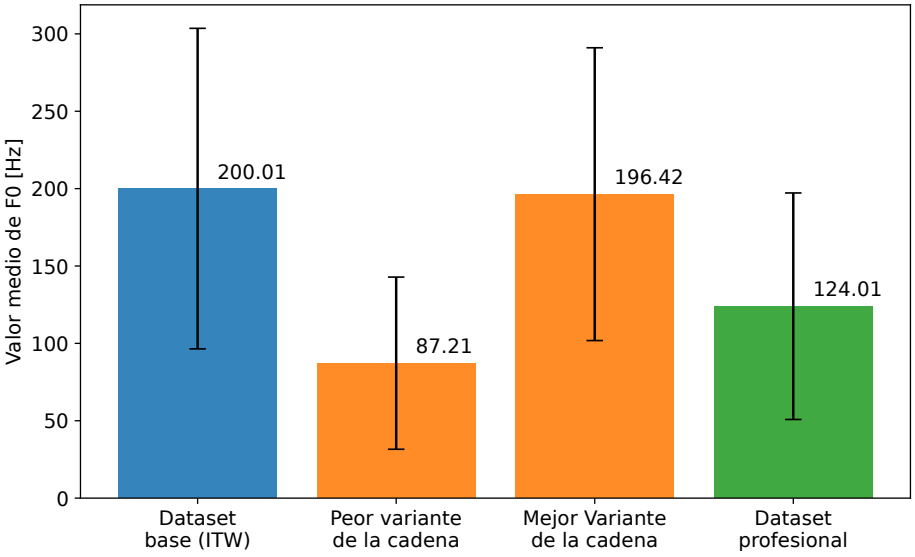


Figura 11. Diferencias del valor de F0 promedio según diferentes conjuntos de datos.

Estos resultados evidencian la necesidad de incorporar conjuntos de datos *in-the-wild* si se busca capturar el fenómeno del habla en su diversidad y complejidad real, ya que los

dataset profesionales, aunque de alta calidad, pueden presentar sesgos significativos en términos de identidad de hablante y patrones prosódicos, lo cual limita su aplicabilidad para tareas que requieren generalización a condiciones reales de uso.

5.3. COMPARACIÓN POR ESTIMACIÓN DE DENSIDAD

En la Sección 4.4.2, se describen los detalles de la configuración usada para entrenar el modelo. En la Tabla 7 se resumen los resultados mas importantes del proceso de entrenamiento, donde se puede ver lo costoso que es entrenar un modelo de difusión de alta fidelidad.

Tabla 7. Especificaciones técnicas e hiperparámetros del entrenamiento del modelo de difusión.

Parámetro / Recurso	**Valor / Descripción**
Duración total del entrenamiento	33,554 kwav (33.5M de muestras)
Tiempo de cómputo total	$\approx$ 92 horas
Función de pérdida (*Score Matching Loss*)	$-1{,}218$
Mecanismo de promediado	EMA (Exponential Moving Average) 0.100

En la Figura 12 se muestra la función de pérdida en función de los audios evaluados (la unidad 1 kwav equivale a 1000 audios evaluados), donde se observa que el entrenamiento ha convergido de manera efectiva, lo cual indica que el modelo ha aprendido a estimar la distribución de los datos, permitiendo así realizar comparaciones significativas entre las diferentes variantes de la cadena de procesamiento.

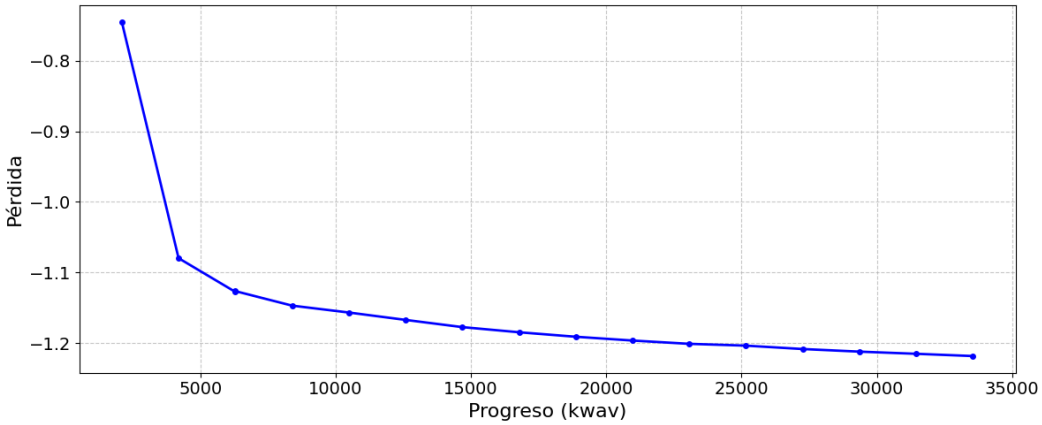


Figura 12. Función de pérdida en función de los audios evaluados durante el entrenamiento del modelo de difusión.

Los modelos de difusión son costosos de entrenar y tienen un alto tiempo de ejecución

en la etapa de inferencia (para procesar 10 horas de audio se necesitan aproximadamente 24 horas de cómputo). Para optimizar los recursos, se evalúa el modelo en ocho variantes seleccionadas a partir de los resultados de la Tabla 5, con el fin de cubrir un rango de puntuaciones de la métrica conjunta. El análisis de likelihood se limita a estas ocho configuraciones y permite describir patrones exploratorios, no establecer diferencias estadísticamente significativas entre todas las variantes posibles.

Al igual que para el cálculo de métricas objetivas, se seleccionan aleatoriamente muestras de cada variante. Se toma la mitad de las muestras disponibles por configuración y se evalúan los primeros cinco segundos de cada audio para limitar el uso de memoria. Como filtro previo al cálculo, se excluyen los recortes que casi no contienen voz en esos cinco segundos, pues su puntuación no representaría la calidad general del audio. Este filtro de voz es distinto del corte post hoc de log-likelihood descrito en la metodología.

En la Tabla 8 se presentan las medias de la serie canónica de likelihood filtrado para las ocho configuraciones evaluadas, junto con su puntuación según las métricas objetivas. Una media mayor indica que las observaciones retenidas son más compatibles con la distribución de referencia del corpus profesional; esta comparación no equivale por sí sola a una medida de calidad perceptual.

Tabla 8. Comparación entre las medias de likelihood y la métrica objetiva total (TOT), ordenadas por verosimilitud.

Filtrado	Umbral	Denoiser	Likelihood filtrado ↑	TOT ↓
DNSMOS	2,7	DeepFilterNet	2,37	4,65
NISQA	3,8	DeepFilterNet	2,30	5,13
DNSMOS	2,7	No denoising	2,02	4,93
NISQA	4,2	No denoising	2,01	5,53
DNSMOS	3,4	Demucs	1,88	5,05
NISQA	4,2	Demucs	1,86	4,68
DNSMOS	2,7	Demucs	1,73	4,08
NISQA	3,0	Demucs	1,69	4,31

En las ocho configuraciones evaluadas, las dos medias de likelihood más altas corresponden a DeepFilterNet (2.37 y 2.30), seguidas por las dos configuraciones sin denoising (2.02 y 2.01); las cuatro configuraciones Demucs se sitúan entre 1.69 y 1.88. Las diferencias entre umbrales no siguen una tendencia única. Descriptivamente, la separación entre algoritmos de denoising parece más marcada que la variación entre umbrales, pero la selección limitada no permite atribuir causalidad ni generalizar este ordenamiento a configuraciones

no evaluadas. Una posible explicación es que el procesamiento de Demucs introduce artefactos espectrales que reducen la compatibilidad con la distribución de referencia.

En la Figura 13 se muestran las distribuciones, estimadas mediante Kernel Density Estimation (KDE; Parzen, 1962), para tres configuraciones: Demucs con NISQA 3.0, DeepFilterNet con DNSMOS 2.7 y sin denoising con DNSMOS 2.7.

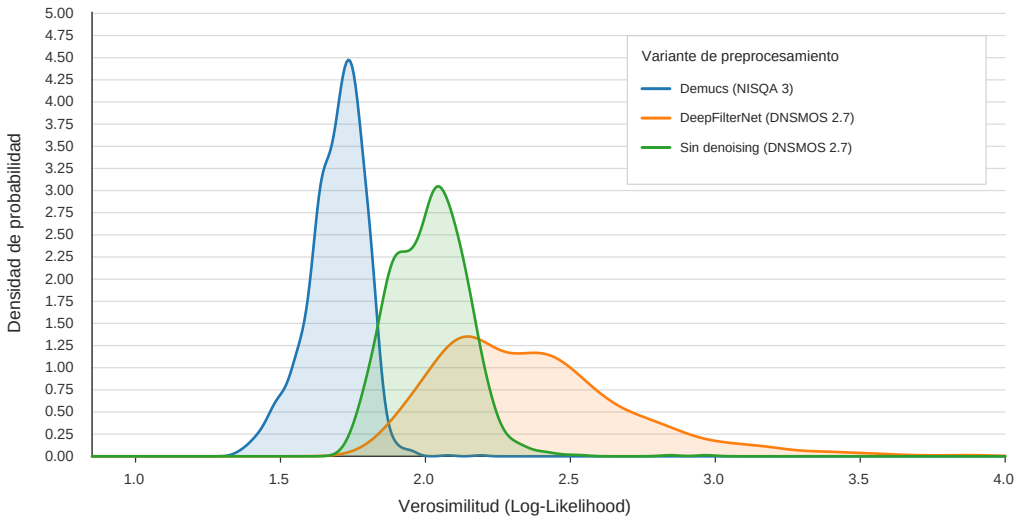


Figura 13. Distribución filtrada de la verosimilitud para tres configuraciones de denoising.

En estas tres configuraciones, Demucs presenta la distribución más concentrada y la media más baja; DeepFilterNet, la media más alta y la mayor dispersión; y la condición sin denoising queda en una posición intermedia. Estas observaciones describen solo las configuraciones y los recortes retenidos que se muestran, y no permiten concluir que un algoritmo produzca conjuntos más homogéneos para todos los umbrales.

La calidad, la homogeneidad y la diversidad son relevantes para preparar datos de TTS. Sin embargo, las distribuciones de la figura corresponden a tres configuraciones y no bastan para establecer diferencias generales de homogeneidad o diversidad entre algoritmos. La evaluación de más configuraciones y umbrales permitiría comprobar si el patrón se mantiene.

5.4. COMPARACIÓN ENTRE MÉTRICAS OBJETIVAS Y ESTIMACIÓN DE DENSIDAD

La comparación entre las métricas objetivas y la estimación de densidad muestra que ambos criterios ordenan de manera distinta las configuraciones evaluadas. Para la comparación se consideran las ocho configuraciones con resultados disponibles en ambas metodologías; las conclusiones de este apartado se limitan a ese conjunto.

En la Tabla 8, el mínimo de TOT corresponde a Demucs con DNSMOS 2.7 (4.08), mientras que las dos medias de likelihood filtrado más altas corresponden a DeepFilterNet (2.37 y 2.30). Este resultado muestra un ordenamiento diferente según el criterio, dentro de las ocho configuraciones compartidas. Las métricas describen aspectos distintos de las cadenas y su interpretación depende del objetivo de uso.

Dentro de las configuraciones incluidas, el puntaje objetivo más bajo se obtiene con Demucs DNSMOS 2.7. Las métricas intrusivas como PESQ y SI-SDR evalúan la señal procesada respecto de una referencia y pueden favorecer la reducción de energía en regiones consideradas silenciosas. El resultado describe el comportamiento de esta configuración bajo las métricas adoptadas y no establece una superioridad universal de Demucs para cualquier conjunto o tarea.

En la serie filtrada, las cuatro configuraciones Demucs presentan medias entre 1.69 y 1.88. Una posible explicación es que algunos artefactos introducidos por la separación de fuentes reduzcan la compatibilidad de la señal con la distribución de referencia. La Figura 14 muestra un ejemplo de diferencias espectrales entre audio sin procesar, Demucs y DeepFilterNet; este ejemplo ilustra un caso y no prueba por sí solo el mecanismo que produce las diferencias de likelihood.

Las dos configuraciones DeepFilterNet evaluadas ocupan las primeras posiciones de la tabla de likelihood, con medias filtradas de 2.37 y 2.30. Este ordenamiento es descriptivo de las configuraciones ensayadas. La hipótesis de que un realce más conservador preserve rasgos próximos a la distribución profesional puede orientar análisis posteriores, aunque las medidas de este experimento no permiten identificar por sí solas el mecanismo ni establecer que el likelihood refleje la preferencia perceptual.

La Figura 15 relaciona la media de likelihood filtrado de cada configuración con sus

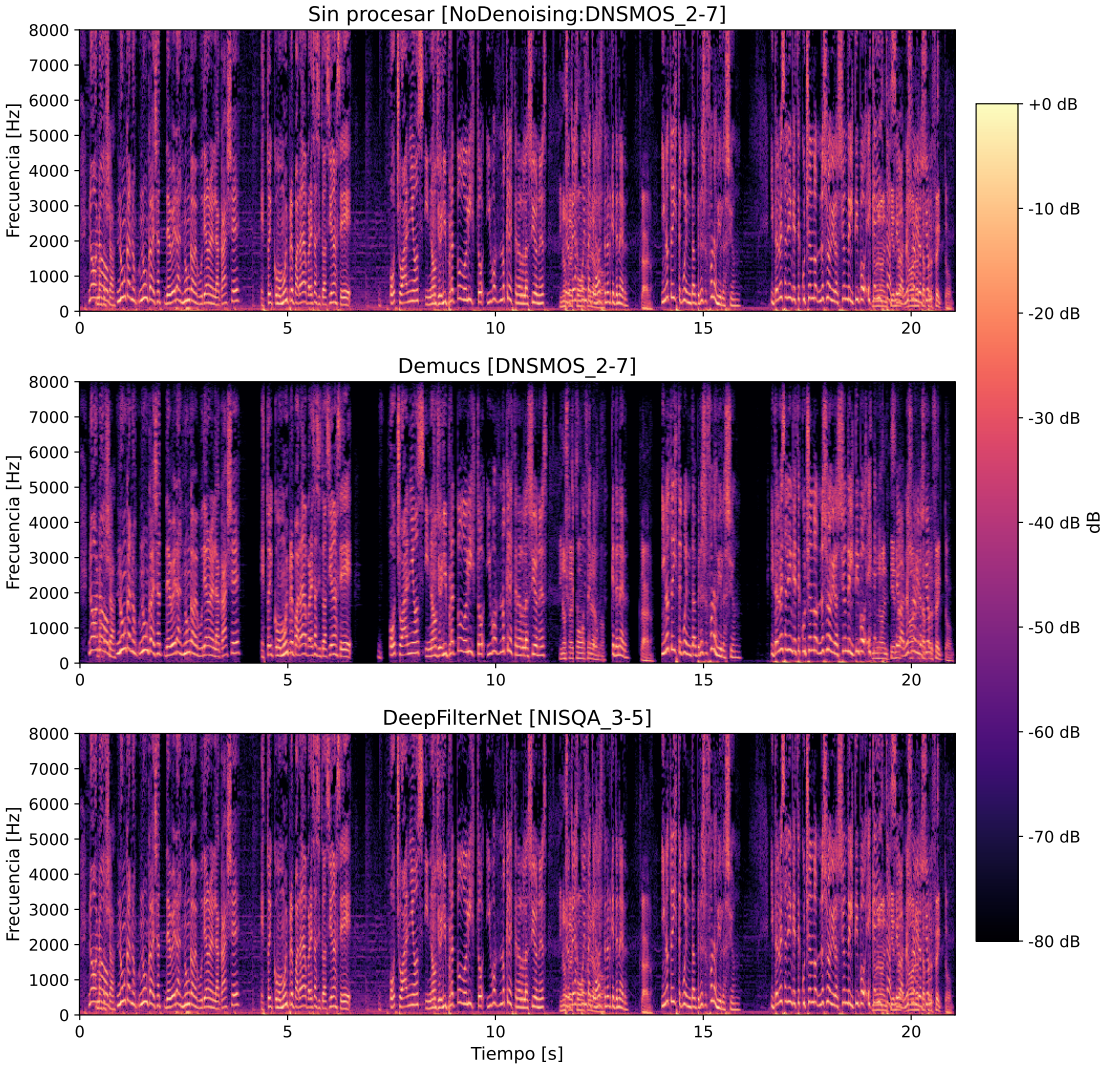


Figura 14. Ejemplo del mismo audio procesado con diferentes algoritmos de denoising.

medias de calidad de señal (CS) y condiciones acústicas (CA). Cada punto representa una configuración, emparejada por algoritmo de denoising, métrica acústica y umbral; las métricas objetivas y el likelihood se comparan como promedios por configuración. En estas ocho configuraciones se aprecia una separación descriptiva por algoritmo, mientras que los umbrales no muestran una tendencia uniforme.

5.4.1. Conclusión del Análisis Cruzado

La integración de ambas metodologías demuestra que evaluar pipelines de procesamiento de habla exige definir claramente el objetivo del sistema downstream.

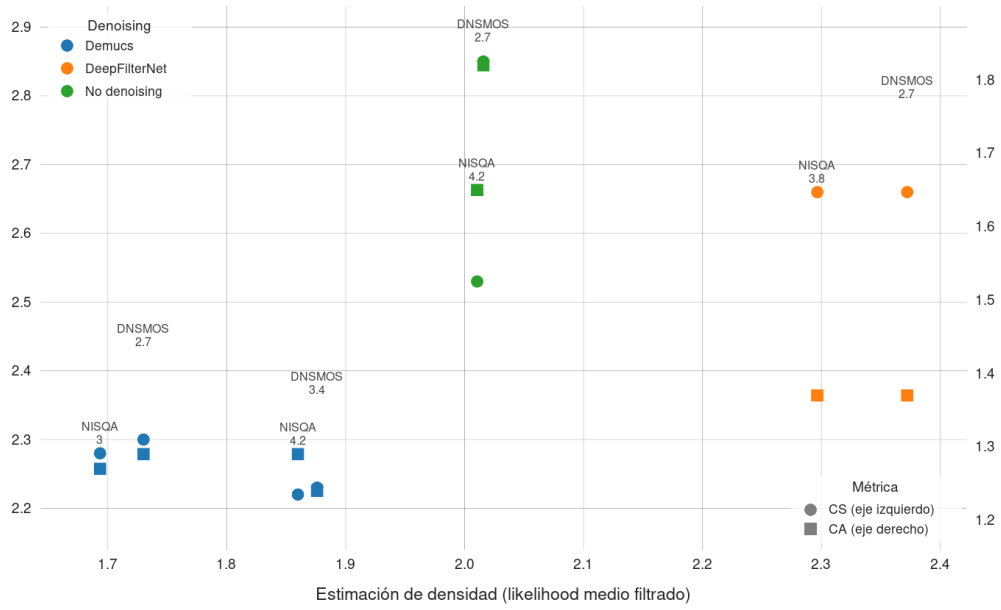


Figura 15. Relación entre la media de likelihood y las métricas de calidad de señal (CS) y condiciones acústicas (CA). El color indica el algoritmo de denoising, la forma distingue CS (círculo, eje izquierdo) de CA (cuadrado, eje derecho) y las etiquetas indican la métrica acústica y su umbral.

Si el objetivo es alimentar un sistema de reconocimiento automático del habla (ASR), las métricas objetivas consideradas ofrecen una forma rápida de comparar claridad de señal y condiciones acústicas; en las configuraciones ensayadas, favorecieron a Demucs según el puntaje TOT. La utilidad de esa elección debe comprobarse con la tarea de reconocimiento y el corpus de destino.

Para un corpus destinado a TTS o clonación de voz, la estimación de densidad aporta una perspectiva complementaria sobre la compatibilidad con el corpus profesional de referencia. En las ocho configuraciones ensayadas, las medias filtradas más altas correspondieron a DeepFilterNet, pero este resultado no demuestra que esas cadenas produzcan mejores modelos generativos ni que eviten artefactos en todos los escenarios. La evaluación directa de sistemas entrenados con esos datos es necesaria para respaldar una recomendación de uso.

Estos resultados también indican que se debe expandir el análisis de las métricas objetivas para incorporar penalizaciones explícitas por artefactos de denoising, o bien, desarrollar nuevas métricas que puedan capturar la naturalidad espectral y la coherencia temporal, aspectos que el modelo de difusión parece valorar de manera inherente. La principal ventaja que tiene el análisis guiado por métricas objetivas es que permite evaluar de forma rápida y con bajo costo computacional una gran cantidad de variantes, lo cual es fundamental para

poder optimizar la cadena de procesamiento, sobre todo cuando esta esta pensada para ser aplicada a grandes cantidades de datos.

5.5. EVALUACIÓN EXPLORATORIA DE TTS ZERO-SHOT

A continuación, se describe la relación exploratoria entre las métricas objetivas (TOT), el likelihood filtrado y el MOS estimado para el habla sintetizada por modelos de TTS *zero-shot*.

5.5.1. Relación con las Métricas Objetivas (TOT)

En la Figura 16 se ilustra la relación entre la puntuación total de métricas objetivas (TOT) en el eje horizontal y el MOS estimado del audio sintetizado en el eje vertical. Cada punto representa una configuración coincidente: el TOT de esa cadena se empareja con la media de MOS de sus síntesis. La figura incluye diez configuraciones comunes entre ambos resultados; son promedios por configuración y no correspondencias entre identificadores individuales de audio.

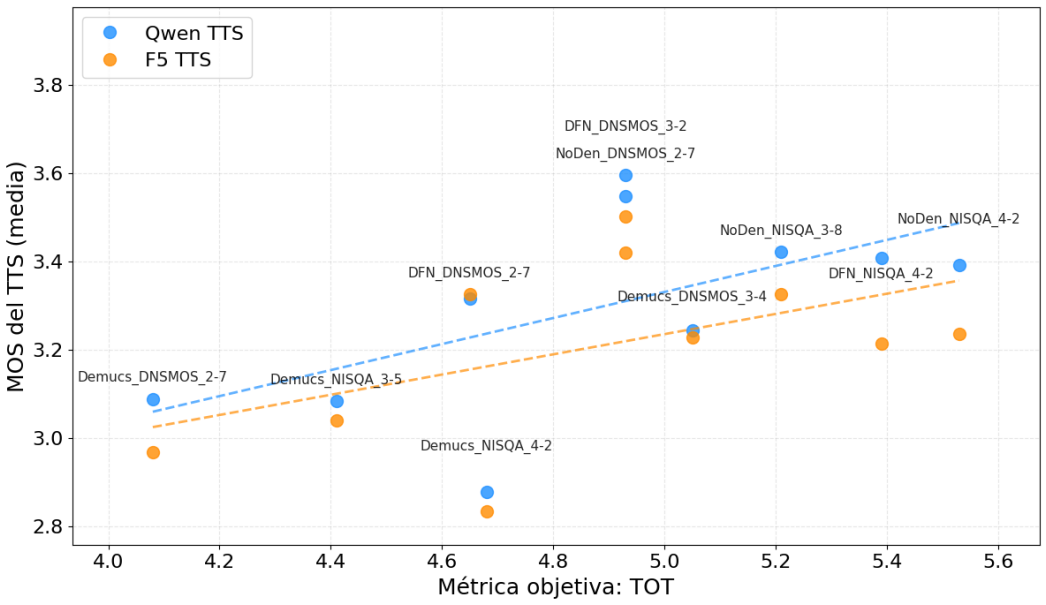


Figura 16. Relación entre la métrica objetiva total (TOT) y la calidad subjetiva sintetizada (MOS).

En las configuraciones evaluadas se observa una tendencia positiva entre TOT y el MOS estimado: los valores mayores de TOT tienden a coincidir con MOS mayores, aunque TOT se define como una métrica que se minimiza. Esta dirección es contraria a la esperada bajo

ese criterio de optimización, pero el patrón por sí solo no demuestra capacidad predictiva ni permite concluir que la métrica objetiva carezca de utilidad para TTS.

Una posible explicación es que el componente de reducción de datos de TOT tenga una relevancia distinta para esta evaluación *zero-shot*, que utiliza referencias cortas. Este análisis no permite aislar el efecto de cada componente de la métrica.

Sobre estas diez configuraciones, las correlaciones de Pearson entre TOT y MOS son positivas para Qwen TTS ($r = 0{,}58$, $p = 0{,}08$) y F5 TTS ($r = 0{,}49$, $p = 0{,}15$), y no alcanzan el umbral de significancia del $5\,\%$. Con este tamaño muestral, la tendencia es exploratoria; estos resultados no validan una relación lineal entre TOT y MOS ni descartan que exista una asociación que requiera más datos para caracterizarse.

5.5.2. Relación con la Estimación de Densidad (Log-Likelihood)

La Figura 17 compara, para cada modelo TTS, la media de likelihood filtrado y la media de MOS asociadas a una misma configuración. Primero se calcula la media de log-likelihood de los recortes retenidos por el filtro post hoc para cada configuración; por separado, se calcula la media de los MOS de las síntesis correspondientes a esa configuración. Luego se emparejan esas dos medias por algoritmo de denoising, métrica acústica y umbral. Cada punto representa ese par de promedios de una configuración, sin emparejar identificadores individuales de audio entre los recortes evaluados y los audios sintetizados. La comparación incluye seis configuraciones con correspondencia exacta en ambos resultados.

Con estos seis pares de medias por configuración, la correlación de Pearson es positiva y no alcanza significancia estadística: para Qwen TTS, $r = 0{,}4671$ ($p = 0{,}3503$); para F5 TTS, $r = 0{,}5973$ ($p = 0{,}2106$). Como descripción del orden de las configuraciones, la correlación de Spearman es $\rho = 0{,}77$ para Qwen TTS y $\rho = 0{,}89$ para F5 TTS. La asociación ordinal observada es más marcada en F5 y debe interpretarse de forma descriptiva.

La tendencia positiva debe interpretarse con cautela: se calcula sobre seis pares de promedios agregados por configuración y no describe una relación entre identificadores individuales de audio. Los resultados ofrecen una observación exploratoria sobre el orden de estas configuraciones, sin validar una relación lineal ni una capacidad predictiva del likelihood.

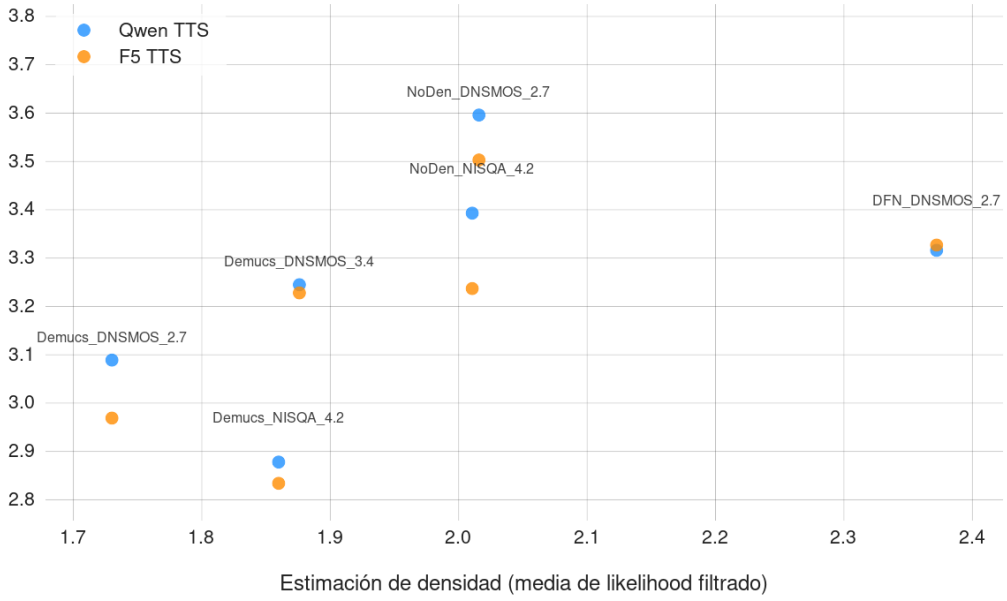


Figura 17. Medias de likelihood y MOS emparejadas por configuración para seis configuraciones coincidentes.

5.5.3. Discusión Final

Los resultados de este experimento muestran ordenamientos distintos entre las métricas objetivas y el likelihood para las configuraciones ensayadas. La correlación entre la estimaciñon de densidad y MOS es más marcada en F5 que en Qwen, mientras que las correlaciones lineales de Pearson no alcanzan significancia estadística en ninguno de los dos modelos.

En consecuencia, el likelihood puede usarse aquí como criterio exploratorio para ordenar las configuraciones evaluadas, pero estos datos no lo validan como predictor lineal del desempeño TTS. Para evaluar su capacidad predictiva se requieren más configuraciones, más datos emparejados y validación independiente, idealmente con juicios de escucha humana.

No obstante, entender esta relación es fundamental en el diseño de pipelines de preprocesamiento de audio para sistemas de ASR y TTS, donde la elección de algoritmos de denoising y filtrado no debe basarse únicamente en métricas objetivas tradicionales, sino también en la preservación de la topología acústica que los modelos generativos esperan encontrar.

Estos resultados también señalan la necesidad de explorar métricas de calidad acús-

tica que sean funcionales a las arquitecturas de modelos generativos actuales y permitan optimizar las distintas etapas de la cadena de procesamiento.

En cinco de las seis configuraciones coincidentes, el MOS medio estimado por Qwen TTS es mayor que el de F5 TTS. Esta diferencia es descriptiva de los modelos, muestras y configuraciones de este experimento; por sí sola no demuestra una diferencia general de rendimiento entre arquitecturas.

Una hipótesis para explorar es que las diferencias entre modelos dependan, en parte, de cómo sus arquitecturas representan las referencias acústicas. Qwen TTS genera a partir de representaciones discretizadas por codecs neuronales, mientras que F5 TTS se basa en flow-matching y difusión. El presente experimento no aisló estos mecanismos ni midió directamente su efecto sobre la calidad percibida.

La correlación positiva observada para F5 en este conjunto de seis configuraciones puede motivar una comparación controlada de arquitecturas. Para establecer si la arquitectura explica ese patrón se necesitarían más cadenas, referencias emparejadas y evaluaciones directas de las síntesis.

Por tanto, estos resultados no permiten concluir que F5 sea un evaluador más estricto ni que Qwen sea más robusto ante referencias no controladas. Ambas interpretaciones quedan como hipótesis para estudios con un diseño que evalúe esos mecanismos de forma directa.

6. CONCLUSIONES

El presente trabajo abordó la evaluación de cadenas de preprocesamiento para generar conjuntos de datos del habla a partir de material *in-the-wild*, mediante métricas acústicas objetivas y estimación de densidad con modelos de difusión probabilística. Para los resultados de likelihood se utilizó la serie canónica filtrada post hoc a nivel de recorte: se excluyeron valores mayores que $4{,}0$ y se conservaron los iguales o menores. La comparación entre criterios se limita a las configuraciones evaluadas y muestra que cada uno resume aspectos distintos del procesamiento.

El ordenamiento por TOT y por likelihood filtrado difirió dentro de las ocho configuraciones con resultados en ambos análisis. La configuración Demucs con DNSMOS 2.7 obtuvo el menor TOT (4.08), mientras que las mayores medias de likelihood correspondieron a DeepFilterNet con DNSMOS 2.7 (2.37) y NISQA 3.8 (2.30); las cuatro configuraciones Demucs quedaron entre 1.69 y 1.88. Este patrón sugiere que el criterio elegido puede cambiar la prioridad asignada a una cadena. Las diferencias espectrales observadas en el ejemplo de Demucs ofrecen una posible explicación, aunque no demuestran el mecanismo ni establecen que un criterio represente por sí solo la calidad perceptual o el rendimiento de TTS.

En la evaluación exploratoria de TTS se compararon medias de likelihood filtrado y MOS de seis configuraciones coincidentes. Las correlaciones lineales de Pearson entre likelihood y MOS fueron positivas, pero no significativas: Qwen TTS obtuvo $r = 0{,}4671$ ($p = 0{,}3503$) y F5 TTS, $r = 0{,}5973$ ($p = 0{,}2106$). La asociación ordinal likelihood-MOS fue más marcada para F5 ($\rho = 0{,}89$) que para Qwen ($\rho = 0{,}77$), de forma descriptiva y con $n = 6$. En una comparación separada de TOT y MOS, basada en diez configuraciones coincidentes, las correlaciones también fueron positivas y no alcanzaron significancia (Qwen: $r = 0{,}58$, $p = 0{,}08$; F5: $r = 0{,}49$, $p = 0{,}15$). Estos datos no validan el likelihood como predictor lineal del desempeño TTS. La tendencia requiere evaluación con más configuraciones, más datos emparejados y validación independiente.

En cinco de las seis configuraciones coincidentes, Qwen TTS obtuvo un MOS medio estimado mayor que F5 TTS. Esta diferencia y la asociación ordinal algo más marcada en F5 pueden orientar una investigación posterior sobre el papel de la arquitectura. El experimento no aisló los mecanismos de cada modelo ni permite concluir que uno sea generalmente

más robusto o más sensible a los artefactos.

Finalmente, en los corpus comparados, el conjunto *in-the-wild* mostró mayor variabilidad prosódica, medida mediante la desviación estándar de la frecuencia fundamental. Este resultado respalda explorar la combinación de datos profesionales y recolectados en condiciones reales para ampliar la variedad prosódica y dialectal; el estudio no prueba por sí solo que esa incorporación mejore la generalización de todos los modelos.

7. LÍNEAS FUTURAS DE INVESTIGACIÓN

Los hallazgos y las limitaciones identificadas a lo largo de este trabajo habilitan diversas líneas de continuación orientadas tanto a la mejora de la cadena de procesamiento como al refinamiento de las metodologías de evaluación empleadas.

Una primera línea, derivada directamente de la divergencia observada entre algoritmos de realce, consiste en el desarrollo de modelos de *speech enhancement* adaptativos o personalizados al dominio acústico del modelo generativo de destino. En lugar de aplicar un denoising de propósito general, dichos modelos buscarían, a través de técnicas de adaptación de dominio, aproximar las grabaciones diversas hacia la distribución acústica esperada por el sistema de síntesis, preservando la topología espectral de la señal y evitando la introducción de artefactos que el modelo replicaría inevitablemente, incrementando así la robustez y la fidelidad de la síntesis resultante.

En estrecha relación con lo anterior, se identifica la necesidad de diseñar nuevas métricas objetivas de bajo costo computacional capaces de penalizar de forma explícita los artefactos topológicos, en particular los huecos espectrales generados por los algoritmos de separación de fuentes. Las métricas tradicionales evaluadas en este trabajo demostraron ser insuficientes para capturar la integridad estructural que requieren las arquitecturas generativas modernas, mientras que el modelo de difusión, aunque más fiel a la percepción de dichos sistemas, presenta un costo de inferencia prohibitivo para su aplicación a gran escala. El desarrollo de descriptores que capturen la naturalidad espectral y la coherencia temporal con la eficiencia de las métricas clásicas permitiría conciliar la rapidez de evaluación con la validez predictiva, aspecto fundamental para optimizar cadenas pensadas para procesar grandes volúmenes de datos.

Una tercera línea de trabajo se orienta a escalar la recolección de datos *in-the-wild* con el objetivo de cubrir exhaustivamente todas las regiones lingüísticas de Argentina. La presente investigación validó la cadena de preprocesamiento sobre dos variantes dialectales representativas; la ampliación de la cobertura hacia la totalidad de los acentos del país consolidaría un corpus de mayor representatividad cultural y contribuiría al desarrollo de tecnologías del habla con arraigo regional, en línea con los objetivos de soberanía tecnológica que motivan este trabajo.

Asimismo, dado el carácter exploratorio de los experimentos de síntesis *zero-shot*, resulta imperativo realizar validaciones subjetivas estandarizadas mediante pruebas de escucha humana que permitan confirmar de forma categórica las tendencias observadas. La predicción automatizada de la calidad subjetiva se encuentra sujeta a múltiples factores inherentes a los propios sintetizadores, por lo que la incorporación de evaluaciones perceptuales con metodologías formales y validación cruzada otorgaría solidez estadística a la conclusión de que la estimación de densidad constituye un predictor robusto del desempeño en tareas generativas.

Por último, se propone explorar diferentes ponderaciones de las variables que componen la métrica conjunta de evaluación objetiva. El análisis de varianza realizado evidenció que ciertos bloques, en particular la reducción de datos, ejercen una influencia desproporcionada sobre el ordenamiento final debido a las características del conjunto de partida. La investigación de esquemas de ponderación que equilibren la contribución de cada componente, o que prioricen criterios específicos según el objetivo del sistema *downstream*, permitiría adaptar la metodología de selección a distintos casos de uso, ya sea favoreciendo la cantidad de material utilizable, la preservación de la identidad vocal o la maximización de la calidad acústica.

BIBLIOGRAFÍA

Ardila, R., Branson, M., Davis, K., Kohler, M., Meyer, J., Henretty, M., Morais, R., Saunders, L., Tyers, F., & Weber, G. (2020). Common Voice: A Massively-Multilingual Speech Corpus. *Proceedings of the Twelfth Language Resources and Evaluation Conference*, 4218-4222. https://aclanthology.org/2020.lrec-1.520/

Ayllón, D., Sánchez-Hevia, H., Figueroa, C., & Lanchantin, P. (2019). Investigating the Effects of Noisy and Reverberant Speech in Text-to-Speech Systems. *Proc. Interspeech*, 1511-1515. https://doi.org/10.21437/Interspeech.2019-3104

Bäckström, T., Räsänen, O., Zewoudie, A., Zarazaga, P. P., Koivusalo, L., Das, S., Mellado, E. G., Mansali, M. B., Ramos, D., Kadiri, S., Alku, P., & Vali, M. H. (2022). *Introduction to Speech Processing* (2.ª ed.). https://doi.org/10.5281/zenodo.6821775

Chen, Y., Wu, Z., Ren, Y., Tan, X., & Zhao, Z. (2024). F5-TTS: A Fairytaler that Fakes Fluent and Faithful Speech with Flow Matching. *arXiv preprint arXiv:2410.06885*.

Cooper, E. (2019,). *Text-to-Speech Synthesis Using Found Data for Low-Resource Languages* [PhD. thesis]. Columbia University.

de Oliveira, D., Richter, J., Lemercier, J.-M., Welker, S., & Gerkmann, T. (2025). Non-intrusive Speech Quality Assessment with Diffusion Models Trained on Clean Speech. *Interspeech 2025*, 2330-2334. https://doi.org/10.21437/Interspeech.2025-1728

Défossez, A., Synnaeve, G., & Adi, Y. (2020). Real Time Speech Enhancement in the Waveform Domain. *Proc. Interspeech*, 3291-3295. https://doi.org/10.21437/Interspeech.2020-2409

de Weinberg, M., & de Mirande, N. (2004). *El español de la Argentina y sus variedades regionales*. Asociación Bernardino Rivadavia, Proyecto Cultural Weinberg/Fontanella. https://books.google.com.ar/books?id=fpxiAAAAMAAJ

Gabriel, C. (2011). Hamburg Corpus of Argentinean Spanish (HaCASpa).

Gonzalez Barrios, G. L. (2021). Intercambios Transorgánicos: Nuevos modos de producir conocimiento en el cruce entre ‘arte, ciencia y tecnología’ desde el paradigma de la complejidad.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2020). Generative adversarial networks. *Commun. ACM*, *63*(11), 139-144. https://doi.org/10.1145/3422622

Guevara-Rukoz, A., Demirsahin, I., He, F., Chu, S.-H. C., Sarin, S., Pipatsrisawat, K., Gutkin, A., Butryna, A., & Kjartansson, O. (2020). Crowdsourcing Latin American Spanish for Low-Resource Text-to-Speech. *Language Resources and Evaluation Conference (LREC)*, 6504-6513. https://aclanthology.org/2020.lrec-1.801/

Gurlekian, J., Güemes, M. M., Evin, D. A., & Torres, H. M. (2021). Normalización del texto "Los sentidosz su aplicación en la evaluación de habla continua. *Onomázein*.

He, H., Shang, Z., Wang, C., Li, X., Gu, Y., Hua, H., Liu, L., Yang, C., Li, J., Shi, P., Wang, Y., Chen, K., Zhang, P., & Wu, Z. (2024). Emilia: An Extensive, Multilingual, and Diverse Speech Dataset For Large-Scale Speech Generation. *IEEE Spoken Language Technology Workshop (SLT)*, 885-890. https://doi.org/10.1109/SLT61566.2024.10832365

Hernandez-Mena, C. D. (2019). TEDx Spanish Corpus. Audio and transcripts in Spanish taken from the TEDx Talks.

Ho, J., Jain, A., & Abbeel, P. (2020). Denoising diffusion probabilistic models. *Proceedings of the 34th International Conference on Neural Information Processing Systems*.

Huang, R., Zhao, Z., Liu, H., Liu, J., Cui, C., & Ren, Y. (2022). ProDiff: Progressive Fast Diffusion Model for High-Quality Text-to-Speech. *Proceedings of the 30th ACM International Conference on Multimedia*, 2595-2605.

Hunt, A. J., & Black, A. W. (1996). Unit selection in a concatenative speech synthesis system using a large speech database. *Proceedings of IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP)*, 373-376.

ISO 3382-2:2008 Acoustics – Measurement of room acoustic parameters – Part 2: Reverberation time in ordinary rooms. (2008). International Organization for Standardization.

ITU-T. (2001, febrero). *Perceptual evaluation of speech quality (PESQ): An objective method for end-to-end speech quality assessment of narrow-band telephone networks and speech codecs* (inf. téc. N.º P.862). International Telecommunication Union.

ITU-T. (2018). *P.863: Perceptual Objective Listening Quality Prediction* (inf. téc. N.º P.863). International Telecommunication Union.

Jeong, M., Kim, H., Cheon, S. J., Choi, B. J., & Kim, N. S. (2021). Diff-TTS: A Denoising Diffusion Model for Text-to-Speech. *Interspeech 2021*, 3605-3609. https://doi.org/10.21437/Interspeech.2021-468

Jung, J., Zhang, W., Maiti, S., Wu, Y., Wang, X., Kim, J.-H., Matsunaga, Y., Um, S., Tian, J., Shim, H.-j., Evans, N., Chung, J. S., Takamichi, S., & Watanabe, S. (2025). The Text-to-speech in the Wild (TITW) Database. *Proc. Interspeech*, 4798-4802. https://doi.org/10.21437/Interspeech.2025-2536

Kim, C., & Stern, R. (2008). Robust signal-to-noise ratio estimation based on waveform amplitude distribution analysis. *Proc. Interspeech*, 2598-2601.

Kim, J., Kong, J., & Son, J. (2021). Conditional Variational Autoencoder with Adversarial Learning for End-to-End Text-to-Speech. *International Conference on Machine Learning*, 5530-5540.

Kingma, D. P., & Welling, M. (2013). Auto-Encoding Variational Bayes.

Koenecke, A., Nam, A., Lake, E., Nudell, J., Quartey, M., Mengesha, Z., Toups, C., Rickford, J. R., Jurafsky, D., & Goel, S. (2020). Racial disparities in automated speech recognition. *Proceedings of the National Academy of Sciences*, *117*(14), 7684-7689.

Kominek, J., Schultz, T., & Black, A. W. (2008). Synthesizer voice quality of new languages calibrated with mean mel cepstral distortion. *Proc. Speech Technology Under-Resourced Languages*, 63-68.

Kong, J., Kim, J., & Bae, J. (2020). HiFi-GAN: generative adversarial networks for efficient and high fidelity speech synthesis. *Proceedings of the 34th International Conference on Neural Information Processing Systems*.

Kong, Z., Ping, W., Huang, J., Zhao, K., & Catanzaro, B. (2021). DiffWave: A Versatile Diffusion Model for Audio Synthesis. *International Conference on Learning Representations*. https://openreview.net/forum?id=a-xFK8Ymz5J

Kumar, A., Tan, K., Ni, Z., Manocha, P., Zhang, X., Henderson, E., & Xu, B. (2023). Torchaudio-Squim: Reference-Less Speech Quality and Intelligibility Measures in Torchaudio. *IEEE International Conference of Acoustics, Speech and Signal Processing (ICASSP)*, 1-5. https://doi.org/10.1109/ICASSP49357.2023.10096680

Le Roux, J., Wisdom, S., Erdogan, H., & Hershey, J. (2019). SDR – Half-baked or Well Done?, 626-630. https://doi.org/10.1109/ICASSP.2019.8683855

Li, X., Jia, K., Sun, H., Dai, J., & Jiang, Z. (2024). Muyan-TTS: A Trainable Text-to-Speech Model Optimized for Podcast Scenarios with a $50K Budget. *arXiv preprint arXiv:2504.19146*. https://arxiv.org/abs/2504.19146

Li, X., Takamichi, S., Saeki, T., Chen, W., Shiota, S., & Watanabe, S. (2023). Yodas: Youtube-Oriented Dataset for Audio and Speech. *2023 IEEE Automatic Speech Recognition and Understanding Workshop (ASRU)*, 1-8. https://doi.org/10.1109/ASRU57964.2023.10389689

Ma, L., Guo, D., Song, K., Jiang, Y., Wang, S., Xue, L., Xu, W., Zhao, H., Zhang, B., & Xie, L. (2024). WenetSpeech4TTS: A 12,800-hour Mandarin TTS Corpus for Large Speech Generation Model Benchmark. *Proc. Interspeech*, 1840-1844. https://doi.org/10.21437/Interspeech.2024-2343

Markl, N. (2023). *Language variation, automatic speech recognition and algorithmic bias* [Tesis doctoral, University of Edinburgh].

Mittag, G., Naderi, B., Chehadi, A., & Möller, S. (2021). NISQA: A Deep CNN-Self-Attention Model for Multidimensional Speech Quality Prediction with Crowdsourced Datasets. *Proc. Interspeech*, 2127-2131. https://doi.org/10.21437/Interspeech.2021-299

Oliveira, F. S., Casanova, E., Junior, A. C., Soares, A. S., & Galvão Filho, A. R. (2023). CML-TTS: Multilingual Dataset for Speech Synthesis in Low-Resource Languages. *Text, Speech, and Dialogue: 26th International Conference, TSD 2023, Pilsen, Czech Republic, September 4–6, 2023, Proceedings*, 188-199. https://doi.org/10.1007/978-3-031-40498-6_17

Ortega Riera, P., Passano, N., Paez, D., Bach, F., Pupkin, I., Sacerdoti, E., Yommi, M., & Martín, H. (2023). Implementación y Evaluación de un Sistema de Clonación de Voz Rioplatense para Asistencia en la Comunicación Oral. *Jornadas de Acústica, Audio y Sonido*.

Ortiz, M. (2023). Estimación ciega de parámetros acústicos de un recinto. *Master Thesis*.

Parzen, E. (1962). On Estimation of a Probability Density Function and Mode. *The Annals of Mathematical Statistics*, *33*(3), 1065-1076.

Popov, V., Vovk, I., Gogoryan, V., Sadekova, T., & Kudinov, M. (2021). Grad-TTS: A Diffusion Probabilistic Model for Text-to-Speech. *International Conference on Machine Learning*, 8599-8608.

Pratap, V., Xu, Q., Sriram, A., Synnaeve, G., & Collobert, R. (2020). MLS: A Large-Scale Multilingual Dataset for Speech Research. *Interspeech 2020*, 2757-2761. https://doi.org/10.21437/Interspeech.2020-2826

Radford, A., Kim, J., Xu, T., Brockman, G., Mcleavey, C., & Sutskever, I. (2023). Robust Speech Recognition via Large-Scale Weak Supervision. *Proceedings of the 40th International Conference on Machine Learning*, *202*, 28492-28518.

Reddy, C. K. A., Gopal, V., & Cutler, R. (2021). Dnsmos: A Non-Intrusive Perceptual Objective Speech Quality Metric to Evaluate Noise Suppressors. *IEEE International Conference of Acoustics, Speech and Signal Processing (ICASSP)*, 6493-6497. https://doi.org/10.1109/ICASSP39728.2021.9414878

Ren, Y., Hu, C., Tan, X., Qin, T., Zhao, S., Zhao, Z., & Liu, T.-Y. (2021a). FastSpeech 2: Fast and High-Quality End-to-End Text to Speech. *International Conference on Learning Representations (ICLR)*.

Ren, Y., Hu, C., Tan, X., Qin, T., Zhao, S., Zhao, Z., & Liu, T.-Y. (2021b). FastSpeech 2: Fast and High-Quality End-to-End Text to Speech. *International Conference on Learning Representations*.

Ricaurte, P. (2019). Data Epistemologies, The Coloniality of Power, and Resistance. *Television & New Media*, *20*(4), 350-365.

Riou, A., Lattner, S., Hadjeres, G., & Peeters, G. (2023). PESTO: Pitch Estimation with Self-supervised Transposition-equivariant Objective. *Proceedings of the 24th International Society for Music Information Retrieval Conference (ISMIR)*.

Sabra, A., Wronka, C., Mao, M., & Hijazi, S. (2024). SECP: A Speech Enhancement-Based Curation Pipeline for Scalable Acquisition of Clean Speech. *IEEE International Conference of Acoustics, Speech and Signal Processing (ICASSP)*, 11981-11985. https://doi.org/10.1109/ICASSP48485.2024.10446973

Schroter, H., Escalante-B, A. N., Rosenkranz, T., & Maier, A. (2022). Deepfilternet: A Low Complexity Speech Enhancement Framework for Full-Band Audio Based On Deep Filtering. *IEEE International Conference of Acoustics, Speech and Signal Processing (ICASSP)*, 7407-7411. https://doi.org/10.1109/ICASSP43922.2022.9747055

Shen, J., et al. (2018a). Natural TTS synthesis by conditioning wavenet on mel spectrogram predictions. *2018 IEEE international conference on acoustics, speech and signal processing (ICASSP)*, 4779-4783.

Shen, J., Pang, R., Weiss, R. J., Schuster, M., Jaitly, N., Yang, Z., Chen, Z., Zhang, Y., Wang, Y., Skerry-Ryan, R. J., Saurous, R. A., Agiomyrgiannakis, Y., & Wu, Y. (2018b). Natural TTS Synthesis by Conditioning WaveNet on Mel Spectrogram Predictions. *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 4779-4783. https://doi.org/10.1109/ICASSP.2018.8461368

Song, Y., Sohl-Dickstein, J., Kingma, D. P., Kumar, A., Ermon, S., & Poole, B. (2021). Score-Based Generative Modeling through Stochastic Differential Equations. *International Conference on Learning Representations*. https://openreview.net/forum?id=PxTIG12RRHS

Sosa Welford, A., & Pepino, L. (2025). A Dataset for Automatic Assessment of TTS Quality in Spanish. *Interspeech 2025*, 4813-4817. https://doi.org/10.21437/Interspeech.2025-973

Taal, C., Hendriks, R., Heusdens, R., & Jensen, J. (2011). An Algorithm for Intelligibility Prediction of Time–Frequency Weighted Noisy Speech. *Audio, Speech, and Language Processing, IEEE Transactions on*, *19*, 2125-2136. https://doi.org/10.1109/TASL.2011.2114881

Tan, X., Qin, T., Soong, F. K., & Liu, T.-Y. (2021). A Survey on Neural Speech Synthesis. *arXiv preprint arXiv:2106.15561*. https://arxiv.org/abs/2106.15561

Team, S. (2024). Silero VAD: pre-trained enterprise-grade Voice Activity Detector (VAD), Number Detector and Language Classifier.

Tokuda, K., Nankaku, Y., Toda, T., Zen, H., Yamagishi, J., & Oura, K. (2013). Speech synthesis based on hidden Markov models. *Proceedings of the IEEE*, *101*(5), 1234-1252. https://doi.org/10.1109/JPROC.2013.2251852

Torres, H. M., Gurlekian, J. A., Evin, D. A., & Cossio Mercado, C. G. (2019). Emilia: a speech corpus for Argentine Spanish text to speech synthesis. *Language Resources and Evaluation*, *53*(3), 419-447.

van den Oord, A., Dieleman, S., Zen, H., Simonyan, K., Vinyals, O., Graves, A., Kalchbrenner, N., Senior, A., & Kavukcuoglu, K. (2016). WaveNet: A Generative Model for Raw Audio. *9th ISCA Workshop on Speech Synthesis Workshop (SSW 9)*, 125.

Van Den Oord, A., Kalchbrenner, N., & Kavukcuoglu, K. (2016). Pixel recurrent neural networks. *Proceedings of the 33rd International Conference on International Conference on Machine Learning - Volume 48*, 1747-1756.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need [NeurIPS 2017]. *Advances in Neural Information Processing Systems*.

Wang, C., Riviere, M., Lee, A., Wu, A., Talnikar, C., Haziza, D., Williamson, M., Pino, J., & Dupoux, E. (2021). VoxPopuli: A Large-Scale Multilingual Speech Corpus for Representation Learning, Semi-Supervised Learning and Interpretation. *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, 993-1003. https://doi.org/10.18653/v1/2021.acl-long.80

Xie, T., Rong, Y., Zhang, P., & Liu, L. (2024). Towards Controllable Speech Synthesis in the Era of Large Language Models: A Survey. *arXiv preprint arXiv:2412.06602*. https://arxiv.org/abs/2412.06602

Yu, C., Lu, H., Yuan, N., & Hu, C. (2020). DurIAN: Duration Informed Attention Network for Multimodal Synthesis. *Interspeech 2020*, 2027-2031. https://doi.org/10.21437/Interspeech.2020-1848

Yu, J., Chen, H., Bian, Y., Li, X., Luo, Y., Tian, J., Liu, M., Jiang, J., & Wang, S. (2024). AutoPrep: An Automatic Preprocessing Framework for In-The-Wild Speech Data. *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 1136-1140. https://doi.org/10.1109/ICASSP48485.2024.10447759

ANEXO I: Comparación métricas individuales

Comparación para métrica de calidad de señal

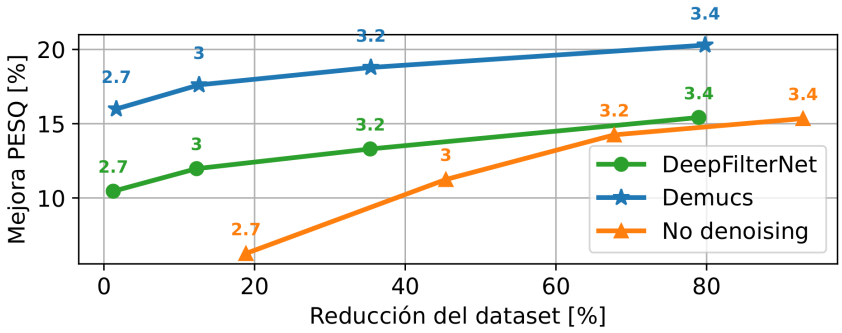


Figura 18. Comparación entre PESQ y horas del dataset para diferentes variantes con DNSMOS.

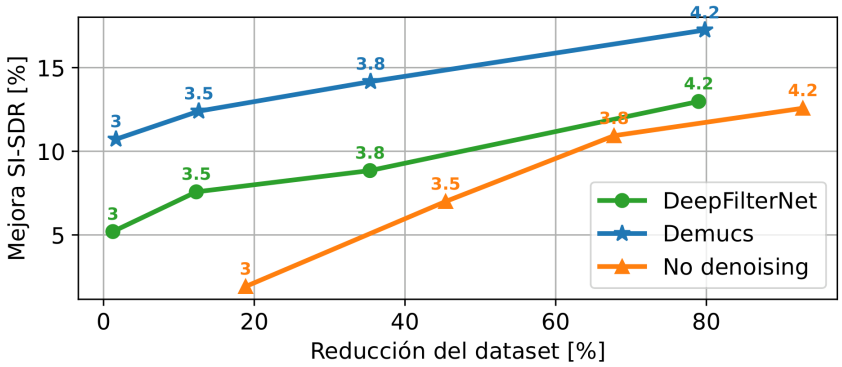


Figura 19. Comparación entre SI-SDR y horas del dataset para diferentes variantes con DNSMOS.

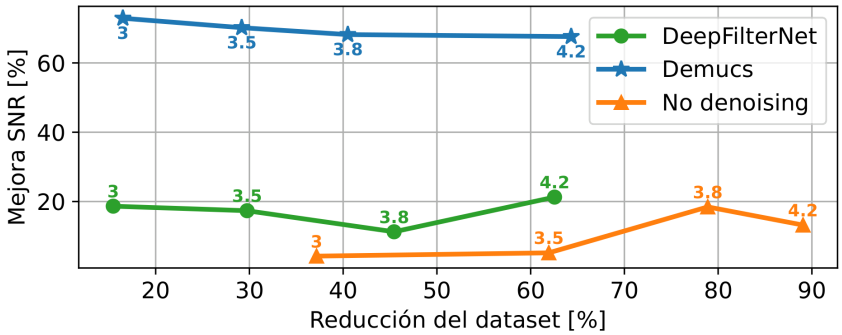


Figura 20. Comparación entre SNR y horas del dataset para diferentes variantes con NISQA.

Comparación para métrica de condiciones acústicas

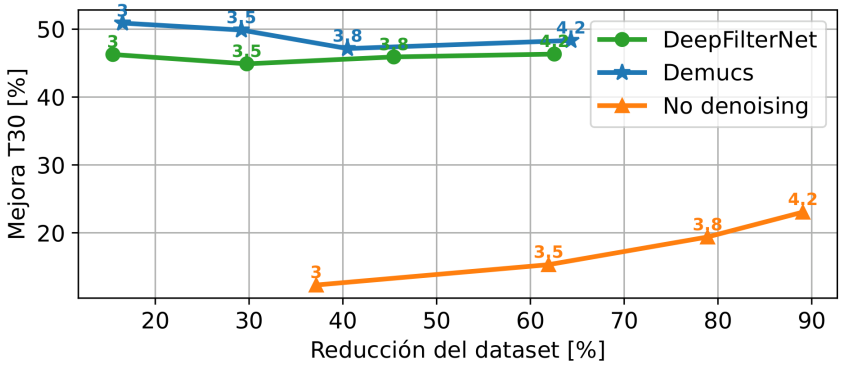


Figura 21. Comparación entre T30 y horas del dataset para diferentes variantes con NISQA.

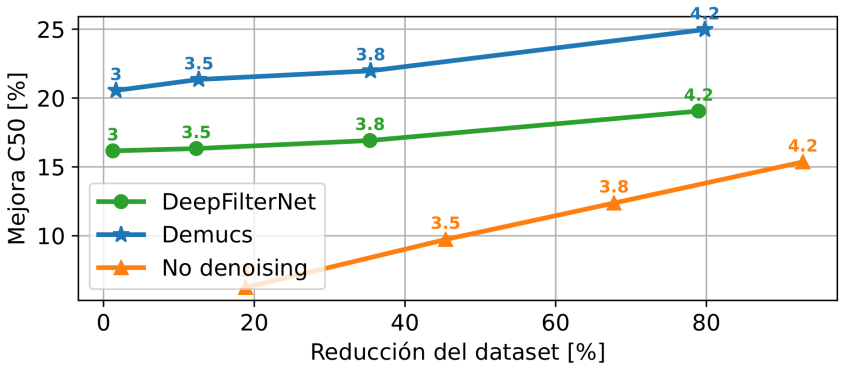


Figura 22. Comparación entre C50 y horas del dataset para diferentes variantes con DNSMOS.

Comparación métrica de diferencias del hablante vs calidad de señal

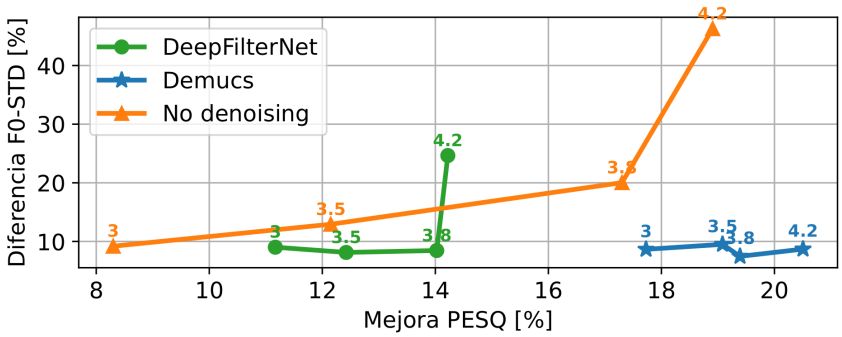


Figura 23. Comparación entre F0-std y PESQ del dataset para diferentes variantes con DNSMOS.

ANEXO II: Comparación métricas compuestas

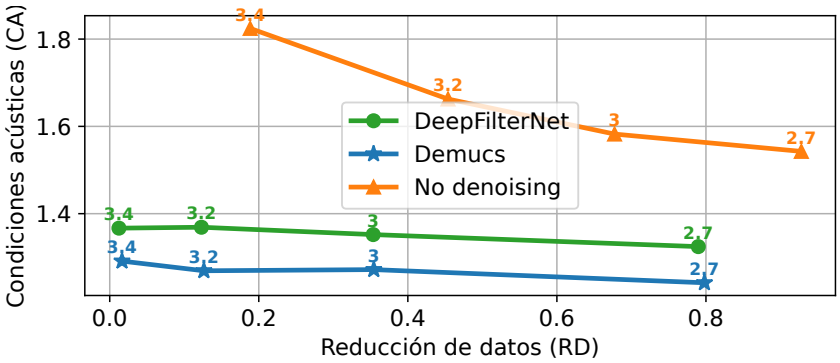


Figura 24. Comparación entre RD y CA del dataset para diferentes variantes con DNSMOS.

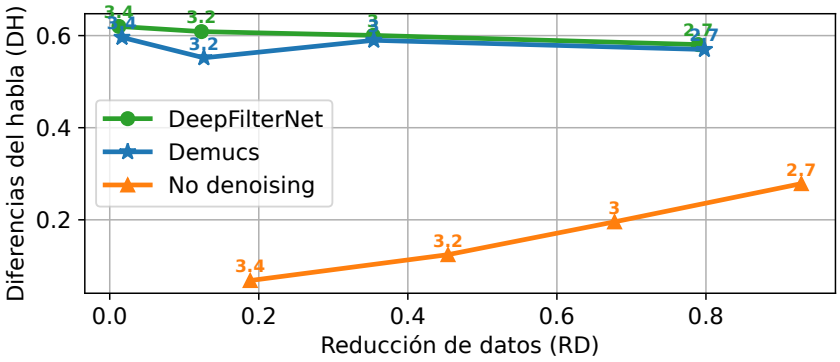


Figura 25. Comparación entre RD y DH del dataset para diferentes variantes con DNSMOS.

ANEXO III: Comparación entre dataset ITW vs Profesional

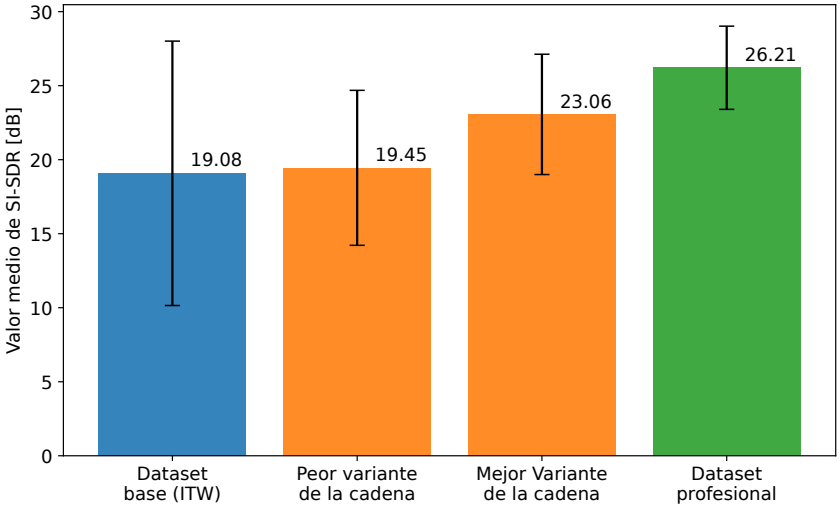


Figura 26. Comparación entre SI-SDR de los datasets ITW y Profesional.

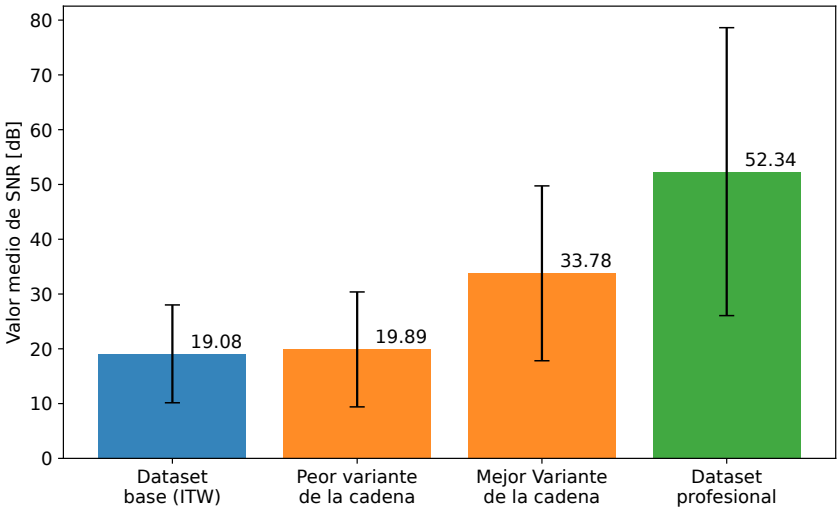


Figura 27. Comparación entre SNR de los datasets ITW y Profesional.

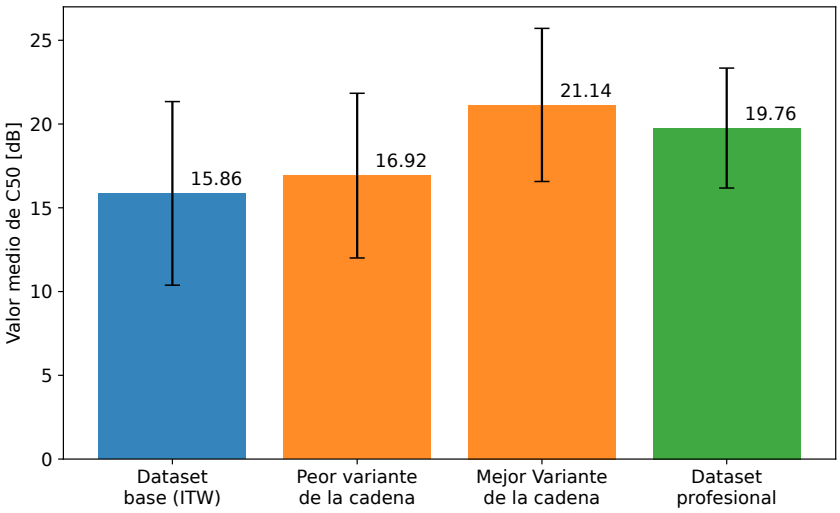


Figura 28. Comparación entre C50 de los datasets ITW y Profesional.